uc3m | Universidad Carlos III de Madrid

Máster en Ciencia y Tecnología Informática

Trabajo de Fin de Máster

«Metodología para la integración de agentes generativos en la toma de decisiones en la fase de preproyecto»

Autor
Adrián Fernández Galán

Tutoras
María Isabel Sánchez Segura
Fuensanta Medina Domínguez

Leganés, Madrid
Septiembre 2026

Esta obra se encuentra sujeta a la licencia Creative Commons
Reconocimiento – No Comercial – Sin Derivadas 4.0 International

And every day, every week, every month and every year of my life, my hero's always 10 years away. I'm never gonna be my hero. I'm not gonna attain that. I know I'm not, and that's just fine with me because that keeps me with somebody to keep on chasing.

— Matthew McConaughey

RESUMEN

Las iniciativas de transformación digital experimentan una tasa de fracaso cercana al 70%, originada en gran medida por decisiones tecnológicas deficientes en la fase de preproyecto y la consiguiente acumulación de deuda técnica. Aunque marcos como SWEBOK formalizan el proceso de toma de decisiones en ingeniería, su adopción en PYMEs se ve frenada por el coste de la educción cualitativa manual de activos intangibles.

Para resolver este cuello de botella, este Trabajo de Fin de Máster propone **AI-Driven DTGEP**, una metodología que automatiza la recolección cualitativa mediante agentes de Inteligencia Artificial. La solución descarga al ingeniero mediante un motor conversacional autónomo desarrollado en LangGraph (paradigma ReAct), con memoria jerárquica y persistencia en esquemas JSON estrictos. Estos datos alimentan de forma desacoplada tres tuberías deterministas: diagnóstico de madurez digital (ALTUS), deducción de activos y artefactos tecnológicos (SIPAC), y priorización multicriterio jerárquica (AHP), todo integrado en una plataforma web con visualización reactiva.

La validación experimental sobre cuatro organizaciones reales evaluó siete modelos de lenguaje (desde 4B locales en hardware de consumo hasta 300B en la nube). Los resultados confirman que el sistema alcanza un error medio absoluto (MAE) de 1.06–1.27 niveles en ALTUS (alineado con la variabilidad inter-evaluador humana), un *Weighted Recall* del 88.9% en la recuperación de soluciones en SIPAC, y una estricta consistencia matemática en AHP ($CR < 0.10$, con ratios entre 0.04 y 0.08). Estos hallazgos validan la viabilidad de asistir y agilizar la consultoría técnica mediante agentes de IA sin comprometer el rigor formal.

Palabras clave: Inteligencia Artificial Agéntica • Toma de Decisiones en Ingeniería • Modelos de Lenguaje • Software Engineering Economics

AGRADECIMIENTOS

En primer lugar, quiero expresar mi más sincero y profundo agradecimiento a mis padres por su apoyo incondicional en cada etapa de este camino. Gracias por estar siempre ahí, por creer en mí y por levantarme el ánimo en aquellos momentos en los que se hacía difícil avanzar en solitario. Su aliento y cariño constantes han sido mi mayor fortaleza.

A mis tutoras, María Isabel Sánchez Segura y Fuensanta Medina Domínguez, por su dedicación, cercanía y valiosa orientación a lo largo de este proyecto. Gracias por cada una de sus ideas, por el tiempo y el material facilitados, y por impulsar este trabajo para que alcance su mejor versión. Sin su guía y confianza, la realización de este trabajo no habría sido posible.

Asimismo, agradezco al Grupo de Usuarios de Linux de la Universidad Carlos III de Madrid (GUL UC3M) por desarrollar y compartir de forma abierta esta fantástica plantilla, cuya calidad, flexibilidad y rigor formal han facilitado enormemente la elaboración y maquetación de este documento.

TABLA DE CONTENIDOS

Capítulo 1. Introducción 1

1.1. Propuesta de Solución 4
1.2. Objetivos 5
1.3. Estructura del documento 5

Capítulo 2. Estado del Arte 7

2.1. El Marco de Decisión y la Necesidad de Información 7
2.2. Metodologías de Evaluación y Toma de Decisiones 8
2.3. La Inteligencia Artificial en la Fase de Pre-proyecto 9
2.4. Síntesis de la Brecha Metodológica y Tecnológica 11

Capítulo 3. Solución Propuesta 13

3.1. Descripción de la Metodología Propuesta: AI-Driven DTGEP 13
3.2. Arquitectura del Software: Motor Genérico e Instanciación de AI-Driven DTGEP. . 17
3.2.1. Motor de Educción 17
3.2.2. Fase de Procesamiento Algorítmico 30
3.2.3. Arquitectura Web del Sistema 35

Capítulo 4. Marco y Resultados de la Evaluación Experimental 41

4.1. Marco y Configuración Experimental 41
4.1.1. Criterios de Evaluación y Rol del Juez LLM 42
4.1.2. Modelos Evaluados e Infraestructura 43
4.2. Evaluación de ALTUS: Diagnóstico de Madurez y Proceso Conversacional 44
4.2.1. Diseño Experimental y Entorno de Simulación 44
4.2.2. Métricas de Evaluación de ALTUS 44
4.2.3. Resultados Empíricos en ALTUS 45
4.3. Evaluación de SIPAC: Deducción Semántica e Inferencia en Cadena 48
4.3.1. Pipeline de Evaluación Semántica Bipartita y Rúbricas Graduadas 48
4.3.2. Resultados Empíricos en SIPAC 50
4.4. Evaluación de AHP: Soporte a la Decisión y Priorización Multicriterio 55
4.4.1. Diseño y Justificación de las Rúbricas de Soporte a la Decisión 55
4.4.2. Resultados Empíricos en AHP 57
4.5. Viabilidad Operativa y Rendimiento Temporal 59
4.5.1. Análisis Comparativo de Entornos de Despliegue 60
4.5.2. Cuello de Botella en Memoria y Recomendaciones de Despliegue 61

4.6. Contraste de Paradigmas: AI-Driven DTGEP frente a la Inferencia Directa con LLMs 62
4.7. Validez y Limitaciones del Estudio Experimental 64
4.7.1. Validez de Constructo 65
4.7.2. Validez Interna 65
4.7.3. Validez Externa 66
4.7.4. Validez de Conclusión 66

Capítulo 5. Conclusiones y Trabajo Futuro **67**
5.1. Síntesis del Trabajo y Grado de Cumplimiento de Objetivos 67
5.2. Contribuciones Principales 68
5.3. Lecciones Aprendidas e Implicaciones Prácticas 69
5.4. Trabajo Futuro y Líneas de Investigación 70
5.4.1. Ampliación Metodológica y Nuevos Dominios de Decisión 70
5.4.2. Evolución de la Arquitectura del Motor Agéntico 71
5.4.3. Extensión y Profundización del Marco Experimental 71

Bibliografía **73**

Apéndice A. Formulación Matemática de las Metodologías de Decisión

Apéndice B. Tablas Detalladas de la Evaluación Experimental

Apéndice C. Declaración de uso de IA generativa

ÍNDICE DE FIGURAS

Fig. 1.1 Alineación e integración de los subprocesos de DTGEP en las etapas del Engineering Decision-Making Process del SWEBOK. 3

Fig. 3.1 Metodología DTGEP. Subprocesos resaltados indican adaptaciones para AI-Driven DTGEP. 14

Fig. 3.2 Representación global de los procesos principales de la solución propuesta. . 15

Fig. 3.3 Modelo de ejecución asíncrono y separación de fases. 17

Fig. 3.4 Ubicación del motor de educción dentro de la arquitectura global. 18

Fig. 3.5 Casos de uso principales del motor de educción. 20

Fig. 3.6 Flujo funcional de una sesión de entrevista. 22

Fig. 3.7 Modelo de datos principal: configuración, tareas y estado. 22

Fig. 3.8 Ubicación de los ficheros de salida dentro de la arquitectura global. 25

Fig. 3.9 Estructura de datos: configuración, estado de ejecución y salida. 26

Fig. 3.10 Arquitectura de estados y transiciones del motor de educción. 28

Fig. 3.11 Detalle de ejecución (zoom del sistema) del flujo de gestión de memoria y estado para la prevención de preguntas redundantes. 29

Fig. 3.12 Capa de abstracción LLM: mapeo de nodos a funciones y pipeline interno. . . 30

Fig. 3.13 Ubicación de la fase de procesamiento dentro de la arquitectura global. 31

Fig. 3.14 Tuberías de procesamiento algorítmico para las metodologías ALTUS, SIPAC y AHP. 31

Fig. 3.15 Vista principal de la aplicación web: panel de configuración y sesiones activas en memoria. 37

Fig. 3.16 Modalidades de configuración de sesiones: (izq.) Pipeline encadenado AI-Driven DTGEP; (der.) Formulario de creación de procesos personalizados. 38

Fig. 3.17 Interfaz de entrevista agéntica: canal de diálogo en tiempo real y visualizador reactivo del grafo de estados en React Flow. 38

Fig. 3.18 Dashboard de resultados de madurez digital ALTUS con huella radar y matriz de cobertura. 39

Fig. 3.19 Visualizador interactivo de Business Model Canvas (BMC) derivado de la evaluación SIPAC. 39

Fig. 3.20 Dashboard de resultados de priorización multicriterio AHP con vector de pesos y matriz de decisión. 40
Fig. 4.1 Evaluación diagnóstica (Accuracy y MAE) en ALTUS frente a la línea base aleatoria. 46
Fig. 4.2 Eficacia extractiva (Hit Rate) frente a error diagnóstico (MAE) en ALTUS. . . . 47
Fig. 4.3 Balance de Precision, Recall y F_1 ponderado por modelo en SIPAC. 51
Fig. 4.4 Weighted F1 por dimensión en las fases de inferencia de SIPAC. 52
Fig. 4.5 Puntuación acumulada y desglose dimensional de calidad en AHP. 58
Fig. 4.6 Razón de Consistencia (CR) frente a solidez del juicio pareado en AHP. 59
Fig. 4.7 Tiempo de ejecución acumulado por metodología en inferencia local. 61

ÍNDICE DE TABLAS

Tabla 2.1 Comparativa entre la consulta directa a un llm y una arquitectura agéntica integrada. 11

Tabla 4.1 Especificaciones técnicas y entorno de ejecución de los modelos evaluados. . 43

Tabla 4.2 Rúbrica de evaluación para preguntas de seguimiento en ALTUS. 45

Tabla 4.3 Rúbricas de evaluación semántica por campos en SIPAC. 49

Tabla 4.4 Comparativa de deducción de artefactos tecnológicos frente al Ground Truth y evaluación semántica en SIPAC (caso G3, Gemini 3.7 Flash). 53

Tabla 4.5 Tasa de descarte por filtrado vectorial previo (sim < 0.35) por modelo y fase en SIPAC. 54

Tabla 4.6 Rúbrica de evaluación del soporte a la decisión en AHP. 57

Tabla 4.7 Comparativa de entregables entre Línea Base y AI-Driven DTGEP (caso G3).. . . 63

Tabla B.1 Métricas detalladas de diagnóstico y diálogo conversacional en ALTUS. 84

Tabla B.2 Métricas detalladas de deducción semántica (Weighted F1) en SIPAC. 85

Tabla B.3 Métricas detalladas de soporte a la decisión y consistencia en AHP. 86

CAPÍTULO 1

INTRODUCCIÓN

La transformación digital ha dejado de ser una opción para convertirse en una necesidad estratégica de las organizaciones modernas. Los datos de la Organización para la Cooperación y el Desarrollo Económicos (OCDE) evidencian por qué: las empresas de sectores de alta intensidad digital presentan márgenes un 55% superiores a la media y fueron responsables de la creación de en torno al 40% de los 38 millones de empleos generados en el área de la OCDE entre 2006 y 2016 [1]. Esta brecha competitiva explica que más del 80% de las organizaciones hayan acelerado o planeen acelerar sus iniciativas de transformación digital [2]. Sin embargo, a pesar de este impulso generalizado, las tasas de éxito de estas iniciativas son preocupantemente bajas, rondando apenas el 16–30% [3], o incluso llegando a fracasar en un 70% de los casos según distintos estudios de la industria y la literatura académica [2], [4], [5]. La investigación de BCG sobre 70 compañías líderes constata que únicamente el 30% de las iniciativas alcanza o supera sus objetivos con un cambio sostenido, mientras que el 26% restante genera un valor inferior al 50% del objetivo fijado [2]. Esta incapacidad de alineación no solo supone pérdidas económicas ingentes, sino que además genera **deuda técnica**, derivada de implantar soluciones tecnológicas inadecuadas que no están alineadas con la realidad de la organización [4]. Según datos de McKinsey, entre el 10% y el 20% del presupuesto tecnológico destinado a nuevos productos acaba desviado a resolver problemas de sistemas legacy, y la deuda técnica acumulada puede representar entre el 20% y el 40% del valor total del parque tecnológico de la organización [6].

La causa de este fracaso sistemático no es técnica: reside en cómo se toman las decisiones tecnológicas. El ingeniero de software desempeña un papel que va más allá del diseño técnico; es el responsable de determinar qué camino tecnológico adoptar y qué valor reportará a la organización. Esta dimensión económica de la práctica de la ingeniería tiene nombre y marco de referencia propio. Tal y como establece la guía SWEBOK v4 [7], el área de conocimiento de **Economía de la Ingeniería de Software** (*Software Engineering Economics*) se define fundamentalmente como la «ciencia de la elección»: la disciplina

encargada de encontrar el equilibrio entre lo técnicamente factible y lo económicamente aceptable, alineando cada decisión técnica con el valor real que aporta al negocio.

El SWEBOK [7] formaliza este proceso bajo el concepto de *Engineering Decision-Making Process*, un ciclo sistemático que exige, ante cada decisión de alto impacto: entender el problema real, identificar los criterios de evaluación, generar y valorar alternativas, y seleccionar la que maximice el valor para la organización. La clave que distingue una ingeniería de calidad es que cuando las consecuencias de una decisión errónea son altas, la inversión en ejecutar este proceso de manera exhaustiva debe ser proporcionalmente mayor. Dicho proceso se articula en seis etapas formales:

1. **Entender el problema real** (*Understand the real problem*).
2. **Definir los criterios de selección** (*Define the selection criteria*).
3. **Identificar todas las soluciones razonables y técnicamente viables** (*Identify all reasonable technically feasible solutions*).
4. **Evaluar cada alternativa frente a los criterios de selección** (*Evaluate each alternative against the selection criteria*).
5. **Seleccionar la alternativa preferida** (*Select the preferred alternative*).
6. **Supervisar el rendimiento de la alternativa seleccionada** (*Monitor the performance of the selected alternative*).

Su principal virtud —y a la vez su mayor limitación práctica en la fase de preproyecto — es su elevado nivel de abstracción: al no prescribir actividades particulares, resulta lo suficientemente general como para ser aplicable a cualquier problema de ingeniería, pero carece de la precisión operativa necesaria para guiar directamente la toma de decisiones en iniciativas complejas como la digitalización de una empresa.

Para salvar esta brecha entre abstracción y aplicabilidad, la metodología DTGEP (*Digital Transformation Governance Engineering Process*) [4] abraza por completo este ciclo de toma de decisiones del SWEBOK, traduciendo cada una de sus fases en subprocesos de ingeniería precisos y estructurados. En este marco, los subprocesos **DTGEP1** (evaluación de la madurez del conocimiento digital) y **DTGEP2** (identificación y caracterización de activos de conocimiento) abordan de manera sistemática la primera etapa de **entender el problema real**, estableciendo el punto de partida real y la capacidad organizativa de la empresa. A continuación, los subprocesos **DTGEP3** (diagnóstico de la transformación digital) y **DTGEP4** (definición del plan de transformación digital) concretan la etapa de **identificar todas las soluciones razonables y técnicamente viables**, detectando las brechas organizativas para formular de manera estructurada las alternativas tecnológicas (artefactos) que las mitiguen.

Por su parte, el subproceso **DTGEP5** (toma de decisiones) da respuesta a las etapas de **definir los criterios de selección**, **evaluar cada alternativa frente a los criterios de selección** y **seleccionar la alternativa preferida**, orquestando la definición de criterios multicriterio y la evaluación cuantitativa de las alternativas para seleccionar la propuesta final. Por último, el subproceso **DTGEP6** (desarrollo del plan de transformación digital) cubre la etapa de **supervisar el rendimiento de la alternativa seleccionada**, asumiendo la ejecución de la solución y evaluando su impacto real a largo plazo en los objetivos del negocio.

De este modo, DTGEP dota de rigor operativo al preproyecto de transformación digital sin renunciar al marco formal de la economía de la ingeniería de software clásica. La alineación entre ambos marcos —y el flujo conjunto que los integra— se ilustra en la Fig. 1.1.

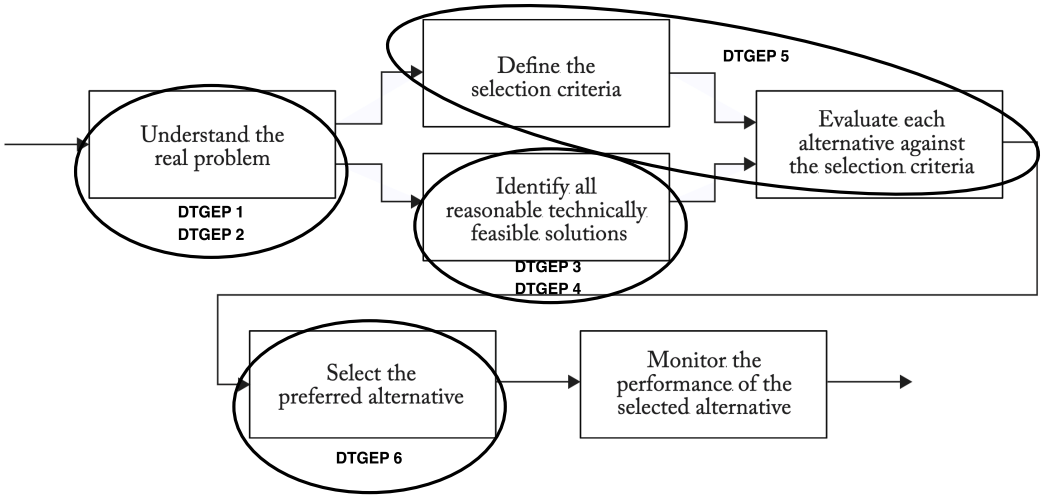


Fig. 1.1. Alineación e integración de los subprocesos de DTGEP en las etapas del Engineering Decision-Making Process del SWEBOK.

Sin embargo, disponer de un marco metodológico riguroso que contemple la evaluación de los **activos intangibles** no resuelve por sí solo el problema operativo. Como señala Sanchez-Segura et al. [8], las organizaciones poseen un «lado intangible» —conocimiento, procesos, cultura, experiencia— que funciona como la parte sumergida de un iceberg: determina el resultado de cualquier implementación tecnológica, pero raramente se hace visible. Los métodos de toma de decisiones multicriterio (MCDM) como el *Analytic Hierarchy Process* (AHP) [9] existen precisamente para valorar estas dimensiones, pero presuponen que los datos ya están disponibles y estructurados. El problema es que nadie los recoge de forma sistemática: proponer una solución digital ignorando la base intangible de la organización es construir sobre cimientos débiles, lo que inevitablemente conduce al fracaso del proceso de digitalización [10].

Aquí reside el problema central: el proceso de evaluación de estos intangibles **carece de un mecanismo de elicitación automatizado** [7]. Para identificar y caracterizar explícitamente estos activos —tal y como proponen marcos como DTGEP integrando la metodología SIPAC [11]— el ingeniero debe realizar largas entrevistas con los *stakeholders* (directivos, responsables de área y demás personas que poseen información valiosa sobre la organización). La fase de recolección cualitativa —aquella en la que se descubren los intangibles, se mapean los procesos y se construyen los criterios de decisión— recae íntegramente sobre el ingeniero, convirtiéndolo en el cuello de botella a la hora de tomar decisiones sobre cuál es la mejor solución tecnológica a desplegar en cada caso. El resultado es que, ante el alto coste operativo de ejecutar esta elicitación con rigor, la industria sistemáticamente omite o simplifica esta etapa del *Engineering Decision-Making Process*, tomando decisiones tecnológicas basadas únicamente en criterios técnicos.

Los recientes avances en **Inteligencia Artificial agéntica** ofrecen, por primera vez, una vía real para romper este cuello de botella. A diferencia de los sistemas de IA tradicionales, un agente de IA puede planificar, razonar sobre su entorno y ejecutar acciones de forma autónoma [12]. En particular, la combinación de Grandes Modelos de Lenguaje (LLMs) con capacidades de razonamiento y acción —paradigma conocido como *ReAct* [13]— permite construir agentes conversacionales que conduzcan entrevistas profundas y adaptativas con los *stakeholders*, sin necesidad de que el ingeniero esté presente en tiempo real. Además, trabajos recientes ya demuestran la viabilidad de utilizar aproximaciones tecnológicas basadas en el Procesamiento de Lenguaje Natural (NLP) y minería de texto para la extracción y descubrimiento automático de activos intangibles a partir de repositorios corporativos no estructurados [14], validando la automatización tecnológica de este esfuerzo de elicitación.

Esto abre la hipótesis de trabajo de esta investigación: el diseño e integración de una **metodología de toma de decisiones asistida por IA agéntica** en la fase de elicitación del *Engineering Decision-Making Process* [7] permite automatizar la captura de conocimiento cualitativo y la formalización de decisiones tecnológicas sin comprometer el rigor analítico ni la consistencia matemática de los modelos formales de decisión, reduciendo drásticamente la carga de dedicación directa del ingeniero de software y haciendo viable su adopción en organizaciones con recursos computacionales limitados.

1.1. Propuesta de Solución

Para dar respuesta a este problema, el presente trabajo propone una **metodología para la integración de agentes generativos en la toma de decisiones en la fase de preproyecto**. La idea central es: sustituir la entrevista síncrona manual —en la que el ingeniero de software debe estar presente para recoger la información— por un agente conversacional autónomo que conduzca ese proceso en nombre del ingeniero, de forma asíncrona, y persista sus resultados de manera estructurada.

Este modelo asíncrono resuelve el cuello de botella operativo aportando un doble beneficio. Por una parte, libera al ingeniero de software de la tarea de recolección manual, permitiéndole concentrar su esfuerzo en actividades de mayor valor: el análisis cualitativo, la evaluación de alternativas y la toma de la decisión final. Asimismo, **garantiza la transparencia, accesibilidad y reutilización del conocimiento recabado**: la salida del agente no queda confinada a notas de reunión privadas o dispersas, sino que se consolida en un conjunto de datos estructurados, directamente procesables por los métodos de toma de decisiones y auditables por el equipo humano.

Para materializar esta aproximación en un caso de uso real, la solución toma como base la metodología DTGEP [4] descrita anteriormente, adaptando sus etapas clave a un esquema de entrevistas asíncronas conducidas por agentes de IA para diagnosticar el estado de la organización y seleccionar los mejores proyectos de transformación digital. En concreto, el sistema implementa tres metodologías y métodos de toma de decisiones específicos que dan respuesta operativa a los subprocesos de DTGEP: la metodología **ALTUS** [15] para evaluar la madurez digital del conocimiento (DTGEP1), la metodología **SIPAC** [11] para identificar y caracterizar los activos intangibles de la empresa y proponer

soluciones tecnológicas (DTGEP2), y el método de toma de decisiones multicriterio **AHP** (*Analytic Hierarchy Process*) [9] para priorizar matemáticamente dichos artefactos tecnológicos (DTGEP4). No obstante, la solución propuesta cuenta con una arquitectura concebida con total genericidad: el motor agéntico de educción conversacional no queda acoplado a estas metodologías concretas, permitiendo que cualquier otro marco o proceso que requiera una fase de recolección cualitativa estructurada pueda incorporarse sin alterar el núcleo del sistema, adaptando así la metodología a distintos contextos organizativos y dominios de decisión.

1.2. Objetivos

Objetivo General: Formalizar, instanciar y evaluar empíricamente una metodología para la integración de agentes generativos en la toma de decisiones en la fase de preproyecto de transformación digital, que automatice la fase de elicitación del *Engineering Decision-Making Process* [7] preservando el rigor metodológico, la consistencia matemática y la viabilidad operativa.

Objetivos Específicos:

1. **Verificación de la calidad de recolección cualitativa:** Verificar que un agente conversacional autónomo puede recoger la información cualitativa y organizacional necesaria para los procesos de decisión con una calidad equivalente a la obtenida mediante entrevistas síncronas conducidas por un ingeniero.
2. **Validación de la integración de los procesos de decisión:** Validar que la información recabada de forma asíncrona por el agente es suficiente para alimentar y producir resultados coherentes en los procesos de evaluación de madurez (ALTUS) [15], caracterización de intangibles (SIPAC) [11] y priorización multicriterio (AHP) [9].
3. **Transparencia y auditabilidad asíncrona:** Demostrar que el modelo asíncrono garantiza una información transparente, auditable y reutilizable tanto por el ingeniero como por los algoritmos de decisión, sin depender de la presencia de ningún actor específico en un momento concreto.
4. **Flexibilidad y extensibilidad arquitectónica:** Confirmar que la arquitectura propuesta es suficientemente flexible para incorporar nuevos procesos de análisis cualitativo y toma de decisiones más allá de los implementados, validando su aplicabilidad a distintos contextos organizativos y dominios de decisión.

1.3. Estructura del documento

El presente documento se estructura de la siguiente forma:

- **Capítulo 1: Introducción.** Motivación bajo el prisma de la Economía de la Ingeniería de Software, propuesta agéntica, y objetivos.
- **Capítulo 2: Estado del arte.** Revisión de la teoría de decisiones de SWEBOK, metodologías como SIPAC y AHP, y el uso de grafos de IA.
- **Capítulo 3: Metodología, Arquitectura y Desarrollo de la solución.** Diseño abstracto, modelo de datos y ciclo de vida de la entrevista en LangGraph.
- **Capítulo 4: Evaluación.** Verificación de las capacidades del sistema.

- **Capítulo 5: Conclusiones y Trabajo futuro.** Reflexiones finales sobre la aportación al campo y líneas de mejora.

CAPÍTULO 2

ESTADO DEL ARTE

En este capítulo se realiza un análisis del estado del arte en relación con el proceso de toma de decisiones en ingeniería de software, las metodologías existentes para la evaluación organizativa y cómo la Inteligencia Artificial se posiciona para resolver los cuellos de botella actuales en estas disciplinas.

2.1. El Marco de Decisión y la Necesidad de Información

El área de conocimiento de *Software Engineering Economics* (recogida en el SWEBOK [7]) se fundamenta en la premisa de que esta disciplina es la «ciencia de la elección», orientada a guiar la toma de decisiones en un contexto de negocio. Para articular este proceso, el SWEBOK formaliza el *Engineering Decision-Making Process*, un ciclo compuesto por pasos secuenciales como: entender el problema real, definir criterios de selección, identificar alternativas viables, evaluarlas y seleccionar la óptima.

Sin embargo, este marco es inherentemente abstracto. Define qué pasos seguir, pero no cómo ejecutarlos operativamente. Metodologías como DTGEP [4], diseñadas específicamente para esta fase de pre-proyecto, demuestran que la información crítica para planificar una transformación digital exitosa orbita en torno a tres ejes: los objetivos de negocio de la organización, sus activos de conocimiento (tangibles e intangibles) y la madurez con la que gestiona dichos activos.

Mientras que los activos tangibles pueden auditarse mediante herramientas automatizadas, la información sobre los activos intangibles y la madurez organizativa reside casi exclusivamente en la mente de los *stakeholders*. Extraer esta información constituye uno de los principales desafíos de la fase de pre-proyecto, dado que gran parte de este conocimiento tácito no está documentado y requiere de consultores o ingenieros que realicen entrevistas y análisis cualitativos para hacerlo explícito [8], [16].

2.2. Metodologías de Evaluación y Toma de Decisiones

Una vez que se asume la necesidad de recopilar esta información organizativa (tanto tangible como intangible), la industria y la academia han desarrollado diversas metodologías para estructurarla y utilizarla en la toma de decisiones. Aunque la información subyacente que consumen es similar, los enfoques difieren significativamente.

Para evaluar el estado general y la capacidad operativa de una organización, la industria y la academia recurren de forma habitual a los modelos de madurez. Por un lado, estándares consolidados como CMMI (*Capability Maturity Model Integration*) [17] evalúan la madurez de los procesos de desarrollo de software, mientras que marcos como ITIL [18] se orientan a la gestión de servicios de TI y COBIT [19] al gobierno de los sistemas de información. Por otro lado, en el ámbito empresarial existen múltiples Modelos de Madurez Digital (DMM) orientados a valorar el grado de adopción tecnológica en los procesos de negocio. En esta misma línea de evaluación organizativa se sitúa ALTUS, un modelo enfocado específicamente en la gobernanza del conocimiento que analiza 51 capacidades organizacionales distribuidas en cuatro niveles de madurez y siete niveles arquitectónicos [15], con el fin de diagnosticar qué capacidades internas están afianzadas antes de abordar iniciativas de cambio tecnológico [10].

Con el fin de modelar la actividad diaria de una organización y estructurar sus componentes, se emplean habitualmente marcos como *Business Process Management* (BPM) [20], *Value Stream Mapping* (VSM) [21] o esquemas de arquitectura empresarial como TOGAF [22], los cuales permiten representar flujos de trabajo e infraestructuras operativas. Como complemento a estos enfoques orientados a flujos lógicos y componentes visibles, se han desarrollado metodologías centradas en los elementos cualitativos e intangibles. Entre ellas se encuentra SIPAC (*Systemic Intangible Process Assets Characterization*) [11], una propuesta diseñada para descubrir y caracterizar activos de procesos —tales como la experiencia acumulada, las relaciones operativas o el conocimiento práctico de las herramientas— a partir de su evaluación en dimensiones de calidad e impacto [16]. Mediante esta caracterización, los activos se categorizan en distintos estados de salud (estables, en evolución, reemplazables o de advertencia) para analizar el soporte que la base intangible proporciona a los procesos de digitalización [8].

En la etapa final de selección de alternativas tecnológicas, la industria a menudo recurre a métricas financieras como el Retorno de Inversión (ROI) o el Análisis Coste-Beneficio. Sin embargo, estas métricas presentan limitaciones al intentar incorporar factores intangibles, riesgos organizativos o el alineamiento estratégico, por lo que la literatura científica aboga por el uso formal de métodos de Toma de Decisiones Multicriterio (MCDM). Entre los enfoques más consolidados se encuentran TOPSIS [23], centrado en la distancia a una solución ideal, y PROMETHEE [24], basado en relaciones de superación matemática, con aplicaciones documentadas en el campo de la ingeniería de software [25]. Entre ellos, el método AHP (*Analytic Hierarchy Process*) [9] presenta como característica diferenciadora la capacidad de estructurar problemas de decisión de forma jerárquica y derivar prioridades mediante comparaciones pareadas, lo que permite incorporar tanto criterios cualitativos

(ej. impacto cultural) como cuantitativos (ej. coste de licencia) en un mismo modelo, si bien cuenta con limitaciones conocidas y documentadas en la literatura [26].

Las tres familias de metodologías descritas en esta sección —evaluación de madurez, caracterización de activos intangibles y toma de decisiones multicriterio— cubren de forma complementaria las necesidades de la fase de pre-proyecto identificadas en la sección anterior. La literatura ha avanzado en su integración bajo marcos metodológicos unificados; en particular, la metodología DTGEP [4] orquesta estas aproximaciones de forma secuencial: integra la metodología ALTUS para evaluar la madurez del conocimiento organizativo, la metodología SIPAC para identificar y caracterizar los activos intangibles clave y formular artefactos tecnológicos, y el método de toma de decisiones multicriterio AHP para priorizar dichas alternativas. De este modo, DTGEP establece una metodología integral que cubre el ciclo completo de pre-proyecto, desde el diagnóstico inicial hasta la selección de la solución óptima.

2.3. La Inteligencia Artificial en la Fase de Pre-proyecto

El uso de Inteligencia Artificial para la gestión y modelado de intangibles organizativos cuenta con respaldo en la literatura reciente. Se han propuesto herramientas basadas en Procesamiento de Lenguaje Natural (NLP) y minería de procesos (método C4PM), orientadas a descubrir capital intelectual a partir de datos corporativos no estructurados preexistentes (repositorios de documentos, logs de sistemas) [14]. Asimismo, se han desarrollado modelos comparativos utilizando Dinámica de Sistemas y Modelado Basado en Agentes para simular el comportamiento dinámico de los activos intangibles de procesos [27], [28]. No obstante, estos enfoques comparten una limitación común: son predominantemente analíticos, dependen de datos estáticos ya existentes y se centran en la extracción documental *a posteriori*, sin abordar la recolección proactiva de información directamente de los *stakeholders*.

Los recientes avances en *Large Language Models* (LLMs) han generado un creciente interés por su aplicación en la ingeniería de software. Una revisión sistemática reciente que analiza 395 estudios primarios identifica más de 85 tareas de ingeniería de software en las que se han aplicado LLMs, abarcando desde la generación de código y la detección de defectos hasta la ingeniería de requisitos y la gestión de proyectos [29]. Sin embargo, el uso de agentes conversacionales para recopilar, mediante entrevista, el conocimiento tácito e intangible de una organización no figura entre las áreas exploradas en dicha revisión.

Un avance particularmente relevante para la automatización de tareas que requieren interacción con el entorno es el paradigma ReAct (*Reasoning and Acting*) [13], que permite a los LLMs intercalar trazas de razonamiento verbal con acciones concretas sobre herramientas externas. A diferencia de las aproximaciones puramente generativas, un agente ReAct puede planificar qué preguntar, evaluar la respuesta obtenida, decidir si necesita profundizar y adaptar su comportamiento en función del contexto conversacional. Este paradigma constituye la base tecnológica sobre la que se construyen los agentes autónomos conversacionales actuales.

La aplicación de agentes basados en LLMs para interactuar con *stakeholders* ha comenzado a explorarse recientemente. Por ejemplo, enfoques como LLMREI [30] demuestran que un agente conversacional autónomo puede conducir entrevistas de elicitación de requisitos técnicos alcanzando un rendimiento comparable al de entrevistadores humanos. En una línea similar, marcos multi-agente como MedNegotiator [31] utilizan la arquitectura ReAct para simular y mediar entre diferentes perfiles de *stakeholders* durante la negociación de requisitos, garantizando el cumplimiento de restricciones en dominios críticos.

Estos trabajos confirman que la tecnología de agentes conversacionales ha alcanzado madurez suficiente para conducir procesos de elicitación. Sin embargo, su aplicación se ha centrado exclusivamente en requisitos técnicos de sistemas software, sin abordar la recolección de información organizativa intangible (cultura, madurez de procesos, activos de la organización) que constituye el insumo de las metodologías de evaluación de la fase de pre-proyecto.

Ante la creciente accesibilidad de los LLMs, resulta pertinente plantear por qué no es suficiente consultar directamente a un modelo con una petición genérica del tipo *«genera un plan de transformación digital para una empresa con estas características»*. Como señalan Bender et al. [32], los LLMs operan manipulando forma lingüística sin acceso al significado subyacente, convirtiéndose en «loros estocásticos» que generan texto plausible pero no fundamentado. La literatura científica respalda esta cautela [29], identificando tres riesgos críticos para la toma de decisiones empresariales.

En primer lugar, las **alucinaciones y la naturaleza estocástica** de estas arquitecturas representan una amenaza directa: Ji et al. [33] demuestran que la alta fluidez lingüística de los LLMs suele enmascarar errores fácticos sustanciales, y que incrementar la escala de parámetros no elimina la generación de información fabricada e inconsistente. En segundo lugar, la **opacidad y condición de caja negra** de los modelos impide auditar su razonamiento real [34], advirtiéndose que las explicaciones auto-generadas (como las cadenas de pensamiento) responden frecuentemente a racionalizaciones *post-hoc* o respuestas complacientes (*sycophancy*) en lugar de a trazas lógicas formalmente verificables. Finalmente, los **sesgos latentes y la discriminación** documentados por Gallegos et al. [35] muestran cómo los modelos heredan y amplifican desviaciones presentes en sus datos de entrenamiento, lo que en el ámbito organizativo puede inducir recomendaciones tecnológicas descompensadas o sesgadas hacia ciertos perfiles o áreas de negocio.

En la fase de pre-proyecto, estas limitaciones inhabilitan su uso directo. Un LLM consultado de forma aislada no realiza una evaluación sistemática de la madurez organizativa, ni caracteriza formalmente los activos intangibles, ni prioriza las alternativas bajo modelos de decisión con rigor matemático. La salida de una consulta directa es un texto narrativo, opaco y genérico, no un conjunto de datos trazables estructurados para alimentar dichas metodologías. Además, la información organizativa específica del caso —que reside exclusivamente en la mente de los *stakeholders*— queda sin recoger.

La diferencia entre el uso directo de un LLM y el sistema propuesto en este trabajo es arquitectónica y metodológica. No se trata de delegar la decisión final al modelo (la caja negra), sino de integrarlo como motor conversacional dentro de un proceso de ingeniería

riguroso. De este modo, el agente se dedica a extraer y estructurar la información del *stakeholder*, mientras que la evaluación y priorización se delegan en los métodos formales pertinentes para cada dimensión organizativa, mitigando los sesgos del LLM, garantizando la trazabilidad de los datos y asegurando una toma de decisiones auditable. La Tabla 2.1 sintetiza estas diferencias metodológicas fundamentales.

Tabla 2.1

Comparativa entre la consulta directa a un LLM y una arquitectura agéntica integrada.

Característica	Consulta Directa a un LLM	Arquitectura Agéntica Integrada
Recolección de información	*Prompt* único de texto libre.	Entrevista adaptativa con el *stakeholder*.
Conocimiento de la organización	Solo lo incluido en el *prompt*.	Conocimiento tácito extraído sistemáticamente.
Fiabilidad del resultado	Baja — riesgo de alucinaciones y datos fabricados.	Alta — datos validados por esquemas estrictos.
Auditabilidad	Nula — razonamiento opaco e irrastreable.	Total — trazable paso a paso por el ingeniero.
Neutralidad	Limitada — sesgos heredados del entrenamiento.	Acotada — el LLM solo gestiona la conversación, no la decisión.

2.4. Síntesis de la Brecha Metodológica y Tecnológica

El análisis de la literatura revela una desconexión fundamental entre la ingeniería de software clásica y los avances recientes en Inteligencia Artificial, conformando una doble brecha en la fase de pre-proyecto.

Por un lado, **desde la perspectiva de la Ingeniería de Software**, se dispone de marcos teóricos robustos (como el SWEBOK) y metodologías formales de toma de decisiones para guiar la transformación digital. Sin embargo, el insumo que alimenta estas metodologías —la recolección de información organizativa intangible— depende de procesos cualitativos manuales. Este cuello de botella operativo hace que la fase inicial sea lenta, costosa y altamente dependiente de la disponibilidad de ingenieros expertos, disuadiendo su adopción sistemática en la industria.

Por otro lado, **desde la perspectiva de la Inteligencia Artificial**, aunque los agentes conversacionales han demostrado solvencia para interactuar con humanos y extraer requisitos técnicos, los modelos generativos por sí solos carecen de la fiabilidad, trazabilidad y estructuración matemática necesarias para soportar decisiones estratégicas a nivel empresarial.

La intersección de ambas limitaciones constituye el principal vacío en el estado del arte actual: la ausencia de soluciones tecnológicas que unan el rigor de los modelos formales de evaluación organizativa con la autonomía de la IA agéntica.

El presente trabajo se posiciona precisamente en este espacio. Al proponer una arquitectura que delega la recolección de conocimiento tácito a un agente conversacional y la toma de decisiones a algoritmos deterministas, se aspira a cerrar el ciclo metodológico. De este modo, se busca democratizar la fase de *Software Engineering Economics*, haciéndola viable, escalable y auditable para cualquier organización.

CAPÍTULO 3

SOLUCIÓN PROPUESTA

En este capítulo se presenta un marco de trabajo soportado por una solución software basada en el uso de agentes inteligentes, cuyo propósito es asistir y descargar de trabajo al ingeniero de software en la fase de pre-proyecto, facilitando la toma de decisiones tecnológicas conforme a los objetivos de la Sección *1.2. Objetivos*. Esta solución consiste en el diseño de una metodología que guíe la toma de decisiones durante el proceso de planificación de las transformaciones digitales en las organizaciones mediante Inteligencia Artificial Agéntica, y en el desarrollo de una herramienta software de soporte. De este modo, el sistema releva al ingeniero de la conducción directa de la entrevista, asumiendo de manera autónoma la recolección inicial de información para generar borradores preliminares auditables.

3.1. Descripción de la Metodología Propuesta: AI-Driven DTGEP

El punto de partida metodológico sobre el que se fundamenta la solución toma como base la metodología DTGEP (*Digital Transformation Governance Engineering Process*), concebida para identificar potenciales proyectos de transformación digital sostenibles y libres de deuda técnica, que sean necesarios desplegar en una organización como parte de su proceso de transformación digital. Para poder integrar la Inteligencia Artificial Agéntica de forma efectiva, la nueva solución no aborda DTGEP en su totalidad, sino que centra sus adaptaciones en modificar los subprocesos DTGEP1, DTGEP2 y DTGEP4 de la metodología DTGEP como se han resaltado en la Fig. 3.1. El cambio fundamental para estos pasos consiste en la transición hacia un modelo asíncrono, dividiendo los procesos tradicionales de evaluación en fases separadas de recolección conversacional de información y posterior procesamiento algorítmico. A esta evolución metodológica con inteligencia artificial se la denominará en adelante **AI-Driven DTGEP**.

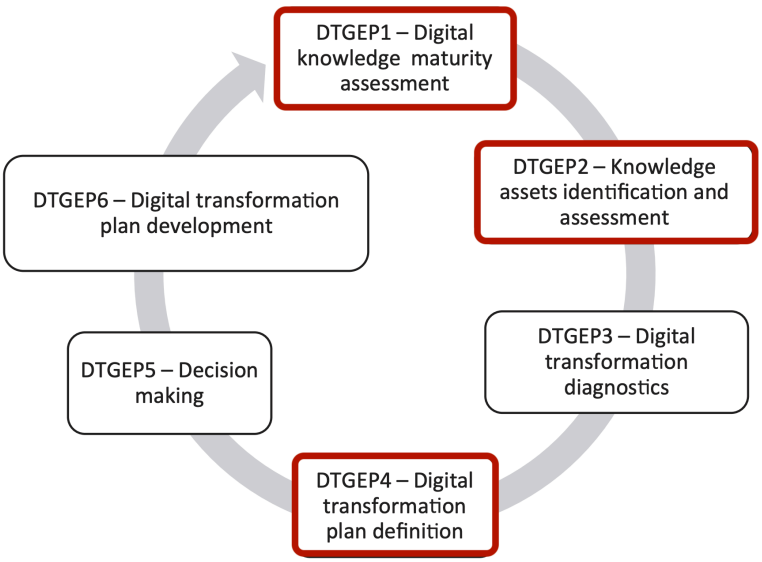


Fig. 3.1. Metodología DTGEP. Subprocesos resaltados indican adaptaciones para AI-Driven DTGEP.

La ejecución de estos tres subprocesos se lleva a cabo mediante la integración de metodologías y métodos de toma de decisiones específicos que conforman la base operativa de la solución propuesta:

En primer lugar, el subproceso **DTGEP1 (ALTUS)** se materializa mediante la metodología ALTUS [15] con el objetivo de medir y caracterizar la madurez digital actual de la empresa. Para ello, el agente recopila información directamente del *stakeholder* (entendido en este ámbito como cualquier actor con conocimiento relevante sobre la organización), produciendo un diagnóstico multidimensional utilizable tanto por la dirección para comprender su posición competitiva como por el equipo técnico como base de planificación.

En segundo lugar, el subproceso **DTGEP2 (SIPAC)** implementa la metodología SIPAC [11]. A partir de los procesos de negocio y las metas estratégicas de la organización, el sistema deduce y caracteriza los activos intangibles clave, formulando las especificaciones funcionales de los artefactos tecnológicos idóneos para impulsar la transformación digital; su salida estructurada constituye el insumo directo para la posterior priorización.

Finalmente, el subproceso **DTGEP4 (AHP)** integra el método de toma de decisiones multicriterio *Analytic Hierarchy Process* de Saaty [9] para ordenar y priorizar las alternativas tecnológicas deducidas en SIPAC. En este paso, el *stakeholder* define y calibra los criterios de decisión pertinentes (impacto, coste, viabilidad), y el motor algorítmico resuelve algebraicamente el vector de prioridades para determinar la hoja de ruta óptima de implantación.

En la Fig. 3.2 se muestra un diagrama que representa de forma global cómo estos 3 subprocesos indicados se relacionan tal y como se define en la metodología DTGEP.

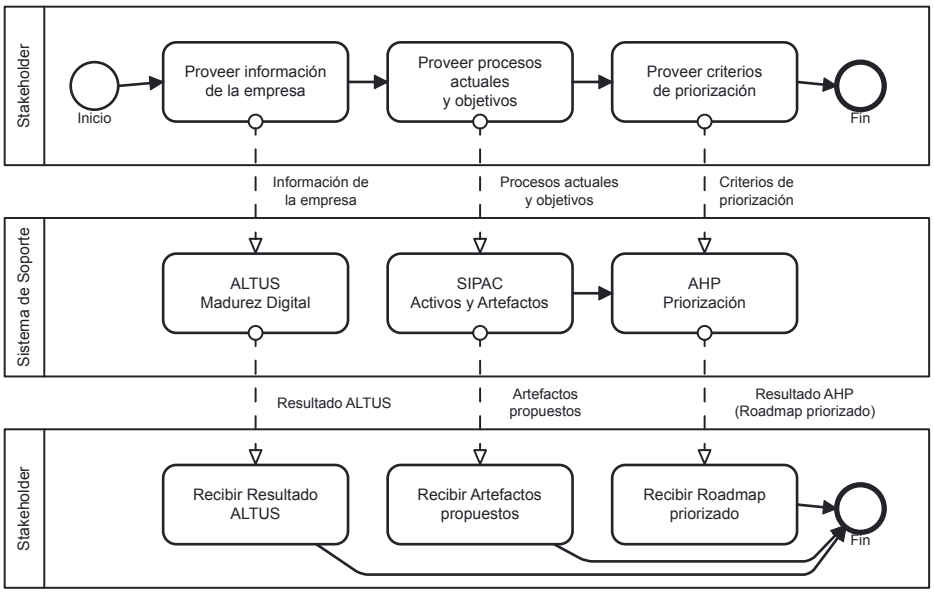


Fig. 3.2. Representación global de los procesos principales de la solución propuesta.[1]

Con los tres subprocesos DTGEP1, DTGEP2 y DTGEP4 ya caracterizados, el siguiente interrogante es cómo incorporar la Inteligencia Artificial Agéntica dentro de ellos sin alterar su esencia metodológica. En su concepción original, cada uno de estos subprocesos se ejecuta como un bloque unitario e indivisible: el ingeniero de software y el *stakeholder* coinciden simultáneamente, el primero formula las preguntas conforme avanza el análisis y va obteniendo de manera inmediata los resultados parciales del proceso. Esta dependencia de sincronía y experiencia humana convierte la fase de entrevista en el principal cuello de botella de la metodología. Para resolver esta limitación, se ha optado por estructurar cada proceso en dos fases que se ejecutan secuencialmente de forma automática: una fase de **recolección de información**, en la que el agente asume el rol del ingeniero para obtener la información organizativa que sólo puede ser provista por el **stakeholder**, y una fase de **procesamiento**, en la que esos datos se transforman algorítmicamente en un primer borrador de los resultados.

La fase de procesamiento es puramente algorítmica y, por tanto, directamente automatizable. El verdadero cuello de botella es la fase de recolección tanto para cada uno de las metodologías mencionadas (ALTUS, SIPAC y AHP): requiere la disponibilidad simultánea del ingeniero y del **stakeholder**, exige experiencia por parte del ingeniero para saber qué preguntar y cómo profundizar en las respuestas, y consume una cantidad de tiempo significativa que depende de la complejidad de la empresa analizada.

[1] **Notación — BPMN 2.0 (Business Process Model and Notation)**: Este y los siguientes diagramas de procesos siguen la notación BPMN 2.0. Los **pools** (grandes rectángulos con título en el lateral) delimitan el ámbito de cada participante del proceso (p. ej., *Stakeholder*, *Sistema*). Dentro de cada pool, los **eventos de inicio y fin** se representan con círculos (borde fino el de inicio, borde grueso el de fin). Los **nodos de tarea** son rectángulos de esquinas redondeadas. Las **líneas continuas con flecha** son flujos de secuencia dentro de un mismo pool; las **líneas discontinuas con círculo en el origen** son flujos de mensaje entre participantes distintos.

La solución propuesta consiste en relevar al ingeniero de software de su presencia en esta fase de recolección mediante **agentes de Inteligencia Artificial**. La alternativa más intuitiva podría ser involucrar a la IA como copiloto síncrono del **stakeholder** o del ingeniero durante la entrevista; sin embargo, esto no eliminaría el cuello de botella de la concurrencia temporal ni el consumo de horas del consultor. Por tanto, la decisión más eficiente es que la IA asuma de forma autónoma la labor de interrogación e indagación: formular las preguntas, gestionar el flujo de la conversación, resolver dudas metodológicas, detectar respuestas insuficientes y profundizar en ellas.

Esta delegación de la entrevista tiene una consecuencia arquitectónica importante: el proceso adopta un **modelo de ejecución automatizado End-to-End con auditoría asíncrona**. El **stakeholder** puede realizar la entrevista con el agente en cualquier momento y desde cualquier lugar. Una vez que la entrevista finaliza, el sistema encadena automáticamente la recolección con la fase de procesamiento, generando un **borrador preliminar** de forma inmediata. Esto proporciona valor instantáneo al usuario. Posteriormente, el ingeniero de software entra en el flujo de forma asíncrona para revisar este borrador diferido, auditar la calidad de las respuestas si detecta inconsistencias, y validarlo para emitir el plan definitivo. Cabe destacar que esta labor de auditoría se plantea conceptualmente dentro de la solución, pero no cuenta con una solución tecnológica específica o interfaz gráfica de usuario dedicada en el presente trabajo; el ingeniero de software realiza esta validación mediante la inspección manual directa de los ficheros JSON generados, quedando el desarrollo de una interfaz de auditoría fuera del alcance de este TFM.

Este modelo automatizado impone, a su vez, un requisito técnico fundamental: el resultado estructurado de la entrevista debe persistirse en ficheros estandarizados. Estos ficheros actúan como el contrato de datos que conecta ambas fases sin intervención humana, permitiendo que los algoritmos los consuman al instante y, al mismo tiempo, sirven de registro auditable para la revisión asíncrona por parte del ingeniero de software (Fig. 3.3).

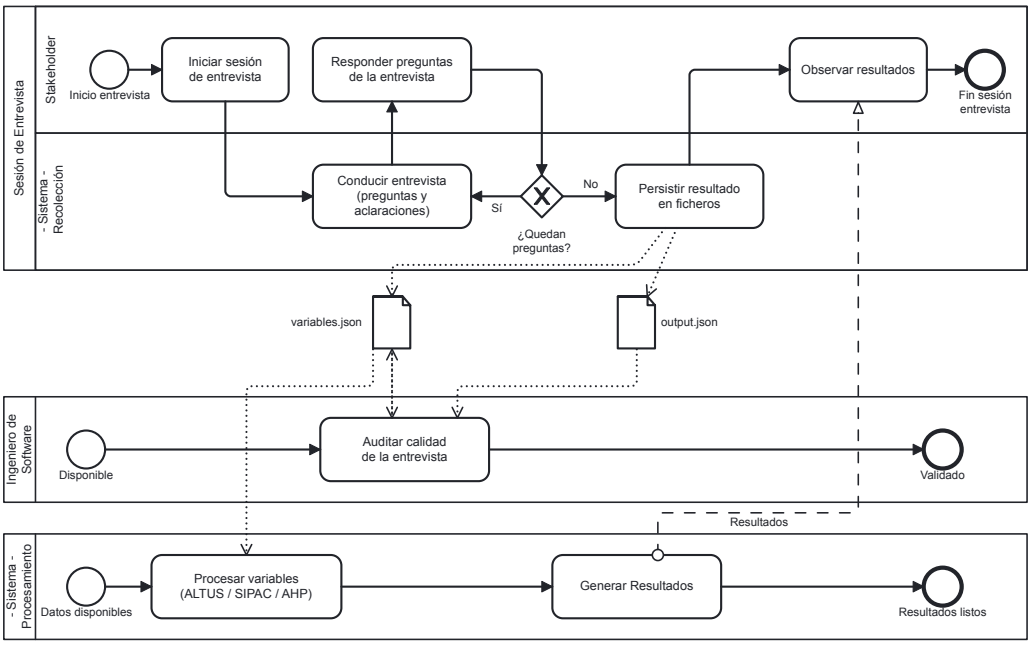


Fig. 3.3. Modelo de ejecución asíncrono y separación de fases.[1]

3.2. Arquitectura del Software: Motor Genérico e Instanciación de AI-Driven DTGEP

Para dar soporte operativo a la metodología AI-Driven DTGEP —y al mismo tiempo proporcionar un marco extensible a otros dominios de decisión—, la solución software se diseña bajo un principio de estricto desacoplamiento entre el **motor de educción agéntica genérico** y las **reglas de negocio específicas**.

Tomando como referencia el modelo asíncrono de la Fig. 3.3, la arquitectura se estructura en tres bloques principales: el **motor de educción agéntico** (Sección *3.2.1. Motor de Educción*), concebido como un componente genérico y agnóstico al dominio responsable de conducir la entrevista cualitativa mediante LangGraph y contratos JSON; la **fase de procesamiento algorítmico** (Sección *3.2.2. Fase de Procesamiento Algorítmico*), integrada por módulos matemáticos deterministas que ejecutan la lógica de negocio de las metodologías instanciadas (ALTUS, SIPAC y AHP); y la **aplicación web unificada** (Sección *3.2.3. Arquitectura Web del Sistema*), desarrollada en Next.js 16 para orquestar la interacción, el streaming en tiempo real y la trazabilidad de las sesiones.

3.2.1. Motor de Educción

Establecido el modelo de ejecución en la Fig. 3.3, el componente central de la solución es el **motor de educción de información**: un framework agéntico autónomo capaz de conducir entrevistas cualitativas complejas emulando el comportamiento de un ingeniero de software.

Arquitectónicamente, este motor opera como un intérprete declarativo: no contiene lógica cableada de ninguna metodología en particular, sino que interpreta estructuras abstractas de tareas, acciones y esquemas de validación. En el contexto de este trabajo,

dicho motor se parametriza mediante ficheros de configuración específicos para materializar operativamente la recolección de datos de ALTUS, SIPAC y AHP dentro de AI-Driven DTGEP. La figura Fig. 3.4 ubica este motor dentro de la arquitectura global, mostrando cómo interactúa con el **stakeholder** y sus salidas.

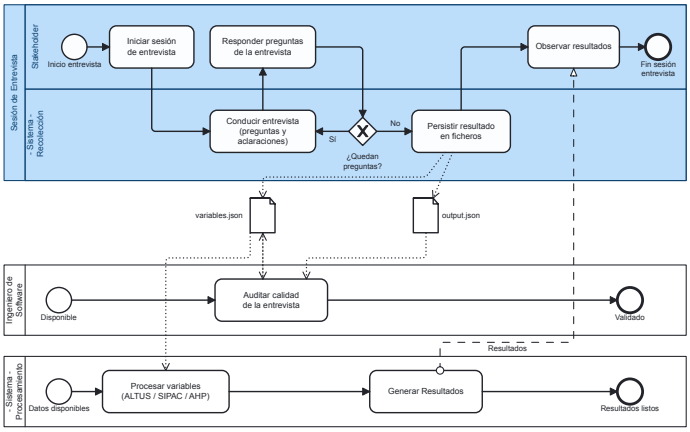


Fig. 3.4. Ubicación del motor de educción dentro de la arquitectura global.[1]

La tecnología seleccionada para implementar este motor es **LangGraph**, una librería que permite construir grafos de ejecución (máquinas de estados) donde cada nodo representa una acción o decisión, y las aristas determinan el flujo de control en función del resultado de cada nodo. Los Modelos de Lenguaje Grandes (LLMs) actúan como el motor de razonamiento de cada nodo que requiera comprensión del lenguaje, clasificación de intenciones o síntesis de información. La elección de LangGraph frente a otras alternativas de IA agéntica se debe a su capacidad para definir flujos de control explícitos y deterministas, lo que resulta esencial en un sistema de entrevista donde el orden y la completitud de la información recogida son críticos y donde los comportamientos erráticos o impredecibles podrían comprometer la calidad del output.

Para que el motor de educción pueda relevar de forma efectiva al ingeniero en la conducción de la entrevista, debe cubrir un conjunto específico de capacidades que emulen el comportamiento de un consultor humano durante la recolección de información:

En primer lugar, la **formulación de preguntas y aclaración de dudas**: el ingeniero no solo interroga, sino que atiende y resuelve las dudas del **stakeholder** sobre los conceptos de la metodología. El motor detecta de forma autónoma cuándo el interlocutor plantea una duda, la solventa consultando la base de conocimiento y reformula la pregunta incorporando la aclaración.

En segundo lugar, el **flujo dinámico de preguntas**: un consultor experimentado no sigue un guión estático. Ante respuestas escuetas o incompletas, el motor evalúa la suficiencia de la información recabada y despliega preguntas de seguimiento contextualizadas (*follow-ups*) para profundizar antes de dar por cerrada la acción.

En tercer lugar, la **memoria conversacional**: en sesiones extensas, el motor mantiene un estado jerárquico de resúmenes que le permite recordar información previa y eludir

preguntas redundantes cuando la respuesta ya ha sido proporcionada de forma implícita en turnos anteriores.

Asimismo, incorpora **razonamiento autónomo**: ciertas variables no se obtienen directamente del usuario, sino que se deducen a partir del contexto ya recopilado aplicando conocimiento de dominio mediante llamadas internas al LLM sin interacción directa con el interlocutor.

Finalmente, la **configurabilidad**: el motor opera de forma completamente desacoplada de la lógica de negocio, definiéndose su comportamiento íntegramente mediante un contrato de configuración externo (ficheros JSON), lo que permite instanciar indistintamente procesos como ALTUS, SIPAC o AHP sobre el mismo núcleo agéntico. Esta aproximación puramente declarativa e interpretada mediante LLMs aporta la **máxima flexibilidad y adaptabilidad**: permite incorporar nuevas metodologías o modificar cuestionarios al vuelo sin necesidad de recopilar datasets de entrenamiento ni reajustar pesos de modelos (**Zero-Shot In-Context Learning**). Aunque este diseño traslada las decisiones internas de transición al tiempo de inferencia del LLM (asumiendo un mayor coste temporal que en un proceso asíncrono desatendido es perfectamente asumible), prioriza el desacoplamiento y la genericidad sobre la rigidez de clasificadores cableados.

Genericidad del motor: cualquier proceso de recolección de información que pueda expresarse mediante tareas y acciones puede ejecutarse sobre este motor sin modificar una sola línea de su código. Un nuevo proceso de auditoría —de cualquier dominio— únicamente necesita respetar el contrato de configuración para beneficiarse de todas las capacidades del motor: flujo dinámico, memoria conversacional, razonamiento autónomo, validación estructurada y persistencia asíncrona.

Todas estas características conforman el motor de educción y se formalizan mediante el diagrama de casos de uso expuesto en la Fig. 3.5.

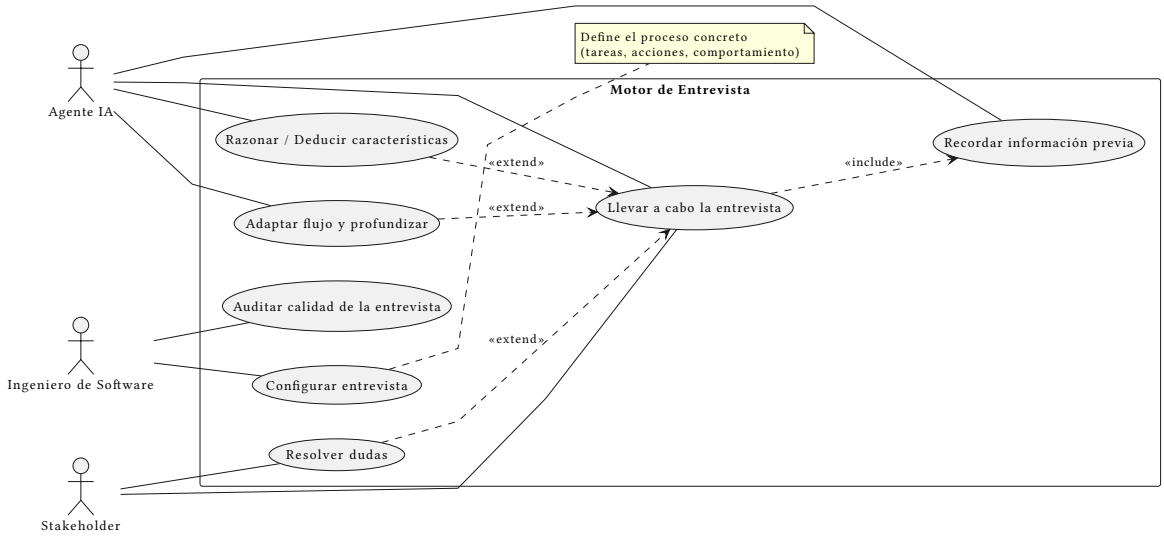


Fig. 3.5. Casos de uso principales del motor de educción.[2]

Flujo de una Sesión de Entrevista

Con las capacidades del motor ya definidas en la Sección *3.2.1. Motor de Educción*, esta sección describe cómo se articula una sesión de educción de información completa desde el punto de vista del usuario y del sistema. El flujo no es lineal sino iterativo, ya que cada pregunta puede dar lugar a varios ciclos de aclaración y evaluación antes de avanzar a la siguiente.

Para poder describir este flujo es necesario introducir dos conceptos clave que estructuran la configuración del motor: las **tareas** y las **acciones**. Una **tarea** representa un bloque temático de la sesión, es decir, un conjunto de preguntas o razonamientos relacionados con un mismo objetivo (por ejemplo, recoger información sobre los procesos internos de la empresa, o sobre sus objetivos estratégicos). Dentro de cada tarea, las **acciones** son las unidades mínimas de trabajo: cada acción es o bien una pregunta que el agente formula al *stakeholder*, o bien un razonamiento interno que el sistema ejecuta de forma autónoma sin interacción con el usuario. Esta distinción es lo que permite configurar el motor de forma diferente para cada proceso (ALTUS, SIPAC, AHP), simplemente variando qué tareas hay y qué acciones contiene cada una.

Al inicio de la sesión, el sistema carga la configuración del proceso correspondiente, que especifica precisamente esta lista de tareas y su secuencia de acciones. No se trata de motores distintos para cada proceso, sino del mismo motor configurado de forma diferente.

Para cada acción de la configuración, el sistema distingue tres modalidades operativas de comportamiento:

[2] **Notación — UML de Casos de Uso**: Este diagrama describe las interacciones funcionales entre actores y el sistema. Los **actores** (figuras de persona) representan entidades externas que interactúan con el sistema. Los **óvalos** representan casos de uso (funcionalidades). Las **líneas continuas** entre un actor y un caso de uso indican que el actor participa en esa funcionalidad. Las **flechas discontinuas** con etiqueta «`include`» indican que un caso de uso incorpora obligatoriamente el comportamiento de otro; las etiquetadas con «`extend`» representan una extensión opcional. El **rectángulo exterior** delimita la frontera del sistema.

Si la acción es de tipo **pregunta**, el agente la presenta al **stakeholder** y abre un sub--flujo interactivo: si el interlocutor plantea una duda, el agente la resuelve y reformula la pregunta; si responde, el sistema evalúa la suficiencia de la respuesta antes de avanzar. En caso de detectar lagunas, emite repreguntas contextualizadas (*follow-ups*). Para evitar la fatiga del usuario y prevenir bucles indefinidos, el motor incorpora **guardas deterministas de parada** que acotan las aclaraciones a un máximo de dos intentos y las repreguntas a tres turnos por acción, consolidando la mejor evidencia disponible si se alcanza dicho límite.

Si la acción es **interna**, el sistema ejecuta un razonamiento autónomo mediante LLM sin interacción directa con el usuario, persistiendo la deducción en el estado global para su consumo por acciones posteriores.

Finalmente, si la acción es de tipo **bucle** (`loop_validation`), opera como un generador dinámico que toma una plantilla y la expande sobre colecciones de elementos descubiertos en tiempo de ejecución (por ejemplo, instanciando preguntas específicas para cada uno de los sistemas informáticos identificados en fases previas), dotando a la entrevista de la flexibilidad necesaria para tratar conjuntos de datos dinámicos.

Una vez que todas las acciones de una tarea se han completado, el sistema genera un resumen de la tarea que queda disponible como contexto para las tareas siguientes. Esta memoria de medio plazo opera en dos sentidos: por un lado, se inyecta como contexto en el prompt de acciones posteriores; por otro, antes de formular cada nueva pregunta al *stakeholder*, el sistema la contrasta con los resúmenes acumulados para determinar si la respuesta ya fue proporcionada implícitamente en una tarea anterior. Si es así, la pregunta se omite y la respuesta extraída de los resúmenes se registra directamente como resultado de la acción, evitando así cualquier redundancia en la entrevista. Cuando todas las tareas han sido procesadas, la sesión concluye y el resultado se persiste en disco, completando así el flujo detallado en la Fig. 3.6.

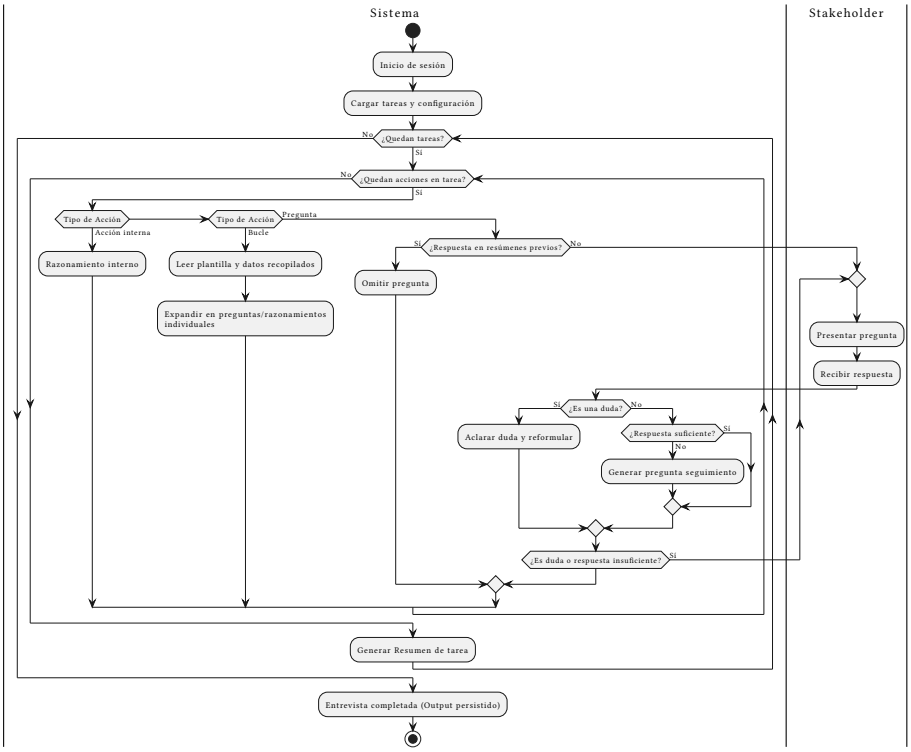


Fig. 3.6. Flujo funcional de una sesión de entrevista.[3]

Diseño de Datos (Configuración, Estado y Salida)

Con el flujo funcional ya descrito, esta sección detalla la estructura de los datos que configuran y sostienen el sistema. No describe comportamiento en tiempo de ejecución, sino las entidades estáticas que lo hacen posible: cómo se configura el motor, cómo representa su estado interno durante la sesión, y qué produce como resultado.

Para tener una visión clara de las entidades y sus relaciones, la Fig. 3.7 ilustra el modelo de datos principal. En el diagrama destacan tres pilares: `GraphProfile` como contenedor de la configuración global, las entidades `Task` y `Action` que formalizan los conceptos de tarea y acción introducidos en la Sección *«Flujo de una Sesión de Entrevista»*, y el `GraphState` que mantiene la memoria activa de la ejecución vinculando la configuración con las colas de trabajo.

La configuración de una entrevista se especifica en un único fichero JSON que contiene dos partes principales. La primera parte es el **perfil del grafo** (`GraphProfile`), que controla el comportamiento global del motor: qué capacidades están activas (evaluación de respuestas, aclaración de dudas, generación de resúmenes), los prompts de sistema para razonamientos internos y la definición de los **hooks** (`GraphHook`). Un **hook** es un mecanismo opcional que permite ejecutar un post-procesamiento automático mediante LLM al alcanzar momentos

[3] **Notación — UML de Actividad**: Este diagrama modela el flujo de control de un proceso paso a paso. El **círculo negro** es el nodo inicial; el **círculo negro con borde** es el nodo final. Los **rectángulos de esquinas redondeadas** representan actividades o acciones. Los **rombos** son nodos de decisión: cada arista saliente lleva una condición que indica cuándo se toma ese camino. Las **flechas continuas** conectan los elementos en el orden de ejecución.

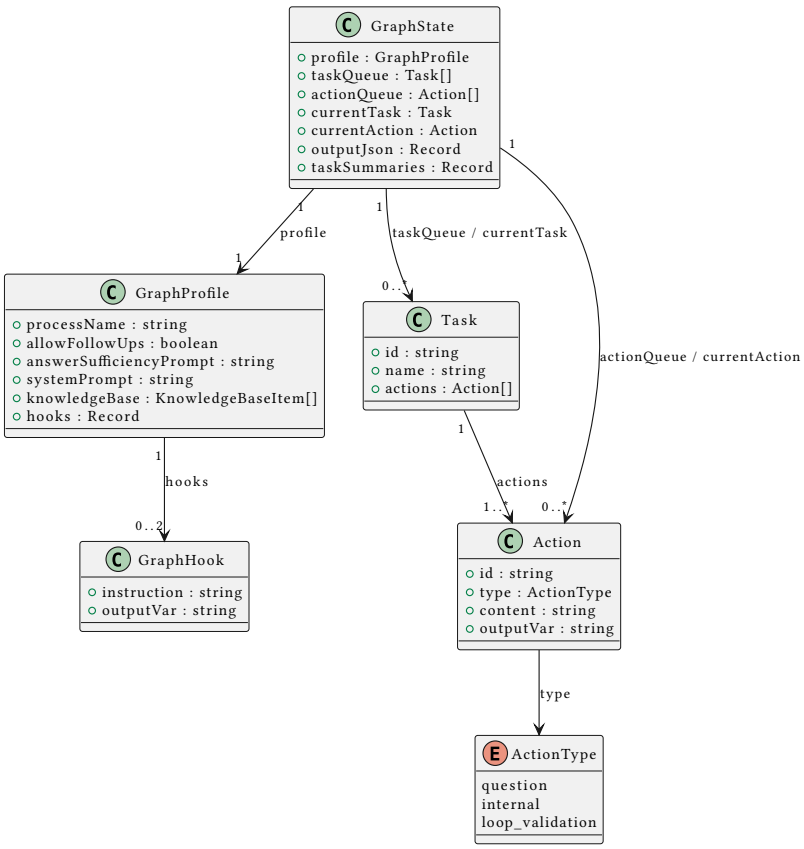


Fig. 3.7. Modelo de datos principal: configuración, tareas y estado.[4]

clave de la sesión: tras validar la respuesta de una acción (`afterActionAnswer`) o al completar una tarea (`afterTask`). Por ejemplo, en el proceso ALTUS, el hook `afterActionAnswer` se utiliza para evaluar automáticamente la madurez digital de la capacidad recién respondida (en una escala de 0 a 5) y generar su justificación sin alterar la lógica del motor genérico ni introducir acciones adicionales tras cada pregunta. La segunda parte es la lista de **tareas** (`Task[]`), cada una con su conjunto de acciones (`Action[]`). Esta separación entre perfil, hooks y tareas permite reutilizar el mismo perfil de comportamiento para distintos conjuntos de preguntas, y viceversa.

Este fichero JSON constituye la **interfaz pública del motor**: es el único punto de contacto entre el motor genérico y cualquier proceso concreto. Quien desee incorporar un nuevo proceso al sistema no necesita conocer ni modificar el código del motor; basta con definir un fichero de configuración que respete este contrato. Un ejemplo de este formato puede apreciarse en la Listado 3.1 para el perfil y en la Listado 3.2 para las tareas.

[4] **Notación — UML de Clases**: Este diagrama describe la estructura estática de los datos del sistema. Cada **rectángulo** representa una clase o tipo de datos, dividido en secciones de nombre y atributos (con su tipo). Las **flechas con punta rellena** indican una relación de asociación direccional entre clases. Los números en los extremos de las líneas indican multiplicidad (p. ej., `1` a `*` significa «uno a muchos»).

```
{
  "profile": {
    "processName": "SIPAC",
    "allowFollowUps": false,
    "allowDoubtConfirmation": false,
    "allowKnowledgeConsultation": true,
    "generateTaskSummaries": true,
    "saveTaskSummariesToOutput": true,
    "systemPrompt": "You are a strategic consultant expert in the SIPAC methodology.\nYour
goal is to perform internal reasoning to help value intangible assets.\n\nCRITICAL RULE:
Return ONLY a valid JSON object or array as requested. No conversational text.",
    "knowledgeBase": [
      {
        "name": "GIA Catalog",
        "path": "../knowledge_base/catalogo_gia.md"
      },
      {
        "name": "GIA to Intellectual Capital Mapping",
    // ...
  }
}
```

Listado 3.1: Fragmento de configuración de entrada (Perfil).

```
{
  // ...
  "tasks": [
    {
      "id": "SIPAC_FULL_COMPLIANCE",
      "name": "SIPAC Process - SIPAC_FULL_COMPLIANCE",
      "actions": [
        {
          "id": "STEP_0_EMPRESA",
          "type": "question",
          "content": "Para contextualizar la valoración estratégica, ¿cuál es el nombre,
descripción y misión principal de tu empresa?",
          "outputVar": "datos_empresa"
        },
        // ...
      ]
    }
  ]
}
```

Listado 3.2: Fragmento de configuración de entrada (Tareas).

Durante la ejecución, el grafo mantiene un estado global (`GraphState`) que actúa como memoria de trabajo de la sesión. Este estado contiene las colas de tareas y acciones pendientes, la tarea y acción actuales, el almacén de resultados compartido (`outputJson`), el historial de resúmenes de tarea, y un indicador de finalización. Es importante destacar que este estado es **efímero**: existe únicamente durante la ejecución de la sesión y no forma parte del output

final. Su propósito es únicamente permitir que el grafo tome decisiones informadas en cada momento.

De forma continua durante la ejecución —tras cada acción o tarea completada, y no únicamente al finalizar la sesión—, el sistema divide y vuelca el contenido del estado en dos ficheros de salida complementarios, tal y como se ilustra en la Fig. 3.8. Esta separación arquitectónica responde a que sirven a consumidores distintos con requerimientos desacoplados:

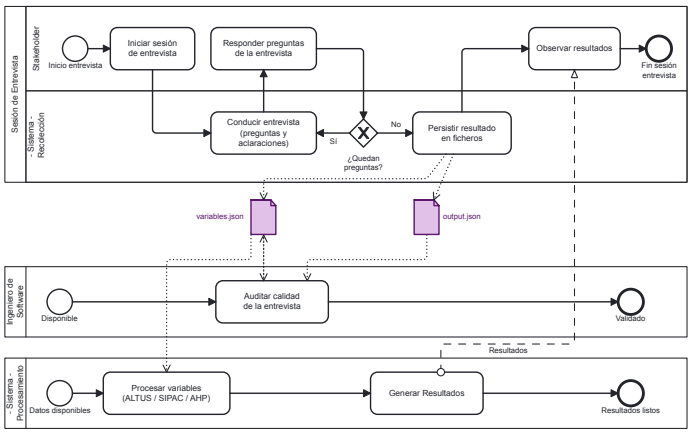


Fig. 3.8. Ubicación de los ficheros de salida dentro de la arquitectura global.[1]

Por un lado, el **fichero de registros de conversación** (`output_<process>_<timestamp>.json`) contiene el transcript completo de la entrevista organizado por tareas y acciones, orientado a la revisión humana durante la auditoría asíncrona del ingeniero de software si se precisa contrastar la calidad de las intervenciones.

Por otro lado, el **fichero de variables estructuradas** (`variables_<process>_<timestamp>.json`) contiene exclusivamente las variables que las acciones persisten explícitamente mediante el campo `outputVar`. Para que los algoritmos deterministas de ALTUS, SIPAC y AHP puedan consumir estos datos sin ambigüedad, la salida se valida obligatoriamente contra un **esquema JSON** estricto, asegurando un contrato de datos tipado que alimenta directamente a los módulos matemáticos.

Finalmente, el flujo completo de información y la relación global entre configuración, estado interno y estos ficheros de salida queda expuesta de forma gráfica en la Fig. 3.9.

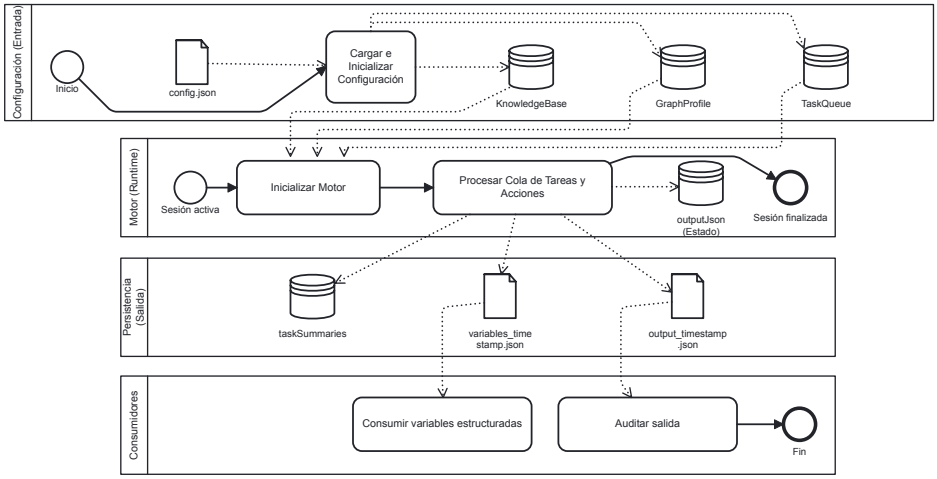


Fig. 3.9. Estructura de datos: configuración, estado de ejecución y salida.[1]

Arquitectura del Grafo

Esta sección describe cómo se organiza el grafo de ejecución, detallando los nodos, las aristas y las colas que implementan el flujo iterativo y el diseño de datos expuestos en la Sección *«Flujo de una Sesión de Entrevista»* y la Sección *«Diseño de Datos (Configuración, Estado y Salida)»*.

Para lograr un comportamiento dinámico y **agnóstico al proceso concreto que se ejecute**, el motor no predefine el camino de la entrevista en la estructura del grafo, sino que se apoya en un sistema de doble cola: una cola para las tareas (`taskQueue`) y una cola para las acciones (`actionQueue`), conceptos y entidades que fueron introducidos en la Sección *«Flujo de una Sesión de Entrevista»* y modelados en la Sección *«Diseño de Datos (Configuración, Estado y Salida)»*. Al inicio de la sesión, se cargan todas las tareas configuradas en la cola principal. El nodo inicial extrae la primera tarea y vuelca todas sus acciones en la cola secundaria.

A partir de ahí, el sistema se fundamenta en un ciclo principal de procesamiento continuo gobernado por la máquina de estados. El motor extrae la primera acción de la cola de acciones y la deriva hacia dos caminos principales en función de su naturaleza: por un lado, el **camino de pregunta**, que presenta la interacción al usuario, gestiona dudas mediante consultas a la base de conocimiento y evalúa la suficiencia de la respuesta antes de avanzar; por otro lado, el **camino interno**, que ejecuta razonamientos autónomos y síntesis deductivas sin interacción del usuario.

Este diseño estructurado en un doble camino y gobernado por evaluaciones previas a cada interacción materializa de forma práctica el paradigma **ReAct** (*Reasoning and Acting*) introducido en el Estado del Arte (Capítulo *2. Estado del Arte*). En lugar de usar el modelo de lenguaje como un mero generador estocástico, la arquitectura orquesta un ciclo donde el agente primero razona sobre el estado actual (clasificando intenciones o evaluando la suficiencia de los datos) y, en función de ese razonamiento, actúa sobre su entorno (haciendo una pregunta de seguimiento, resolviendo dudas o avanzando en el proceso).

Dentro de estos caminos, cuando una acción tiene definido un esquema JSON para su `outputVar` (tal y como se detalló en la Sección *«Diseño de Datos (Configuración, Estado y Salida)»*), el grafo incorpora un sub-bucle de validación estructurada. Tras invocar al LLM para extraer el contenido, un nodo validador comprueba si el JSON devuelto encaja estrictamente en el esquema esperado. Si la validación falla, el grafo traza una arista de retroceso hacia el LLM, inyectando el error de formato en el prompt para que el modelo corrija su respuesta. Este bucle garantiza solidez en el formato antes de avanzar.

Para las acciones de tipo bucle (`loop_validation`), cuya necesidad funcional se introdujo en la Sección *«Flujo de una Sesión de Entrevista»*, el grafo delega la ejecución en un proceso de desenrollado: lee una colección de elementos del estado, genera de forma dinámica las acciones derivadas para cada elemento y las añade a la cabeza de la cola de procesamiento.

Ambos caminos principales convergen en un proceso de consolidación o cierre de acción, donde se genera un resumen de la iteración y se guarda el estado en disco de forma incremental. Si la cola de acciones aún tiene elementos, el grafo vuelve a extraer la siguiente acción. Al vaciarse la cola de acciones, el sistema ejecuta el cierre de tarea, generando un resumen global de todo el bloque, y extrae la siguiente tarea de la cola principal para reiniciar el ciclo. El proceso completo termina cuando ambas colas quedan vacías.

Para facilitar la asimilación visual de todas estas transiciones y observar en detalle la complejidad de las interacciones, el esquema de estados completo que configura el motor **LangGraph** se detalla en la Fig. 3.10.

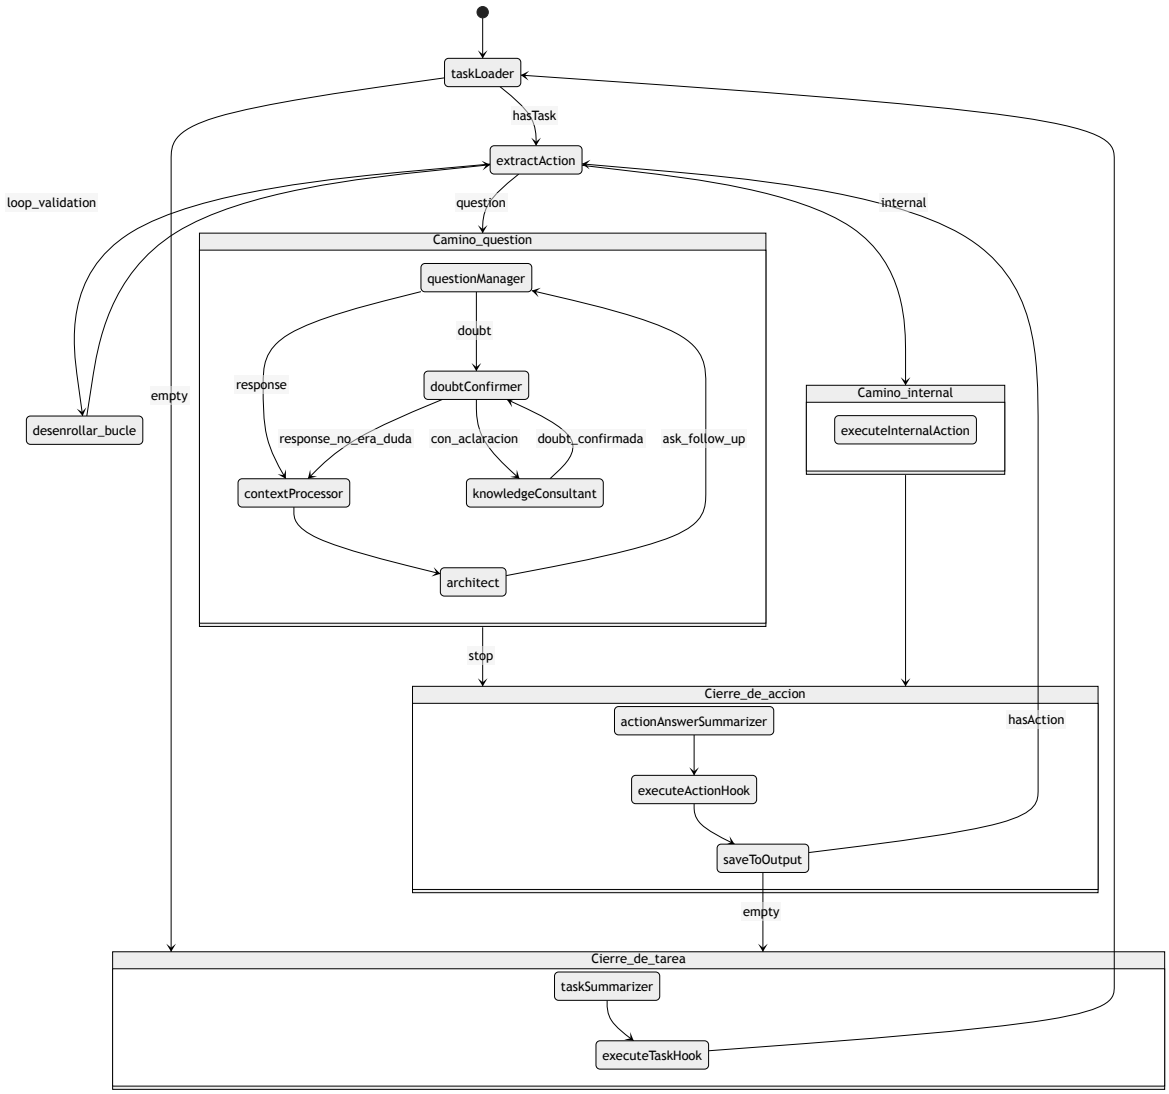


Fig. 3.10. Arquitectura de estados y transiciones del motor de educción.[5]

Gestión de Memoria y Estado

La capacidad de **memoria conversacional** descrita en la Sección *3.2.1. Motor de Educción* se implementa mediante un sistema de dos planos complementarios, tal y como se anticipó en el flujo de sesión de la Sección *«Flujo de una Sesión de Entrevista»*.

A corto plazo, dentro de una misma tarea, el sistema inyecta en el prompt únicamente los **resúmenes** de las acciones anteriores a modo de contexto inmediato; las respuestas completas se almacenan en el estado exclusivamente para la auditoría humana posterior y no se envían al modelo, lo que mantiene el coste de tokens acotado. A medio plazo, al

[5] **Notación — Grafo de Estados**: Este diagrama representa la máquina de estados que implementa el motor de educción. Cada **nodo** (rectángulo) es un estado del sistema, es decir, una operación concreta que el motor puede ejecutar. Las **aristas con línea continua** son transiciones incondicionales que se activan siempre al terminar un nodo. Las **aristas con línea discontinua** son transiciones condicionales que solo se activan cuando se cumple la condición indicada en su etiqueta. Los nodos con el mismo color de fondo pertenecen a la misma fase del flujo.

concluir cada tarea, el sistema sintetiza todos sus intercambios en un resumen global que quedará disponible como contexto para las tareas siguientes.

Este doble repositorio de resúmenes es lo que permite al gestor de la entrevista eludir preguntas redundantes: antes de formular cualquier pregunta, consulta el conocimiento acumulado y, si el modelo determina que la respuesta ya está implícita, la acción se cierra directamente sin interacción con el stakeholder. Esto materializa la capacidad enunciada en la Sección *3.2.1. Motor de Educción* de evitar que el motor repita información ya proporcionada. La Fig. 3.11 ilustra este mecanismo dual mediante una vista detallada (zoom del sistema) enfocada en el ciclo de vida de la memoria y el estado del motor.

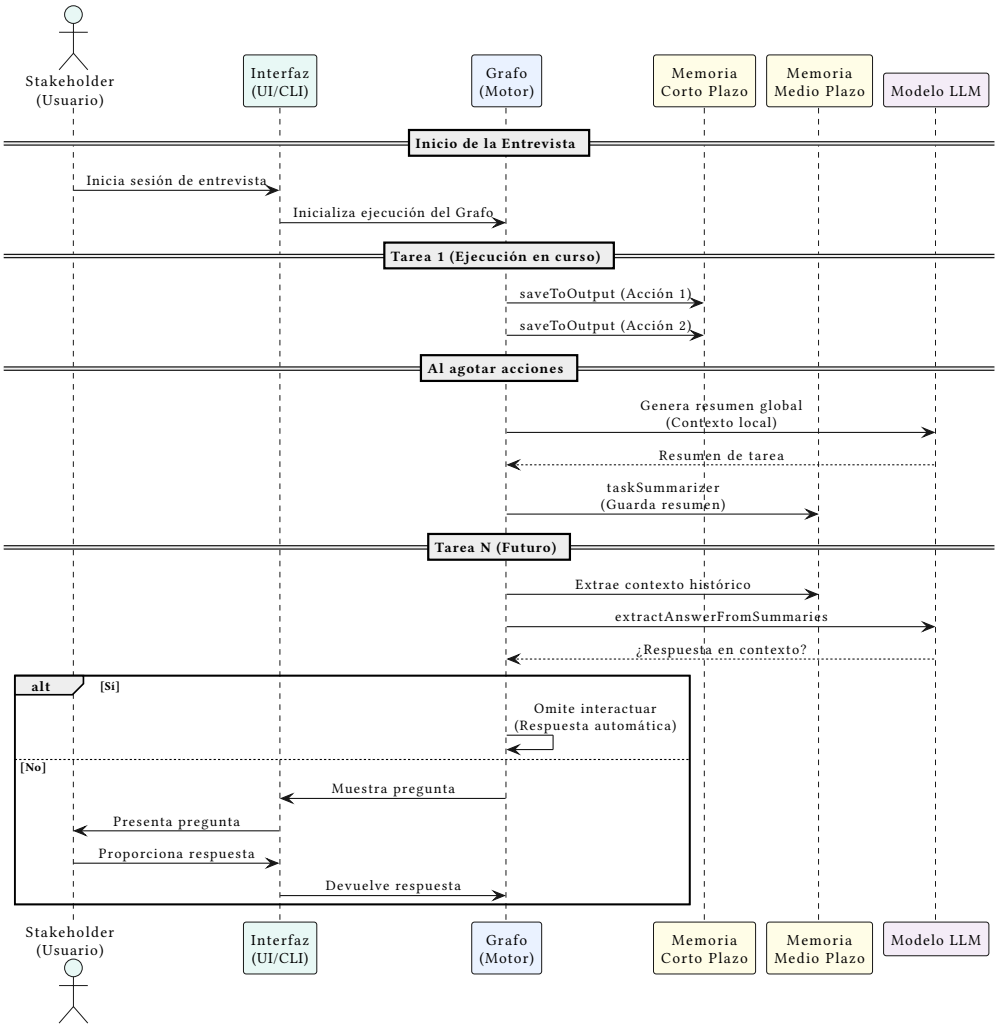


Fig. 3.11. Detalle de ejecución (zoom del sistema) del flujo de gestión de memoria y estado para la prevención de preguntas redundantes.[6]

[6] **Notación — UML de Secuencia**: Este diagrama representa el comportamiento dinámico del sistema, detallando cómo interactúan los componentes con las capas de memoria y estado a lo largo del tiempo. Los **rectángulos** en la parte superior representan los módulos o subsistemas participantes. Las **líneas verticales discontinuas** son las líneas de vida de cada participante. Las **flechas horizontales con punta rellena** representan mensajes enviados de un participante a otro; las **flechas con punta abierta sobre línea discontinua horizontal** representan el retorno de la respuesta. El tiempo avanza de arriba hacia abajo.

Capa de Abstracción LLM

El grafo de nodos descrito en la Sección *«Arquitectura del Grafo»* contiene la lógica de enrutamiento y las reglas de negocio, pero ningún nodo llama directamente a la API del modelo de lenguaje. Toda interacción se delega en una capa de abstracción unificada, ocultando los detalles de construcción de prompts, validación de esquemas y gestión de reintentos.

Esta separación es lo que hace posibles, de forma fiable, las capacidades descritas en la Sección *3.2.1. Motor de Educción*: la detección de dudas, la evaluación de suficiencia de respuestas, los follow-ups contextualizados o el razonamiento autónomo no son decisiones tomadas directamente por los nodos, sino el resultado de invocar funciones especializadas que garantizan una salida con tipo y estructura conocidos. Como se muestra en la Fig. 3.12, estas funciones se agrupan en operaciones de clasificación/evaluación y operaciones de síntesis/razonamiento, y todas siguen un **pipeline** interno idéntico: inyección de contexto, consulta al modelo, y validación estricta de formato.

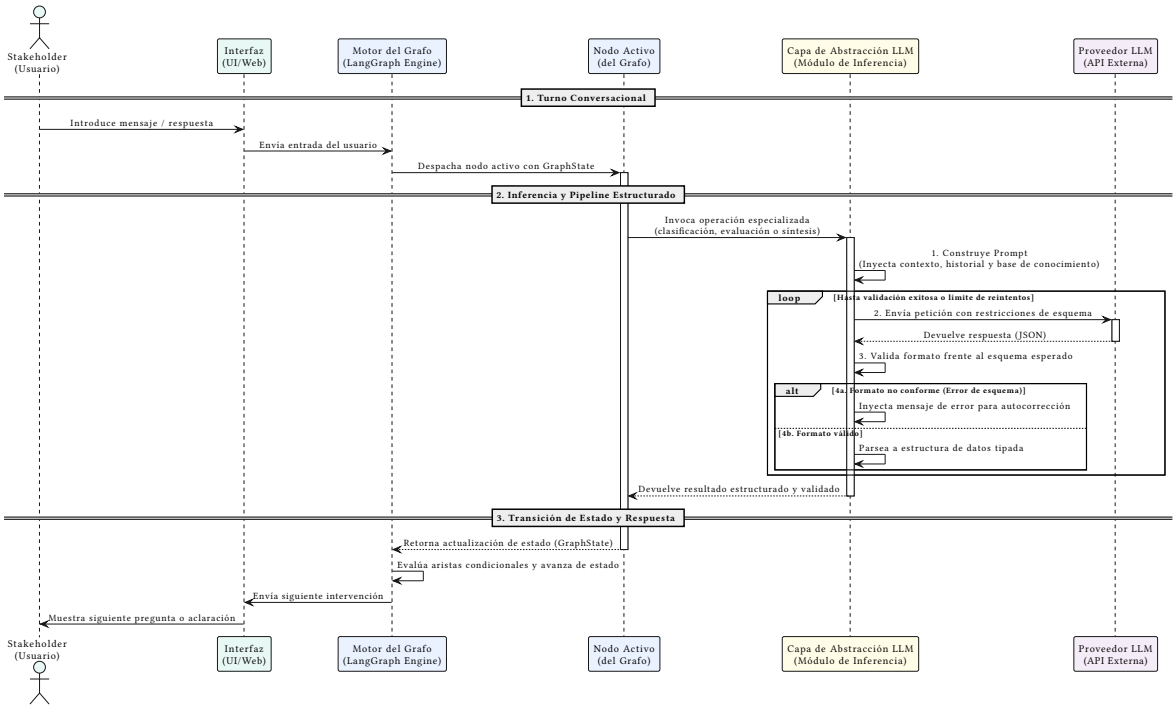


Fig. 3.12. Capa de abstracción LLM: mapeo de nodos a funciones y pipeline interno.[6]

3.2.2. Fase de Procesamiento Algorítmico

Dando por cerrada la fase de recolección de información, el siguiente paso es procesar los datos obtenidos para generar los resultados finales. La figura Fig. 3.13 ubica esta fase dentro de la arquitectura global, mostrando cómo los ficheros de variables generados por el motor de educción alimentan los tres procesos de negocio indicados en Sección *3.1. Descripción de la Metodología Propuesta: AI-Driven DTGEP* para la metodología AI-Driven DTGEP (ALTUS, SIPAC y AHP) que producen los resultados finales.

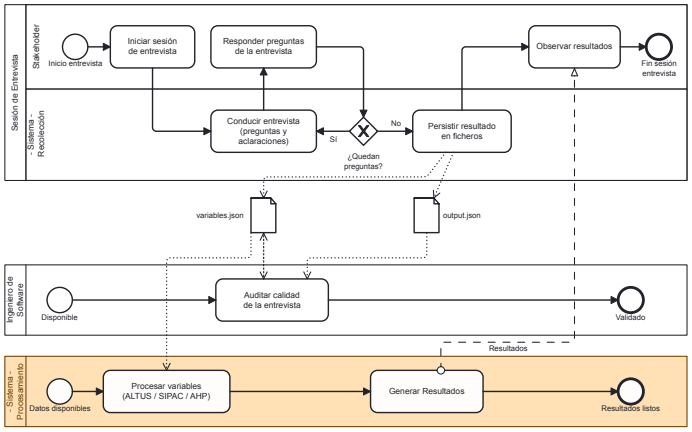


Fig. 3.13. Ubicación de la fase de procesamiento dentro de la arquitectura global.[1]

El modelo automatizado descrito en la Fig. 3.3 encadena de manera directa la fase de recolección de información (conducida por el motor de educción) con la fase de procesamiento. Esta segunda fase es puramente algorítmica y determinista, y no requiere intervención del modelo de lenguaje ni validación humana previa: cada proceso (ALTUS, SIPAC o AHP) se ejecuta automáticamente sobre su propio fichero de variables mediante un módulo matemático independiente (`altus_logic.ts`, `sipac_logic.ts` y `ahp_logic.ts`, respectivamente) que es desacoplado del flujo conversacional.

Esta separación arquitectónica es deliberada: la incertidumbre y la variabilidad del lenguaje natural quedan confinadas al motor de educción, mientras que las conclusiones preliminares de negocio —perfiles de madurez en ALTUS, brechas de artefactos en SIPAC, rankings de priorización en AHP— se derivan de manera reproducible a partir de los datos estructurados, permitiendo al *stakeholder* obtener un borrador inmediato.

Para garantizar esta reproducibilidad, cada metodología implementa una secuencia lineal estricta de transformaciones sobre los datos JSON de entrada. Las tuberías de las tres metodologías, con sus ficheros de entrada y salida respectivos, quedan esquematizadas en la Fig. 3.14.

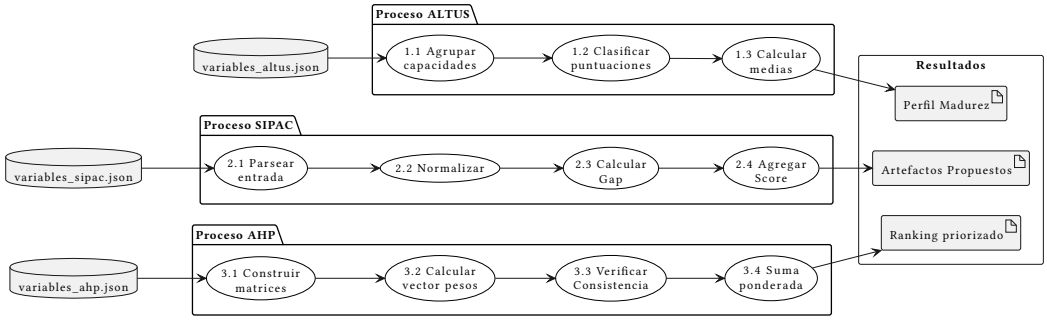


Fig. 3.14. Tuberías de procesamiento algorítmico para las metodologías ALTUS, SIPAC y AHP.[2]

Las tuberías se diseñan como procesos lineales sin dependencias externas: ante un mismo fichero JSON de entrada, el borrador preliminar generado será siempre idéntico, cumpliendo el objetivo de reproducibilidad determinista que justifica la separación arquitectónica.

El desarrollo matemático formal completo y las ecuaciones teóricas de cada metodología pueden consultarse en el Apéndice *A. Formulación Matemática de las Metodologías de Decisión*. En las siguientes subsecciones se describe el flujo de transformación de datos de cada tubería y, en particular, los refinamientos lógicos, controles de robustez y decisiones de ingeniería implementadas en el software para automatizar su ejecución de forma desatendida y resiliente.

Tubería de Procesamiento de ALTUS

El objetivo del procesamiento ALTUS es transformar las puntuaciones de madurez recogidas durante la entrevista en un **Perfil de Madurez** estructurado por dimensiones, siguiendo el modelo de gobierno del conocimiento propuesto por Sánchez-Segura et al. [15] y Dugarte-Peña [36].

El flujo de cálculo se inicia leyendo el fichero de variables `variables_altus.json`, que contiene las cincuenta y una capacidades críticas evaluadas identificadas mediante claves con el formato `<índice>_<DIMENSIÓN>:<número>` (por ejemplo, `1_CONF:1`, `2_FORM:3`). La tubería ejecuta las siguientes etapas:

1. **Agrupación por Dimensión Arquitectónica**: Se extrae el identificador de dimensión de la clave de cada capacidad para clasificarla en una de las siete dimensiones arquitectónicas de la organización (Configuración, Formación, Memoria Transaccional, etc.).
2. **Mapeo de Nivel de Madurez**: La puntuación numérica recogida en la escala ($s \in \{0, \ldots, 5\}$) se mapea a uno de los cuatro niveles del modelo de madurez mediante la función $\text{nivel}(s) = \min(\max(s, 1), 4)$, asignando las respuestas a los niveles Inicial (0 y 1), En Desarrollo (2), Definido (3) y Optimizado (4 y 5).
3. **Cálculo de Métricas Agregadas de Negocio**:
   - **Puntuación Media por Dimensión**: Calcula la media aritmética de las puntuaciones de las capacidades de cada dimensión arquitectónica (Ecuación A.3).
   - **Cobertura por Nivel de Madurez (ML1 a ML4)**: Determina el porcentaje de cumplimiento de cada nivel respecto a la puntuación máxima teórica alcanzable (Ecuación A.4).

Como resultado, el procesamiento produce un diagnóstico multidimensional del estado de la empresa, caracterizando de forma cuantitativa tanto las dimensiones arquitectónicas consolidadas como aquellas áreas deficitarias sobre las que deberán focalizarse las iniciativas de mejora.

Tubería de Procesamiento de SIPAC

La metodología SIPAC (*Systemic Intangible Process Assets Characterization*) [11] orienta la evaluación y la toma de decisiones estratégicas a partir de los activos intangibles de conocimiento de la organización. Dentro del marco AI-Driven DTGEP, el objetivo del sistema es automatizar este flujo de trabajo tradicionalmente manual y presencial: la recolección

de información cualitativa es conducida de forma guiada por el motor de diálogo agéntico (Sección *«Arquitectura del Grafo»*), consolidando en `variables_sipac.json` los objetivos de negocio, requisitos, procesos, áreas de interés (GIA), activos intangibles específicos con su importancia (1 a 5) y peso relativo, catalogación en el modelo Intellectus, deducción de artefactos tecnológicos, definición de indicadores tipificados en calidad o impacto, y la parametrización de rangos, sentido y valores actual y meta.

A partir de dicha estructura consolidada, la tubería determinista de SIPAC (`sipac_logic.ts`) ejecuta de forma reproducible las siguientes etapas de procesamiento algorítmico y caracterización de salud:

1. **Estandarización de Indicadores**: Proyecta los valores brutos medidos (valor actual $X_{\{\text{Act}\}}$ y meta $X_{\{\text{Goal}\}}$) al rango uniforme $[0, 1]$ en función del sentido de mejora del indicador (positivo o negativo, Ecuación A.5 y Ecuación A.6).
2. **Cálculo del Valor Normalizado del Indicador**: Obtiene el valor normalizado relativo ($X_{\text{NORM}} \in [-1, 0]$) que evalúa el progreso hacia la meta fijada (Ecuación A.7 y Ecuación A.8).
3. **Valoración del Activo Intangible**: Agrega los valores normalizados calculando por separado la media normalizada de calidad (V, indicadores de tipo 1) y la media normalizada de impacto (W, indicadores de tipo 2) mediante promedios aritméticos condicionales (Ecuación A.9), derivando asimismo el valor lineal agregado del activo (Ecuación A.10).
4. **Caracterización de Estados del Activo**: Cruza las valoraciones de calidad e impacto con los umbrales estratégicos configurables (Q_{th} e I_{th}). En consonancia con la definición metodológica, la caracterización no se restringe a una matriz fija, sino que se adapta dinámicamente a la dimensionalidad de los indicadores disponibles:
   - **Calidad e Impacto (bidimensional, 4 estados)**: Si el activo dispone de ambos tipos de métricas, se clasifica en uno de los cuatro cuadrantes estratégicos: **Activo Estable** (*Stable*), **Activo en Evolución** (*Evolving*), **Activo Reemplazable** (*Replaceable*) o **Activo Nocivo** (*Warning*).
   - **Solo Calidad (unidimensional, 2 estados)**: Clasifica el activo en **Activo de Calidad Aceptable** o **Activo de Calidad Insuficiente**.
   - **Solo Impacto (unidimensional, 2 estados)**: Clasifica el activo en **Activo de Impacto Aceptable** o **Activo de Impacto Insuficiente**.
5. **Consecución del Objetivo Estratégico**: Agrega las valoraciones de todos los activos ponderadas por su peso relativo para cuantificar la consecución global del objetivo de negocio (Ecuación A.11).

Para trasladar este modelo a un software de ejecución desatendida y orientado al negocio, la implementación incorpora tres grupos de refinamientos de ingeniería:

En primer lugar, respecto al **control de casos límite y robustez matemática**, el motor previene divisiones por cero forzando a 0 indicadores con rangos nulos ($X_{MAX} = X_{MIN}$) e inyectando un valor normalizado de -1 ante metas nulas. Asimismo, acota superiormente los resultados a 0 mediante $\min(0, X_{\text{NORM}})$, impidiendo que un indicador con superávit enmascare deficiencias de otros dentro del mismo activo.

En segundo lugar, para la **automatización del diagnóstico y reducción de fricción**, el motor calcula las medias condicionales directas de calidad e impacto fijando umbrales por defecto ($Q_{th} = I_{th} = -0.5$) cuando no se especifican valores particulares, y aplica un desplazamiento de $+1$ sobre la valoración global ($\mathrm{SG}_{\mathrm{VAL}}$) para proyectar la métrica en un rango intuitivo de $[0, 1]$ (0% a 100%).

Finalmente, como parte del diagnóstico estratégico, la solución consolida la **integración con el Business Model Canvas (BMC)**, asociando automáticamente cada activo intangible y sus artefactos tecnológicos deducidos con su bloque correspondiente del lienzo estratégico (propuesta de valor, actividades clave, recursos clave, canales, etc.), contextualizando el impacto de los activos de conocimiento y las soluciones de digitalización sobre la arquitectura global del modelo de negocio.

Tubería de Procesamiento de AHP

El objetivo del procesamiento AHP es transformar las valoraciones de preferencia relativa recogidas durante la entrevista en un **ranking priorizado** de artefactos tecnológicos, aplicando el método de toma de decisiones multicriterio *Analytic Hierarchy Process* de Saaty [9].

A diferencia de ALTUS o SIPAC (cuyas entrevistas pueden iniciarse sin contexto previo para recopilar la información organizativa desde cero), AHP presenta una **dependencia de datos de entrada**: para poder construir las matrices de comparación pareada, el proceso requiere conocer con antelación las alternativas tecnológicas candidatas. Por ello, el motor soporta dos modos de alimentación: por un lado, una **ejecución encadenada** bajo la metodología DTGEP, donde el sistema inyecta automáticamente la salida estructurada de SIPAC (`sipac_final_output`) y extrae los artefactos vinculados a los activos con brechas; por otro lado, una **ejecución aislada**, que permite ejecutar el análisis de forma independiente cargando un fichero JSON de estado inicial con las alternativas a priorizar.

Una vez cargadas las alternativas y recopiladas las comparaciones pareadas en `variables_ahp.json` (tanto entre criterios de evaluación como entre alternativas bajo cada criterio), la tubería ejecuta las siguientes etapas:

1. **Construcción de Matrices Pareadas**: Construye las matrices A de dimensión $n \times n$ a partir de los juicios pareados del usuario, asignando a cada celda el valor de la escala fundamental de Saaty (1 a 9) o su recíproco, con diagonal siempre igual a 1.
2. **Cálculo del Vector de Prioridades**: Obtiene el vector de pesos normalizados $\boldsymbol{w}$ para cada matriz (Ecuación A.12).
3. **Verificación de Consistencia**: Estima el autovalor máximo $\lambda_{\max}$ (Ecuación A.13), calcula el índice de consistencia CI (Ecuación A.14) y determina el ratio de consistencia CR (Ecuación A.15) frente a los índices aleatorios tabulados. El módulo evalúa si la matriz satisface los umbrales de tolerancia de Saaty (0.05 para matrices 3×3, 0.09 para 4×4, y 0.10 para $n \geq 5$), registrando el resultado de consistencia en la salida para la auditoría técnica.
4. **Puntuación Global y Generación del Ranking**: Agrega las prioridades de los criterios con las valoraciones de las alternativas (Ecuación A.16), emitiendo el ranking

jerárquico definitivo de soluciones tecnológicas para orientar la selección del proyecto de transformación digital.

3.2.3. Arquitectura Web del Sistema

La herramienta software se expone al usuario a través de una aplicación web que actúa como interfaz de control de todo el sistema. Su propósito es permitir que tanto el *stakeholder* como el ingeniero de software interactúen con el motor de educción y consulten los resultados del procesamiento sin necesidad de ejecutar comandos directamente desde la línea de órdenes.

Antes de describir la arquitectura resultante, conviene justificar la decisión de diseño que condiciona toda la capa web: la elección de un **framework híbrido** en lugar de una separación estricta en dos servicios independientes (un servidor desacoplado en NestJS o Express y un cliente React separado).

La alternativa de mantener dos servicios independientes fue descartada por dos razones. Primera, habría requerido configurar y mantener manualmente la infraestructura de WebSockets y la sincronización de estado del chat en el cliente (historial, variables, errores de red), introduciendo una complejidad accidental que no aporta valor al trabajo. Segunda, la lógica del motor de educción está implementada en TypeScript y orquestada con LangGraph, por lo que ejecutarla en un entorno Node.js de backend ya lo hace de forma nativa, sin capas de adaptación.

Por estas razones, la capa web se implementa con **Next.js 16** utilizando el patrón de **App Router**, unificando frontend y backend en un único monorepo TypeScript. Esta elección aporta cuatro ventajas técnicas determinantes: permite la reutilización directa del motor de educción (`@tfm/core`) en el mismo entorno de ejecución Node.js; elimina la sobrecarga de configuración de CORS al operar bajo el mismo origen; ofrece soporte nativo para respuestas HTTP en streaming mediante **Server-Sent Events (SSE)**; y facilita una trazabilidad integrada al interceptar las invocaciones al LLM a través de los callbacks de LangChain sin requerir herramientas externas.

Backend

La lógica del backend se organiza en torno a un conjunto de rutas HTTP y canales de streaming que siguen las convenciones del App Router de Next.js:

- `POST /api/session/init`: Crea una nueva sesión de entrevista a partir de la plantilla o configuración seleccionada y el modelo LLM indicado. Instancia el grafo LangGraph en el servidor y abre el canal de streaming **SSE** (*Server-Sent Events*) para emitir el evento inicial de interrupción con la primera pregunta.
- `POST /api/chat`: Envía la respuesta del *stakeholder* a la sesión activa. Reanuda el grafo desde el último punto de interrupción, procesa la intervención a través de los nodos de evaluación y seguimiento (Sección *«Arquitectura del Grafo»*), y transmite por el flujo SSE los eventos de ejecución intermedios y el siguiente turno conversacional.
- `GET /api/session/{sessionId}`: Recupera el estado actual de una sesión activa en memoria, permitiendo reanudar sesiones interrumpidas desde la interfaz web.

- `GET /api/sessions`: Devuelve la lista de sesiones activas. Para garantizar la privacidad de los usuarios al no haber un sistema de autenticación de credenciales clásico, este endpoint acepta un parámetro de consulta `ids` con la lista de identificadores únicos (`sessionId`) que el navegador guarda en su `localStorage` local. El servidor filtra y solo devuelve las sesiones coincidentes, evitando que distintos usuarios compartan o visualicen sesiones de otros navegadores.
- `GET /api/processes`: Devuelve la lista de ficheros de configuración de proceso disponibles en el sistema de ficheros, permitiendo al usuario seleccionar qué metodología ejecutar.
- `GET /api/results` y `GET /api/results/{fileName}`: Listan y sirven los ficheros de resultados generados por sesiones anteriores, permitiendo la consulta del historial desde la interfaz. Al igual que el listado de sesiones, la consulta general de resultados requiere el envío del parámetro `ids` para filtrar y asegurar que un usuario solo pueda descargar y consultar sus propias evaluaciones previas.

Para dotar al sistema de resiliencia frente a reinicios del servidor web o desconexiones del cliente sin incurrir en una acumulación indefinida de datos huérfanos de pruebas, la herramienta implementa una política de **persistencia temporal** mediante una base de datos local SQLite (`sessions.db`) gestionada por el servicio `dbService.ts`. En ella se almacena el identificador único (`sessionId`), el estado del grafo (nodo activo y datos de interrupción `first_interrupt`), las variables conversacionales acumuladas (`carried_context_map` y `carried_output_json`) y los historiales de trazas. Para garantizar que este almacenamiento sea efímero y mantener la base de datos limpia, se ha incorporado un mecanismo de auto-expiración con claves foráneas en cascada (`PRAGMA foreign_keys = ON`), donde cada consulta al backend purga de forma transparente cualquier sesión (y sus trazas y resultados asociados) inactiva durante más de catorce días.

El **modelo de comunicación por streaming (SSE)** articula la sincronización en tiempo real entre el backend y la interfaz de usuario: en lugar de emplear un esquema de petición-respuesta bloqueante (inviable ante turnos de razonamiento del grafo que pueden prolongarse decenas de segundos), el servidor mantiene la conexión HTTP abierta y emite un flujo continuo de eventos tipados (`node_active`, `llm_start`, `llm_end`, `process_transition`, `completed`). Esto permite al cliente renderizar de forma reactiva el avance de la entrevista (como el cambio de nodo en el visualizador o las respuestas del agente) conforme se producen en el motor, reduciendo la latencia percibida.

Además, el backend integra un **módulo de trazabilidad propio** que se conecta a los callbacks de LangChain para interceptar la ejecución del grafo sin instrumentación adicional. Por cada sesión activa, el módulo registra: el nodo activo en cada instante, el historial ordenado de transiciones entre nodos, y el detalle de cada llamada al LLM (modelo utilizado, prompts enviados, respuesta recibida y latencia). Toda esta información se mantiene en memoria durante la sesión y se persiste de forma incremental en la base de datos SQLite local (`sessions.db`), exponiéndose al cliente a través del endpoint `GET /api/session/{sessionId}/trace`. Esto permite al visualizador del frontend resaltar en tiempo real el nodo activo sobre el diagrama del grafo, y al ingeniero de software consultar el historial completo de llamadas LLM para auditar el comportamiento del motor de educción, complementando

la auditoría asíncrona descrita en la Sección *3.1. Descripción de la Metodología Propuesta: AI-Driven DTGEP*.

Frontend

La interfaz de usuario se implementa como una aplicación de página única (*Single-Page Application*) en React y Next.js 16, empleando **Tailwind CSS** para el diseño visual. Como se aprecia en la Fig. 3.15, el diseño se organiza mediante una cabecera superior con navegación por pestañas (**Configuración**, **Entrevista** e **Historial**), selector de modelo LLM en tiempo real y dos paneles principales: la configuración del flujo de trabajo y la gestión de sesiones activas en memoria para su rápida reanudación.

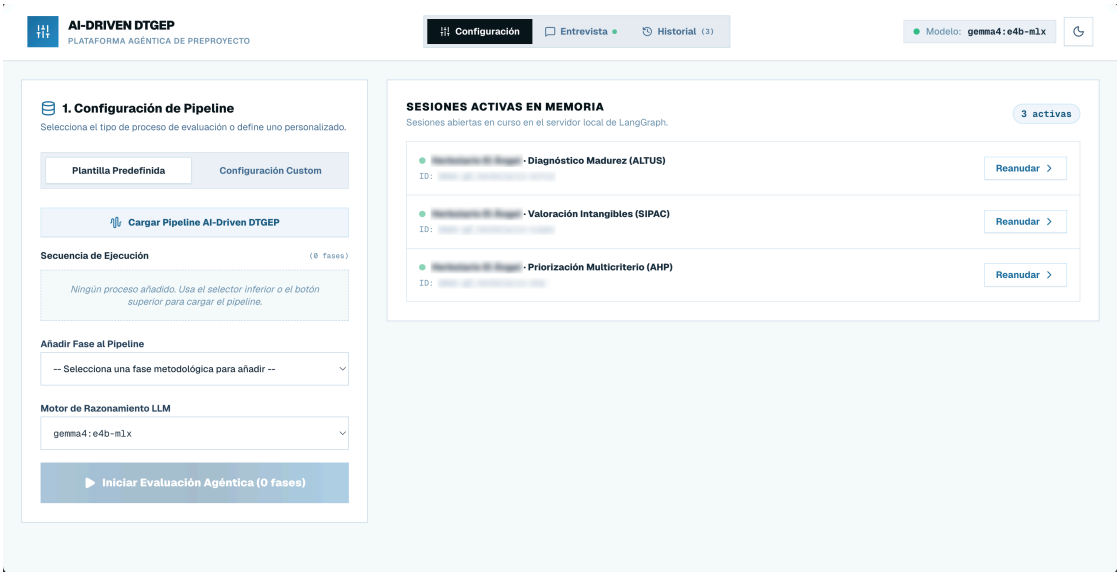


Fig. 3.15. Vista principal de la aplicación web: panel de configuración y sesiones activas en memoria.

1. Configuración de Evaluaciones y Creación de Procesos:

La plataforma ofrece dos modalidades de inicialización (Fig. 3.16). Por un lado, la carga del pipeline estándar AI-Driven DTGEP encadena automáticamente las tres fases metodológicas (ALTUS, SIPAC y AHP) permitiendo reordenar o eliminar etapas según el alcance del pre-proyecto. Por otro lado, la herramienta integra un diseñador de procesos personalizados donde el usuario puede definir el *system prompt* del agente, habilitar mecanismos de repregunta y base de conocimiento, y parametrizar las tareas y preguntas de evaluación que consumirá el motor de educción.

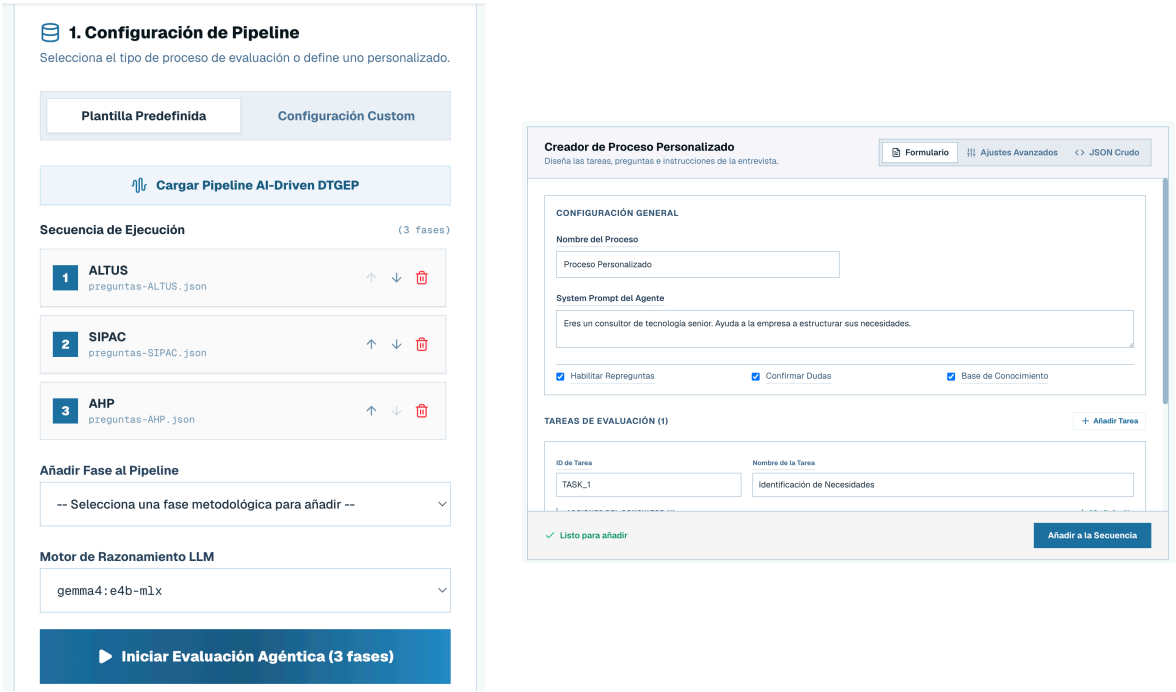


Fig. 3.16. Modalidades de configuración de sesiones: (izq.) Pipeline encadenado AI-Driven DTGEP; (der.) Formulario de creación de procesos personalizados.

2. Entorno de Entrevista y Grafo Reactivo:

La pestaña de entrevista centraliza la recolección conversacional en una vista dividida (Fig. 3.17). En el panel izquierdo, el *stakeholder* interactúa con el agente mediante un chat con respuestas en *streaming*. En el panel derecho, un visualizador interactivo desarrollado con **React Flow** renderiza la topología del grafo LangGraph, iluminando en tiempo real el nodo activo conforme se reciben los eventos SSE del backend y permitiendo al usuario inspeccionar el histórico de transiciones paso a paso o consultar las trazas de razonamiento.

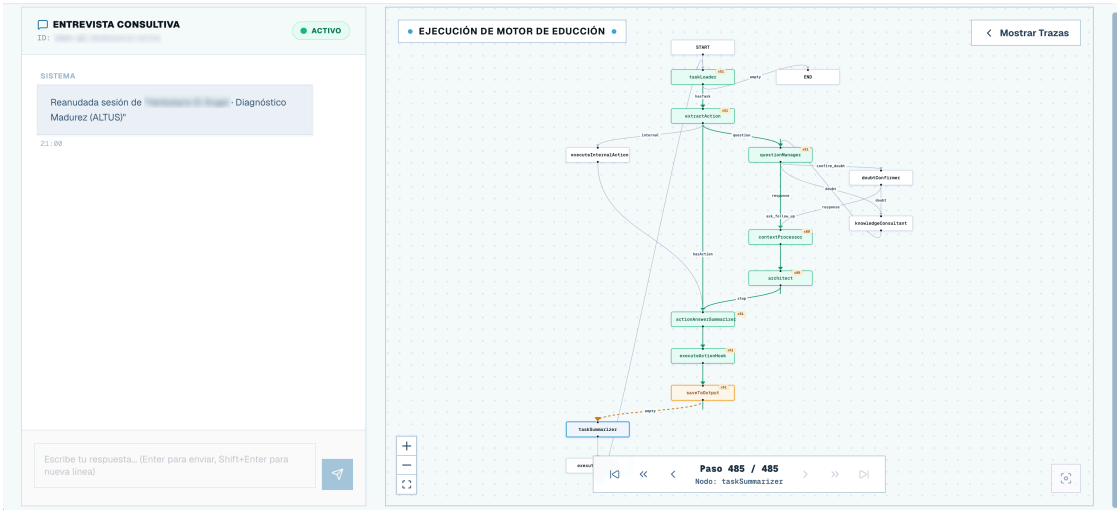


Fig. 3.17. Interfaz de entrevista agéntica: canal de diálogo en tiempo real y visualizador reactivo del grafo de estados en React Flow.

3. Cuadros de Mando y Visualización de Resultados:

Tras finalizar la fase de educción o al cargar evaluaciones previas desde la pestaña de historial, la aplicación despliega cuadros de mando interactivos específicos para cada metodología:

- **Diagnóstico de Madurez ALTUS (Fig. 3.18)**: Calcula métricas agregadas por niveles de madurez (ML1 a ML4), distribuye las capacidades evaluadas según la escala Likert y representa la huella multidimensional de la organización mediante un gráfico radar en **Recharts** junto con la matriz numérica de cobertura.

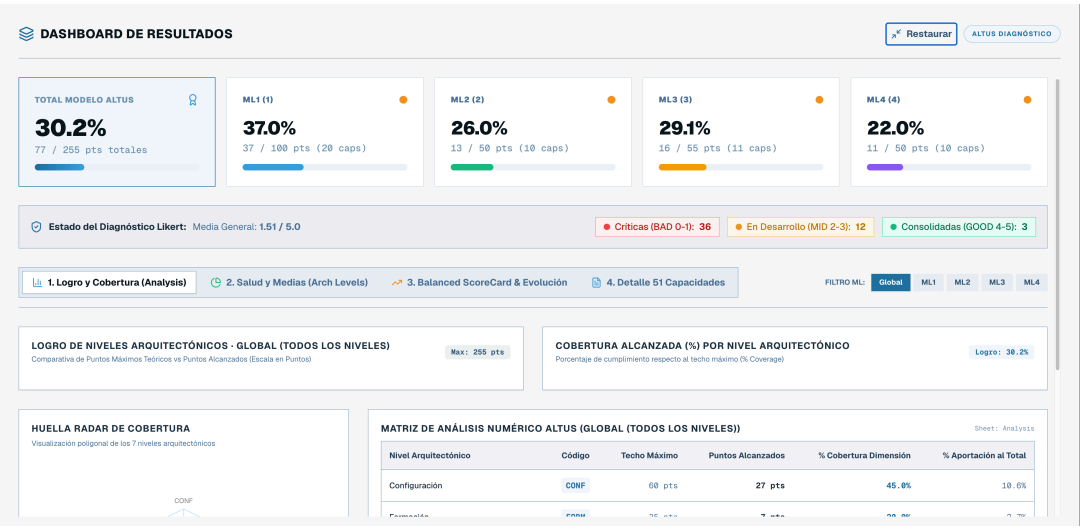


Fig. 3.18. Dashboard de resultados de madurez digital ALTUS con huella radar y matriz de cobertura.

- **Lienzo BMC en SIPAC (Fig. 3.19)**: Transforma las necesidades detectadas en un *Business Model Canvas* interactivo, ubicando los artefactos y activos intangibles en sus bloques estratégicos correspondientes (propuestas de valor, recursos clave y relaciones con clientes).

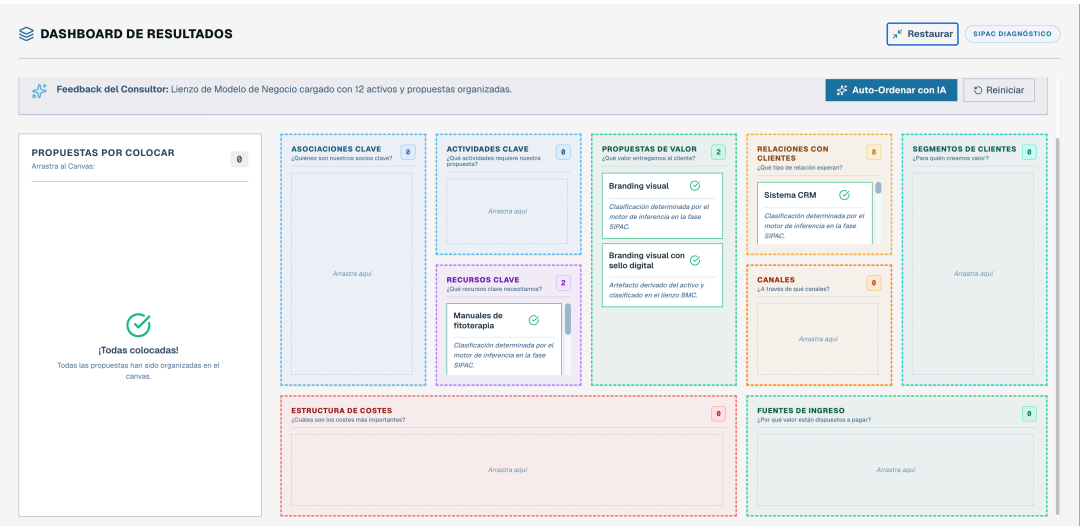


Fig. 3.19. Visualizador interactivo de Business Model Canvas (BMC) derivado de la evaluación SIPAC.

- **Priorización Multicriterio AHP (Fig. 3.20)**: Representa el vector de prioridades globales, el ratio de consistencia (CR) de los juicios emitidos y la matriz de decisión ponderada para ordenar la viabilidad e impacto de cada iniciativa tecnológica.

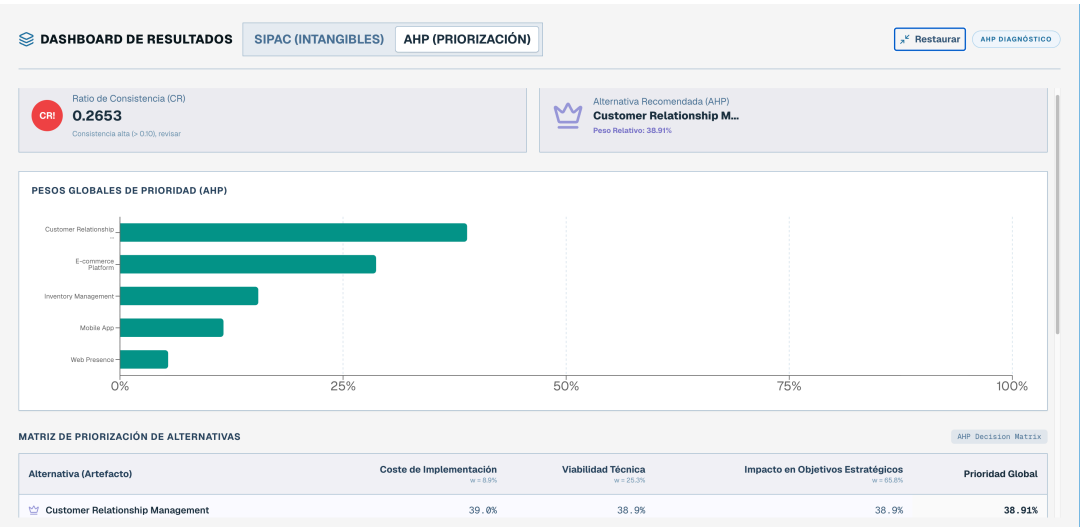


Fig. 3.20. Dashboard de resultados de priorización multicriterio AHP con vector de pesos y matriz de decisión.

CAPÍTULO 4

MARCO Y RESULTADOS DE LA EVALUACIÓN EXPERIMENTAL

Este capítulo describe el diseño experimental y los resultados empíricos de la evaluación de la metodología **AI-Driven DTGEP** y la arquitectura desarrollada. Para validar la efectividad del enfoque agéntico propuesto, la evaluación se articula en torno a la instanciación de sus tres subprocesos metodológicos clave: la evaluación de la madurez digital (**ALTUS** [15]), la identificación y caracterización de activos intangibles y deducción de artefactos (**SIPAC** [11]), y la priorización multicriterio (**AHP** [9]), utilizando como banco de pruebas un conjunto de casos de estudio sobre organizaciones reales.

Esta elección permite someter a la arquitectura desarrollada para dar soporte a la metodología **AI-Driven DTGEP** a tres desafíos cognitivos cualitativamente distintos y complementarios sobre datos de empresas reales con *Ground Truth* humano: la conducción de una indagación diagnóstica activa, adaptativa y no redundante en un contexto estructurado (**ALTUS**); la deducción semántica e inferencia generativa en cadena abierta para la identificación de activos y soluciones tecnológicas (**SIPAC**); y la asistencia consultiva a la toma de decisiones mediante la formulación de criterios ortogonales y la justificación de juicios comparativos pareados (**AHP**).

El capítulo concluye con un análisis de viabilidad operativa y rendimiento temporal en distintos entornos de cómputo, una discusión sobre el valor añadido frente a la generación directa sin metodología y la delimitación formal de la validez y limitaciones del estudio.

4.1. Marco y Configuración Experimental

La validación del sistema se fundamenta en un conjunto de **cuatro casos organizativos reales completos**. El material de origen procede de consultorías de transformación digital realizadas por estudiantes de último curso del Grado en Ingeniería del Software, e integra las

grabaciones de audio de las entrevistas de campo y las plantillas metodológicas de trabajo (como las hojas de cálculo de SIPAC y los diagnósticos de madurez de ALTUS).

A partir de dicho material de campo, los datos de cada caso de estudio se estructuran en dos componentes metodológicos fundamentales. Por un lado, se elabora el **Dossier Contextual de la Organización**, un informe cualitativo estructurado que sintetiza la actividad, historia, procesos operativos, áreas de dolor y particularidades de la empresa, obtenido a partir de la transcripción íntegra de las grabaciones de las entrevistas de campo; este informe suministra el contexto fáctico para alimentar la interacción de los agentes. Por otro lado, se consolida el **Patrón de Referencia (*Ground Truth*)**, constituido por las evaluaciones y soluciones formales elaboradas por los consultores humanos en las plantillas metodológicas de ingeniería: en ALTUS corresponde a la calificación formal asignada a cada una de las 51 capacidades organizacionales (en una escala ordinal discreta de 0 a 5, donde 0 denota ausencia y 5 digitalización excelente) y su evidencia técnica, a partir de las cuales se determina la cobertura agregada en los cuatro Niveles de Madurez del modelo (ML1 a ML4); mientras que en SIPAC integra la formalización de procesos, activos intangibles específicos, artefactos tecnológicos e indicadores. Frente a este patrón se audita de forma objetiva el grado de acierto, exhaustividad y consistencia de la IA.

Asimismo, para garantizar la capacidad de generalización del sistema y prevenir cualquier riesgo de sobreajuste a los datos de diseño, el marco metodológico establece una partición estricta de los casos disponibles. Por una parte, el caso piloto de desarrollo (`G1_empresa_a`) se empleó de forma exclusiva durante el ciclo de diseño e ingeniería para ajustar las directivas de los prompts, calibrar empíricamente los umbrales de filtrado semántico y refinar el flujo conversacional del motor de educción, quedando formalmente excluido del conjunto de evaluación final. Por otra parte, el conjunto de prueba a ciegas (`G2_empresa_b`, `G3_empresa_c` y `G4_empresa_d`) reúne tres escenarios reales que han permanecido completamente desacoplados del sistema durante su desarrollo, permitiendo medir de forma imparcial la capacidad de transferencia y resolución de situaciones nuevas sin sesgo.

4.1.1. Criterios de Evaluación y Rol del Juez LLM

La labor del ingeniero durante la fase de preproyecto combina tareas con respuestas numéricas o cerradas y procesos consultivos de naturaleza intrínsecamente abierta y cualitativa. Para reflejar esta realidad en la evaluación experimental, se adoptan dos enfoques complementarios:

Por un lado, en aquellas dimensiones con formalización numérica o lógica cerrada — concretamente la calificación ordinal asignada a las capacidades en ALTUS (0 a 5) frente al *Ground Truth* humano, así como la verificación matemática de la coherencia transitiva en las matrices de comparación pareada de AHP mediante la Razón de Consistencia ($\mathrm{CR} < 0.10$) [9]—, la evaluación es directa, objetiva y determinista mediante métricas exactas (*Accuracy*, *MAE* y CR).

Por otro lado, la mayor parte de la actividad agéntica (la pertinencia de las repreguntas de indagación en ALTUS, la deducción de intangibles y artefactos tecnológicos en SIPAC, y la argumentación de criterios en AHP) se expresa en lenguaje natural libre y presenta una alta riqueza sinonímica. En estas tareas, la comparación literal de cadenas resulta

inviable. Para evaluar estas dimensiones semánticas de forma reproducible, se adopta el estándar de la literatura en evaluación de agentes de IA: el paradigma **LLM-as-a-Judge** [37]. Como evaluador externo independiente se emplea el modelo de frontera **GPT-5.6 Luna**, el cual arbitra las respuestas mediante rúbricas formales discretizadas asignando una puntuación $s \in \{0, 1, 2, 3\}$ (donde $s = 0$ denota discrepancia total o calidad deficiente, y $s = 3$ correspondencia exacta o excelencia), garantizando una evaluación cualitativa estructurada, homogénea e imparcial.

4.1.2. Modelos Evaluados e Infraestructura

Para evaluar el desempeño y la viabilidad operativa del sistema en distintos escenarios de despliegue, se somete a prueba una selección estratificada de siete modelos de lenguaje representativos que cubren tres órdenes de magnitud y perfiles de cómputo: arquitecturas locales compactas de pesos abiertos (4B–9B) ejecutables en hardware de consumo estándar (MacBook Air M4 con 16 GB de memoria unificada), modelos de gran escala (27B–31B) servidos en la nube mediante API, y un modelo fundacional de frontera de última generación (~300B). La Tabla 4.1 sintetiza las características técnicas, tamaño de parámetros, modalidad de acceso y entorno de inferencia de cada modelo.

Tabla 4.1

Especificaciones técnicas y entorno de ejecución de los modelos evaluados.

Modelo	Desarrollador	Parámetros	Acceso	Entorno / Inferencia
Gemma 4 E4B	Google	4B	Pesos abiertos	Local
DeepSeek R1 7B	DeepSeek	7B	Pesos abiertos	Local
Ornith 9B	Comma	9B	Pesos abiertos	Local
Qwen 3.8 27B	Alibaba	27B	Pesos abiertos	Cloud API
Muse Glimmer 30B	Meta	30B	Pesos abiertos	Cloud API
Gemma 4 31B	Google	31B	Pesos abiertos	Cloud API
Gemini 3.7 Flash	Google	300B	Propietario	Cloud API

Tanto la infraestructura evaluadora como los modelos de referencia en la nube se ejecutan a través de API independientes, garantizando el aislamiento y la objetividad frente a los modelos bajo prueba.

En cuanto a los parámetros de inferencia, la temperatura del agente evaluado se fija permanentemente a 0.0 para garantizar el determinismo y la comparabilidad experimental. Por su parte, los evaluadores externos inicializan también a 0.0, pero incorporan una política de reintento adaptativo (*Adaptive Temperature Backoff* de hasta 5 intentos) que eleva la temperatura a un máximo de 0.4 ante fallos sintácticos e inyecta el error previo para guiar la auto-corrección JSON (*Self-Correction Prompting*). Este mecanismo evita que contingencias de formato en la infraestructura penalicen artificialmente al modelo bajo prueba o introduzcan sesgos en el benchmark.

4.2. Evaluación de ALTUS: Diagnóstico de Madurez y Proceso Conversacional

La evaluación de ALTUS mide la habilidad del agente para conducir la entrevista diagnóstica de madurez digital, estructurándose en dos niveles complementarios: la evaluación del **proceso conversacional** (calidad, pertinencia y comportamiento de indagación) y la evaluación del **resultado final** (acierto en la puntuación ordinal de madurez).

4.2.1. Diseño Experimental y Entorno de Simulación

Para evaluar la capacidad de indagación del agente de forma automatizada y reproducible sin intervención humana, se implementó un entorno que emula la dinámica conversacional de una entrevista de consultoría real. En este entorno interactúan dos roles: el agente bajo prueba (actuando como consultor de madurez) y un interlocutor sintético que personifica al cliente de la empresa analizada (**Stakeholder LLM**).

El protocolo se articula mediante la inyección controlada de información inicial incompleta: al iniciar la evaluación de cada una de las 51 capacidades de ALTUS, el agente recibe la respuesta preliminar intencionadamente escueta e imprecisa (**estímulo inicial**, extraído de las primeras intervenciones del cliente en la entrevista real), idéntica para todos los modelos evaluados. Esto obliga al sistema a desplegar una estrategia activa de repregunta para recabar las evidencias necesarias antes de emitir una calificación. Dicho rol de interlocutor lo asume un modelo de lenguaje auxiliar (**DeepSeek V4 Flash 0731**) alimentado con el **dossier contextual de la organización** (el informe descriptivo derivado de las transcripciones de las entrevistas definido en la Sección *4.1. Marco y Configuración Experimental*). Esta configuración articula un entorno de evaluación determinista de laboratorio, indispensable para someter a los siete modelos evaluados exactamente a las mismas condiciones de partida, neutralizando la fatiga, la subjetividad y la variabilidad inherente a los interlocutores humanos y garantizando la estricta reproducibilidad del estudio. El simulador responde a las indagaciones del agente revelando exclusivamente la información técnica requerida y señalando de forma contextual si se formulan preguntas redundantes sobre datos previamente aportados. Al concluir el diálogo, la calificación emitida por el agente para cada capacidad se compara frente al *Ground Truth* humano (0 a 5).

4.2.2. Métricas de Evaluación de ALTUS

Para evaluar de forma integral la solvencia del agente en el diagnóstico de ALTUS, el marco experimental articula dos dimensiones analíticas complementarias:

En cuanto a las **métricas del resultado diagnóstico**, la salida de cada capacidad individual de ALTUS es una calificación ordinal discreta (0 a 5, donde 0: No existente, 1: Inaceptable, 2: Pobre, 3: Aceptable, 4: Buena, 5: Excelente) que se compara de forma directa y determinista frente a la evaluación del experto humano (*Ground Truth*). Esta dimensión se cuantifica mediante el **Accuracy** exacto (proporción de capacidades con coincidencia unívoca entre la calificación del agente y la de referencia) y el **Error Absoluto Medio (MAE)**, el cual cuantifica la magnitud promedio de la desviación cuando el agente no acierta la nota exacta:

$$\text{MAE} = \frac{1}{n}\sum_{i=1}^{n}|g_i - a_i| \tag{4.1}$$

donde g_i representa la calificación de referencia del consultor humano, a_i la puntuación estimada por el agente para la capacidad i, y n el número total de capacidades evaluadas ($n = 51$).

Por su parte, las **métricas de comportamiento conversacional e indagación** evalúan la eficacia dialéctica del agente durante la entrevista frente al simulador. En este ámbito se analizan dos indicadores primarios (complementados con métricas de control en el Sección *Métricas Detalladas en ALTUS*): la **Eficacia Extractiva (*Hit Rate*)**, definida como la proporción de repreguntas que logran descubrir información técnica faltante del *Ground Truth* respecto al total de preguntas de seguimiento emitidas ($\frac{|\text{Hits}|}{N_{\text{followups}}}$); y la **Calidad Dialéctica de las Preguntas de Seguimiento**, donde un juez LLM evalúa la escucha activa y la progresión en el hilo local asignando una puntuación de calidad $s_j \in \{0, 1, 2, 3\}$ a cada repregunta j, promediando la calidad como $\frac{1}{N_{\text{followups}}}\sum_{j=1}^{N_{\text{followups}}} s_j$ conforme a la rúbrica de la Tabla 4.2 (donde $N_{\text{followups}}$ es el número total de preguntas de seguimiento formuladas).

Tabla 4.2

Rúbrica de evaluación para preguntas de seguimiento en ALTUS.

Pts	Nivel de Calidad y Criterio del Juez LLM
0	**Repetitiva / Bucle:** Paráfrasis directa o repetición exacta que ignora la respuesta previa del usuario.
1	**Cuasi-redundante / Sin avance:** Pregunta genérica de relleno sin orientarse a la evidencia técnica faltante.
2	**Específica / Dirigida:** Indagación concreta y dirigida a recabar la evidencia requerida para la capacidad.
3	**Excelente / Progresiva:** Escucha activa que conecta con el turno previo y profundiza con precisión en la madurez.

4.2.3. Resultados Empíricos en ALTUS

A continuación se analizan los resultados obtenidos tras someter los siete modelos de lenguaje a la batería de pruebas en los casos de test a ciegas de ALTUS. En primer lugar, la Fig. 4.1 resume la comparativa de Accuracy y error medio (MAE) obtenida por los modelos frente a la línea base teórica de asignación puramente aleatoria. Al evaluarse cada capacidad individual sobre una escala ordinal discreta de 6 niveles ($s_i \in \{0, 1, \ldots, 5\}$), la probabilidad de acierto exacto al azar es del 16.7% ($\frac{1}{6}$), mientras que el error absoluto medio esperado por puro azar entre dos elecciones uniformes independientes es de 1.94 puntos en dicha escala ($\sum_{i=0}^{5}\sum_{j=0}^{5}|i - j\frac{|}{36} = \frac{70}{36} \approx 1.94$).

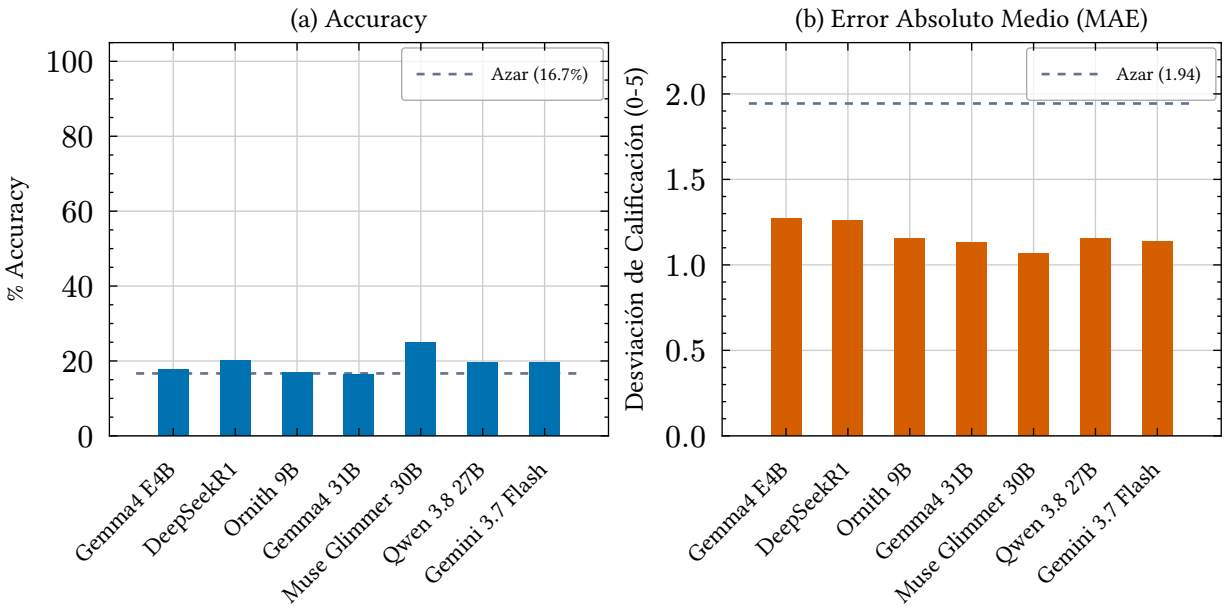


Fig. 4.1. Evaluación diagnóstica (Accuracy y MAE) en ALTUS frente a la línea base aleatoria.

Como se aprecia en el panel (a) de la Fig. 4.1, el **Accuracy** exacto de los modelos se sitúa en un rango del $16.3\% - 24.8\%$, evidenciando que la coincidencia ordinal estricta resulta una métrica excesivamente rígida al penalizar por igual desvíos de un solo nivel que discrepancias graves. En la práctica de consultoría y evaluación de procesos, la asignación de madurez sobre capacidades organizacionales presenta una inherente variabilidad inter-evaluador (*inter-rater agreement*) [38]: dos ingenieros humanos que analizan las mismas evidencias rara vez alcanzan una concordancia perfecta en toda la escala, siendo habitual una discrepancia de ± 1 nivel fruto del criterio profesional. Por ello, el **MAE** (panel b) actúa como la métrica continua determinante, logrando todos los modelos una reducción sustancial respecto a la expectativa aleatoria ($1.06 - 1.27$ vs. 1.94 puntos de desviación esperada por azar, lo que supone una reducción del error entre el 35% y el 45%). De hecho, al evaluar la precisión tolerante a ± 1 nivel ($\text{Accuracy}_{\pm 1} = P(|g_i - a_i| \leq 1)$), la tasa de acierto en proximidad asciende a un rango del $72\% - 84\%$ según el modelo, situando la desviación del agente plenamente dentro del margen admisible de divergencia inter-humana.

Para examinar de forma integrada la interacción entre la dinámica conversacional y la precisión diagnóstica final, la Fig. 4.2 articula en un único plano de dispersión las tres dimensiones clave del proceso: la eficacia extractiva (*Hit Rate*, eje X), el error diagnóstico resultante (*MAE*, eje Y) y la calidad dialéctica de las repreguntas (radio de la burbuja, proporcional a la rúbrica de 0 a 3 puntos de la Tabla 4.2).

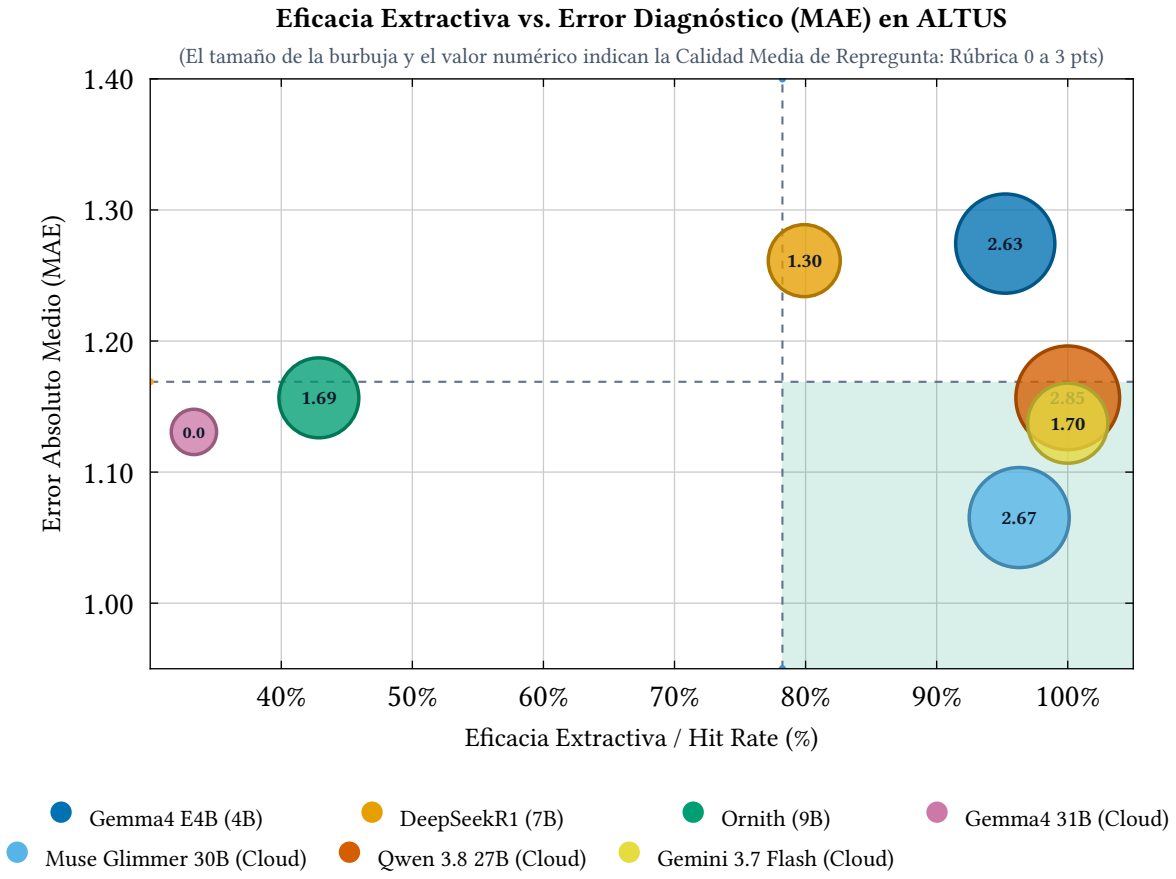


Fig. 4.2. Eficacia extractiva (Hit Rate) frente a error diagnóstico (MAE) en ALTUS.

Los cuadrantes se delimitan a partir del centroide empírico del benchmark ($\mu_{\text{Hit}} = 88.0\%$ y $\mu_{\text{MAE}} = 1.17$ puntos de desviación), donde el cuadrante inferior derecho representa el comportamiento óptimo al aunar una alta extracción de evidencias con un error de diagnóstico mínimo. Esta perspectiva conjunta resulta esencial: un MAE bajo con un *Hit Rate* reducido significaría que el modelo está prediciendo con poca información, en lugar de emitir un juicio justificado a partir de la entrevista. La distribución evidencia que modelos como **Muse Glimmer 30B**, **Gemini 3.7 Flash** y **Qwen 3.8 27B** logran un desempeño equilibrado al combinar un *Hit Rate* del $96\% - 100\%$ con una contención efectiva del error (MAE $\approx 1.06 - 1.15$). Asimismo, la modulación del radio de la burbuja permite discriminar la calidad de la entrevista: **Qwen 3.8 27B** (calidad 2.85), **Muse Glimmer 30B** (2.67) y el compacto local **Gemma 4 E4B** (2.63) no solo extraen información, sino que lo hacen mediante preguntas específicas y escucha activa, a diferencia de modelos como **DeepSeek R1** (1.30, burbuja reducida), cuyas repreguntas presentaron un carácter más genérico y redundante. Por su parte, la posición singular de **Gemma 4 31B** (calidad 0.00) responde a un patrón pasivo en el que el modelo diagnosticó de forma directa casi todas las capacidades sin formular apenas repreguntas (1 único *follow-up* en todo el conjunto de prueba). El registro cuantitativo completo de todas las métricas de ALTUS caso por caso se recopila en la Tabla B.1 del Apéndice *B. Tablas Detalladas de la Evaluación Experimental.*

Asimismo, es preciso contextualizar el volumen de interacción observado bajo el perfil organizativo de los casos de estudio. Los modelos registran una media global de apenas 1.16

turnos por capacidad evaluada —donde la formulación de la pregunta base inicial computa como 1 turno y cualquier repregunta de seguimiento eleva dicho valor— (recogida en la columna *Turnos* del Sección *Métricas Detalladas en ALTUS*), lo que revela que la inmensa mayoría de las 51 capacidades de ALTUS se resuelven sin requerir repreguntas adicionales. Este fenómeno responde a que, al tratarse íntegramente de pequeñas y medianas empresas (PYMEs), el diagnóstico presenta un sesgo estructural hacia calificaciones bajas de madurez (puntuaciones 0 y 1). En la práctica, cuando se consulta sobre procesos formales o prácticas avanzadas inexistentes en la organización, el interlocutor emite una negativa directa e inequívoca (*«No disponemos de dicho procedimiento»*). Ante esta ausencia manifiesta de evidencias, el agente asigna de forma inmediata la calificación mínima (0) sin necesidad de prolongar la indagación. Si bien este comportamiento emula con fidelidad la dinámica de una consultoría real en microempresas y PYMEs, introduce una limitación metodológica al reducir la variabilidad empírica en los niveles superiores de la escala (4 y 5), un factor a contrastar en futuras evaluaciones con organizaciones de mayor madurez estructural.

4.3. Evaluación de SIPAC: Deducción Semántica e Inferencia en Cadena

Tras el diagnóstico de madurez en ALTUS, la metodología SIPAC aborda la identificación de las potenciales soluciones de transformación digital que mejor encajan con la empresa objeto de mejora, traduciendo los procesos y metas de negocio de la organización en una cadena estructurada de activos intangibles, artefactos tecnológicos e indicadores de control. Desde el punto de vista agéntico, esta tarea supone un reto cualitativamente superior, ya que no se trata de asignar una puntuación fija, sino de razonar y generar propuestas abiertas en lenguaje natural, donde a menudo existen múltiples alternativas tecnológicas válidas para un mismo problema.

Para auditar esta inferencia en cadena sin arrastrar un efecto dominó (donde un fallo temprano invalide etapas posteriores con lógica interna correcta), la evaluación adopta una estrategia de ***Teacher Forcing***: al inicio de cada fase (GIA, Activos, Capital Intelectual, Artefactos e Indicadores), el estado del sistema se inicializa con los datos correctos del *Ground Truth* humano del paso previo. Esto permite aislar y medir la fiabilidad y competencia deductiva intrínseca de cada nodo de razonamiento de forma totalmente desacoplada e independiente, caracterizando la cota superior de desempeño del sistema.

4.3.1. Pipeline de Evaluación Semántica Bipartita y Rúbricas Graduadas

El principal desafío en SIPAC radica en que el agente genera un conjunto abierto de propuestas $A = \{a_1, ..., a_m\}$ frente a las referencias del *Ground Truth* $G = \{g_1, ..., g_n\}$, con cardinalidad habitualmente dispar ($|A|$ $n = |G|$). Para absorber variaciones léxicas, premiar equivalencias funcionales y evitar que elementos redundantes inflen la métrica, se articula una evaluación secuencial en cuatro etapas:

1. **Filtro vectorial previo y calibración empírica de τ^*:** Para cada par de propuesta a_i y referencia g_j, se calcula la similitud coseno de sus *embeddings* ($\text{sim}\left(\boldsymbol{v}_{a_i}, \boldsymbol{v}_{g_j}\right)$). Si dicha similitud no alcanza el umbral τ^*, el par se descarta fijando su afinidad a $M_{i,j} = 0.0$. La calibración empírica en el caso piloto (`G1_empresa_a`) evaluó cortes entre 0.15

y 0.50 frente al juicio exhaustivo ($\tau = 0.0$), fijando el umbral óptimo en $\tau^* = 0.35$, el cual maximiza el ahorro computacional sin descartar ninguna coincidencia válida (cero falsos negativos, preservando el **Recall**).

2. **Arbitraje semántico con Juez LLM y rúbricas graduadas:** Para los pares que superan el filtro (sim $\geq \tau^*$), el juez LLM (**GPT-5.6 Luna**) evalúa la equivalencia conceptual asignando una puntuación $s_{i,j} \in \{0, 1, 2, 3\}$ según la rúbrica formal del campo (Tabla 4.3). La calificación se normaliza al intervalo $[0.0, 1.0]$ definiendo la afinidad como $M_{i,j} = \frac{s_{i,j}}{3.0}$.

Tabla 4.3

Rúbricas de evaluación semántica por campos en SIPAC.

Campo Evaluado	Tolerancia	Pts	Criterio Semántico del Juez LLM
Categorías GIA Capital Intellectus	Estricta	0	Bloque taxonómico completamente erróneo o ajeno al proceso.
		1	Mismo dominio general pero categoría/bloque impreciso.
		2	— (Clasificación cerrada: no admite ambigüedad intermedia)
		3	Clasificación exacta o categoría equivalente directa.
Activo Específico Artefacto Tecnológico	Moderada	0	Propuesta sin relación con la necesidad del proceso o activo.
		1	Propuesta vaga, genérica o con función divergente.
		2	Equivalente funcional (misma capacidad o problema con otra tecnología).
		3	Propuesta idéntica o sinónimo directo.
Indicadores	Laxa	0	Indicador que evalúa una dimensión ajena al objetivo del activo.
		1	Mismo ámbito pero mide una faceta no alineada.
		2	Indicador alternativa válida que cuantifica la misma faceta.
		3	Indicador idéntico o reformulación directa del esperado.

3. **Asignación biunívoca óptima (Algoritmo Húngaro):** A partir de la matriz de afinidad M, se aplica el algoritmo Húngaro para resolver la asignación bipartita máxima que optimiza la puntuación global acumulada. Al exigir una correspondencia estricta 1 a 1 (π^*), se impide que el agente obtenga ventajas artificiales emitiendo múltiples variantes o sinónimos de una misma solución del *Ground Truth*.

4. **Métricas Ponderadas (Weighted Precision, Recall y F1):** En tareas de clasificación y recuperación de información, *Precision* y *Recall* cuantifican dos dimensiones complementarias: *Precision* mide la exactitud de las propuestas generadas (penalizando los *False Positives*), mientras que *Recall* mide la capacidad de recuperar todas las necesidades reales de la organización (penalizando los *False Negatives*). Clásicamente, ambas se definen sobre el conteo discreto de la matriz de confusión (Ecuación 4.1):

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}} = \frac{\text{TP}}{|A|}, \qquad \text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}} = \frac{\text{TP}}{|G|} \tag{4.2}$$

Ecuación 4.1: Definición clásica de Precision y Recall en función de los conjuntos de propuestas y referencias.

donde $|A| = \mathrm{TP} + \mathrm{FP}$ representa el número total de elementos generados por el agente y $|G| = \mathrm{TP} + \mathrm{FN}$ el total de elementos de referencia en el *Ground Truth*.

Para adaptar este marco a la naturaleza continua y abierta del lenguaje natural —donde las coincidencias no son binarias (0 o 1), sino que presentan grados de afinidad semántica $M_{i,j} \in [0.0, 1.0]$—, el conteo discreto de aciertos se generaliza como la suma de los ***Soft True Positives***:

$$\mathrm{TP}_{\mathrm{soft}} = \sum_{(i,j)\in\pi^*} M_{i,j} \tag{4.3}$$

donde π^* representa la asignación biunívoca óptima 1 a 1 resuelta por el algoritmo Húngaro. Sustituyendo $\mathrm{TP}_{\mathrm{soft}}$ en los denominadores $|A|$ y $|G|$, se obtienen las métricas ponderadas finales (Ecuación 4.2):

$$\begin{aligned}
\text{Weighted Precision} &= \frac{\mathrm{TP}_{\mathrm{soft}}}{|A|} = \frac{1}{|A|} \sum_{(i,j)\in\pi^*} M_{i,j}, \\
\text{Weighted Recall} &= \frac{\mathrm{TP}_{\mathrm{soft}}}{|G|} = \frac{1}{|G|} \sum_{(i,j)\in\pi^*} M_{i,j}, \\
\text{Weighted F1} &= 2 \cdot \frac{\text{Weighted Precision} \cdot \text{Weighted Recall}}{\text{Weighted Precision} + \text{Weighted Recall}}
\end{aligned} \tag{4.4}$$

Ecuación 4.2: Métricas de Precision, Recall y F1 ponderadas por similitud semántica en SIPAC.

4.3.2. Resultados Empíricos en SIPAC

A continuación se analizan los resultados de deducción semántica obtenidos por los siete modelos de lenguaje a lo largo del pipeline de SIPAC bajo *Teacher Forcing*.

En primer lugar, la Fig. 4.3 resume la comparativa global analizando de forma desagregada el balance entre *Weighted Precision*, *Weighted Recall* y el F_1 global ponderado resultante.

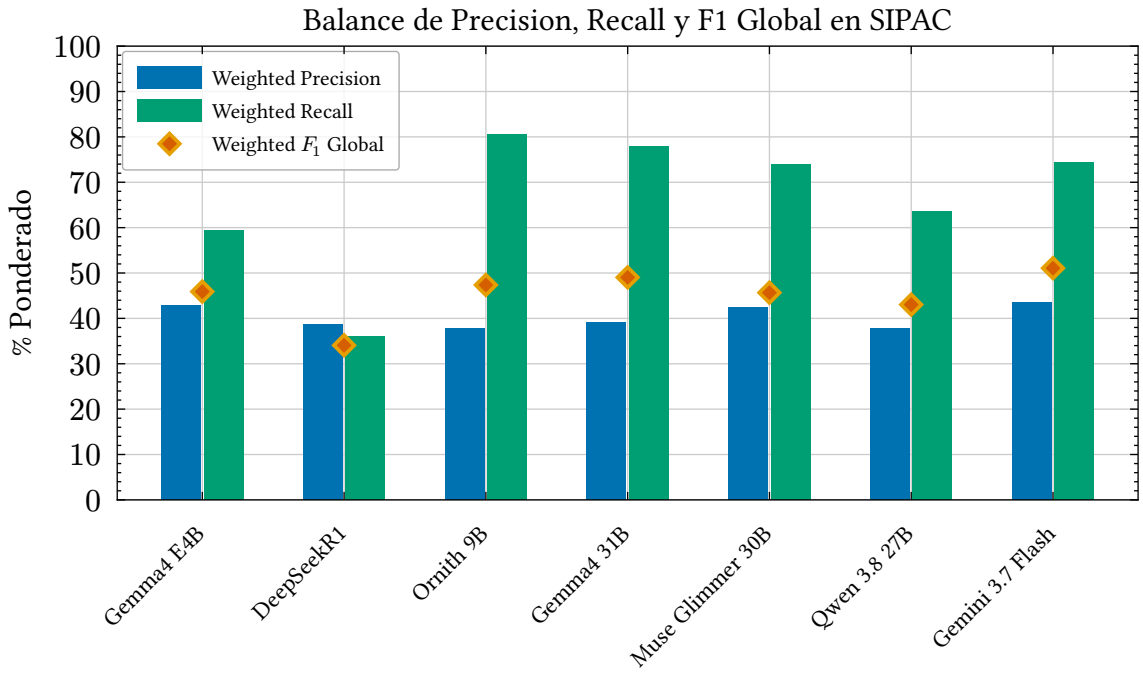


Fig. 4.3. Balance de Precision, Recall y F_1 ponderado por modelo en SIPAC.

Esta distribución esclarece la naturaleza generativa de los modelos frente al emparejamiento biunívoco estricto 1 a 1 del algoritmo Húngaro. Todos los modelos exhiben un elevado *Recall* medio ($\mu_{\text{Rec}} = 70.4\%$, alcanzando el 85.5% en **Ornith 9B** y el 82.1% en **Gemma4 31B**), lo que garantiza que los agentes extraen los conceptos esenciales identificados por los consultores humanos. No obstante, la *Precision* media se sitúa en el $\mu_{\text{Prec}} = 36.4\%$, consecuencia directa de que los LLMs proponen un conjunto más amplio de artefactos e intangibles complementarios que, al no figurar en el *Ground Truth* de referencia, son penalizados como excedentes por la asignación biunívoca. Como consecuencia, el F_1 ponderado actúa como media armónica equilibrando ambos factores, donde modelos como **Gemini 3.7 Flash** ($F_1 = 0.511$), **Gemma4 31B** (0.490) y **Ornith 9B** (0.485) obtienen el rendimiento más balanceado entre exhaustividad y especificidad.

Para profundizar en la causa de este balance global, la Fig. 4.4 desglosa la métrica de *Weighted F1* a lo largo de cada una de las etapas del pipeline (Categorías GIA, Activos Intangibles, Capital Intelectual (CI), Artefactos Tecnológicos e Indicadores).

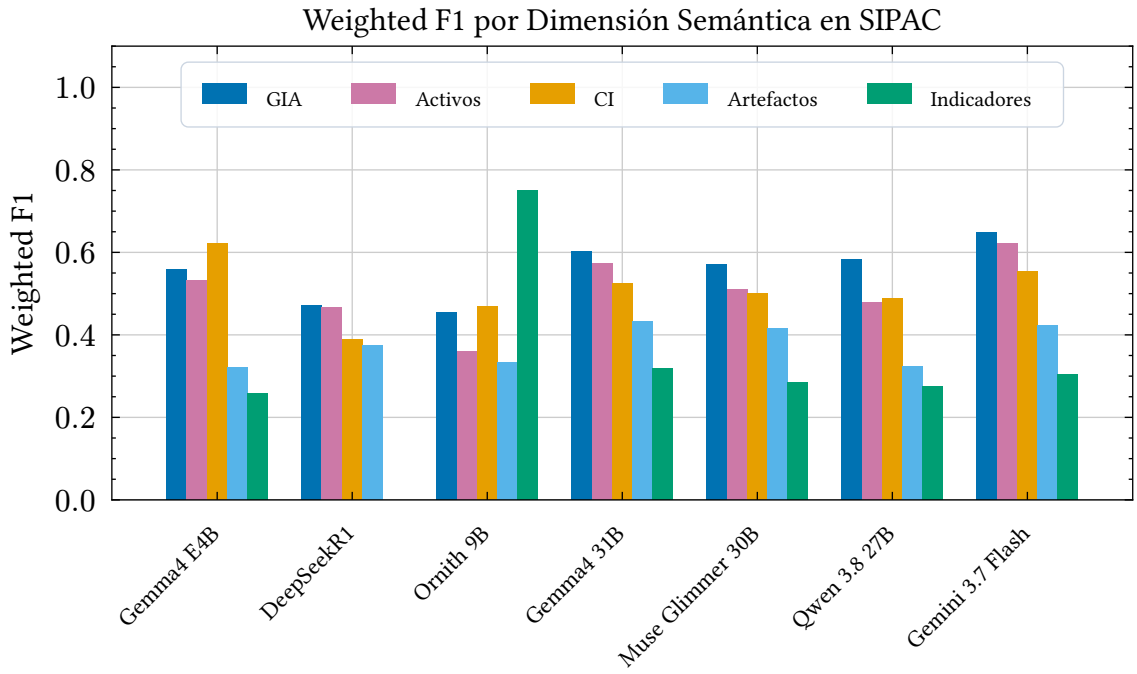


Fig. 4.4. Weighted F1 por dimensión en las fases de inferencia de SIPAC.

El análisis dimensional de la Fig. 4.4 revela un patrón claro de degradación a lo largo de la cadena de razonamiento: las fases de mayor anclaje taxonómico (**GIA**, **Activos Intangibles** y **CI**) alcanzan puntuaciones de F_1 notablemente superiores ($0.47 - 0.65$), mientras que las fases de generación abierta con vocabulario libre (**Artefactos** e **Indicadores**) presentan mayor dispersión ($F_1 \approx 0.28 - 0.43$). Asimismo, el desglose permite detectar fallos sintácticos puntuales como el sufrido por **DeepSeek R1**, cuya generación de bloques de razonamiento desestructuró el esquema JSON en la fase de indicadores ($F_1 = 0.000$). El registro cuantitativo completo de las puntuaciones caso por caso se recoge en la Tabla B.2 del Apéndice *B. Tablas Detalladas de la Evaluación Experimental*.

Para complementar la perspectiva agregada e ilustrar de forma práctica la interacción entre la deducción generativa del agente y las diferentes fases del pipeline de evaluación semántica, la Tabla 4.4 desglosa un extracto representativo del caso de prueba **G3 (Empresa C)** bajo *Teacher Forcing* con el modelo **Gemini 3.7 Flash**. En este experimento, tanto el consultor humano como el agente de IA parten de los dos activos intangibles específicos siguientes, relativos a dos procesos formalizados e identificados en el *Ground Truth*: el *Modelo de Clientes* (asociado al proceso de venta a particulares, clasificado como `GIA 2`) y el *Modelo de Marca* (asociado a la estrategia de marketing digital, clasificado como `GIA 7`).

Tabla 4.4

Comparativa de deducción de artefactos tecnológicos frente al Ground Truth y evaluación semántica en SIPAC (caso G3, Gemini 3.7 Flash).

Activo Intangible Específico	Ground Truth	Propuesta del Sistema	Asignación	Calificación
Proceso 1: Mejora de Venta a Particulares *(GIA 2: Modelo Comercial o de Clientes)*				
Modelo Clientes Capital Negocio	Página Web	Página Web transaccional para particulares	**Match 1:1**	3 / 3
	—	Manual de protocolo comercial y atención B2C	*Poda vectorial*	—
	—	Módulo ERP de gestión y stock multicanal	*Poda vectorial*	—
Proceso 2: Estrategia de Marketing Digital *(GIA 7: Modelo de Marca)*				
Modelo de Marca Capital Negocio	Redes Sociales	Canales oficiales en RRSS (Instagram/TikTok)	**Match 1:1**	3 / 3
	Marketing Digital	Sistema CRM con módulo de fidelización	**Equiv. parcial**	2 / 3
	—	Plataforma de automatización de Email Marketing	Excedente 1:1	—
	—	Repositorio digital de recursos y guía de marca	*Poda vectorial*	—

Como evidencia la Tabla 4.4, el agente logra emparejar la totalidad de los artefactos del *Ground Truth* ($\frac{3}{3}$ elementos recuperados), alcanzando un *Weighted Recall* del 88.9% (0.889) debido a la ponderación graduada de la equivalencia parcial ($\frac{2}{3}$). Además, el desglose permite apreciar cuatro patrones de comportamiento característicos del pipeline de evaluación:

En primer lugar, se registran **coincidencias exactas (Match 1:1, 3/3 pts)** por identidad funcional directa, tales como *Página Web* (sim $= 0.64$) y *Perfiles en Redes Sociales* (sim $= 0.73$). En segundo lugar, se identifica una **equivalencia funcional parcial (2/3 pts)**: frente al artefacto genérico *Marketing Digital* del *Ground Truth*, el agente dedujo un *Sistema CRM con módulo de fidelización* (sim $= 0.40$). El juez LLM estimó que, si bien un CRM trasciende la mera publicidad, cubre operativamente la captación y fidelización de clientes en una PYME de bordado, otorgando una calificación aprobada alta ($\frac{2}{3}$).

Por otro lado, emergen **propuestas excedentes evaluadas favorablemente sin plaza 1:1 (Exceso)**: iniciativas como la *Plataforma de automatización de Email Marketing* (sim $= 0.58$ con *Marketing Digital*) superaron el filtro de embeddings y recibieron una valoración positiva del juez LLM, pero no pudieron emparejarse formalmente al haber asignado ya el algoritmo Húngaro la única referencia disponible al CRM. Por último, opera la **poda vectorial previa (sim < 0.35)** sobre soluciones técnicas válidas en una PYME (como el *Módulo ERP de stock multicanal* o el *Manual de protocolo comercial*) que, al no guardar proximidad textual directa con el catálogo minimalista del consultor humano, fueron descartadas en frío por el filtro de embeddings sin ser remitidas al juez LLM (0.0).

Este desglose pone de manifiesto una limitación intrínseca de los conjuntos de datos de referencia en tareas prescriptivas abiertas: el *Ground Truth* humano, elaborado con un enfoque deliberadamente minimalista (3 artefactos básicos), resulta insuficiente para

abarcar todo el espacio de soluciones tecnológicas válidas para la organización. Como consecuencia, cuando el agente propone una arquitectura digital más completa y profunda (incorporando ERP de inventario, protocolos comerciales o automatización de marketing), el mecanismo de asignación biunívoca penaliza matemáticamente estas aportaciones como excedentes sin correspondencia ($\frac{0}{3}$). Por tanto, el *Recall* (88.9%) refleja mucho mejor el acierto real del modelo, ya que la *Precision* (22.2%) es baja simplemente porque el agente propuso más soluciones válidas de las que había anotado el consultor.

Por último, en relación con la eficiencia computacional del evaluador automatizado y la dispersión conceptual de los modelos, la Tabla 4.5 detalla la **tasa de filtrado vectorial previo** por embeddings (sim $< \tau^* = 0.35$). Cada celda cuantifica el porcentaje de descarte y el ratio exacto ($\frac{\text{pares descartados}}{\text{pares totales generados}}$) para cada fase metodológica de SIPAC. Por ejemplo, el registro de **Gemini 3.7 Flash** para el campo de **Artefactos** (68.7%, $\frac{46}{67}$) indica que de las 67 combinaciones candidatas evaluadas para el modelo, 46 fueron descartadas automáticamente por el filtro vectorial al no alcanzar la afinidad mínima con el *Ground Truth*, mientras que las 21 restantes (31.3%) superaron el umbral y fueron remitidas al juez LLM para su evaluación semántica. A nivel agregado, este mecanismo descarta en frío el 60.6% de las propuestas (754 de las 1.245 totales generadas en los tests a ciegas), ahorrando más de la mitad de llamadas a la API del juez LLM.

TABLA 4.5

TASA DE DESCARTE POR FILTRADO VECTORIAL PREVIO (sim < 0.35) POR MODELO Y FASE EN SIPAC.

Modelo	GIA	Activos Específicos	Componente CI	Artefactos	Indicadores	Poda Global
Gemma4 E4B	**20.0%**	**42.1%**	**30.0%**	**48.7%**	**68.5%**	**55.9%**
Local Ollama	(2/10)	(8/19)	(3/10)	(19/39)	(63/92)	(95/170)
DeepSeekR1	**30.8%**	**28.6%**	**0.0%**	**27.8%**	**100.0%**	**38.3%**
Local Ollama	(4/13)	(4/14)	(0/5)	(5/18)	(10/10)	(23/60)
Ornith 9B	**50.0%**	**71.8%**	**52.9%**	**76.4%**	**48.1%**	**64.3%**
Local Ollama	(11/22)	(28/39)	(9/17)	(68/89)	(26/54)	(142/221)
Gemma4 31B	**23.1%**	**56.0%**	**50.0%**	**69.6%**	**65.5%**	**62.0%**
Cloud API	(3/13)	(14/25)	(7/14)	(48/69)	(55/84)	(127/205)
Muse Glimmer 30B	**30.8%**	**63.3%**	**37.5%**	**70.8%**	**77.7%**	**70.4%**
Cloud API	(4/13)	(19/30)	(3/8)	(51/72)	(101/130)	(178/253)
Qwen 3.8 27B	**28.6%**	**62.1%**	**0.0%**	**68.2%**	**51.7%**	**53.1%**
Cloud API	(4/14)	(18/29)	(0/4)	(15/22)	(15/29)	(52/98)
Gemini 3.7 Flash	**18.2%**	**47.6%**	**30.0%**	**68.7%**	**63.7%**	**59.3%**
Cloud API	(2/11)	(10/21)	(3/10)	(46/67)	(51/80)	(112/189)
Media Global	**31.3%**	**57.1%**	**36.8%**	**67.0%**	**67.0%**	**61.0%**
	(30/96)	(101/177)	(25/68)	(252/376)	(321/479)	**729/1196**

Escala de intensidad del filtrado vectorial previo (sim < 0.35)

El análisis de la Tabla 4.5 permite extraer cuatro conclusiones fundamentales sobre el comportamiento del sistema:

En primer término, el descarte automático del 60.6% de las combinaciones sin relación (754 pares) aporta una notable **eficiencia computacional y blindaje del juez**, reduciendo a menos de la mitad el tiempo y coste de ejecución del benchmark y protegiendo al

evaluador de emparejamientos absurdos que pudieran inducir calificaciones arbitrarias o sesgos.

En segundo lugar, se constata el **impacto de la apertura léxica en la precisión**: mientras que en fases taxonómicas como **GIA** y **Capital Intelectual** la tasa de poda es reducida ($30\% - 37\%$), esta se eleva al 66.5% en **Artefactos** e **Indicadores**. Esta dispersión léxica inherente al lenguaje libre explica la contención de la *Precision* ($\mu = 36.4\%$) y reafirma al *Recall* como el indicador más representativo de la cobertura de necesidades.

Asimismo, el evaluador automatizado garantiza la **detección objetiva de alucinaciones**, identificando de forma autónoma cuándo un modelo desvía su razonamiento, como ocurrió con **DeepSeek R1** en Indicadores (100% de poda al generar nombres de software como *«Sistema deBigData»*, *«Sistema deBolt»* o *«Sistema deIA»* en lugar de métricas cuantitativas), asignando un $F_1 = 0.000$ determinista y evitando que respuestas mal estructuradas contaminen el flujo.

Por último, se ratifica el **carácter conservador del marco experimental**: calibrar el umbral en $\tau^* = 0.35$ asume el riesgo de descartar soluciones válidas si su redacción dista del vocabulario del *Ground Truth* (como el ERP del caso de estudio), garantizando que la evaluación sea deliberadamente estricta y que el desempeño real de los modelos en consultoría tienda a ser superior al reflejado por sus métricas numéricas.

4.4. Evaluación de AHP: Soporte a la Decisión y Priorización Multicriterio

En el ciclo de preproyecto de DTGEP, el proceso AHP actúa como una herramienta de toma de decisiones multicriterio (*Multi-Criteria Decision Making*, MCDM) orientada a priorizar los artefactos tecnológicos propuestos en SIPAC. A diferencia de ALTUS y SIPAC, donde existe un *Ground Truth* unívoco frente al que medir la exactitud del sistema, la selección de criterios y preferencias en AHP es inherentemente dependiente del contexto organizativo y del juicio del decisor.

El cálculo matemático de AHP (la derivación del autovalor máximo $\lambda_{\max}$, el cálculo de la Razón de Consistencia CR y la resolución del vector de prioridades $\boldsymbol{w}$) es estrictamente determinista y se ejecuta mediante el motor algorítmico independiente. En la metodología de Saaty [9], la Razón de Consistencia cuantifica si las comparaciones pareadas guardan coherencia lógica transitiva (evitando contradicciones como juzgar que $A > B$ y $B > C$, pero luego $C > A$); un umbral de $\mathrm{CR} < 0.10$ (10%) garantiza que las ponderaciones son matemáticamente fiables y no fruto del azar. En consecuencia, la evaluación de AHP se centra en auditar la **capacidad de asistencia consultiva del agente de IA**: su habilidad para formular un marco de decisión sectorial a medida y emitir juicios comparativos pareados fundamentados en la escala Saaty (1–9).

4.4.1. Diseño y Justificación de las Rúbricas de Soporte a la Decisión

Para evaluar de forma reproducible el soporte a la decisión generado por cada modelo, el evaluador inyecta al juez LLM el **dossier contextual de la organización** (el mismo informe cualitativo de la empresa derivado de las transcripciones de las entrevistas presen-

tado en la Sección *4.1. Marco y Configuración Experimental* y empleado en ALTUS), la lista de artefactos tecnológicos a priorizar procedentes de SIPAC, la propuesta estructurada de criterios con sus descripciones y las comparaciones pareadas de criterios con sus justificaciones de negocio.

La selección de las cuatro dimensiones de la rúbrica formal y su escala graduada de 0 a 3 puntos responde a fundamentos teóricos de la toma de decisiones y a requisitos de ingeniería de software en preproyecto:

1. **Justificación de la Adaptación Contextual (Relevancia):** En consultoría de transformación digital, el uso de plantillas genéricas de libro de texto (*«Coste, Calidad, Tiempo»*) ignora los dolores reales de la PYME. Esta dimensión audita si el agente digiere el contexto del caso para formular criterios adaptados a los procesos del negocio (ej. incidencias en obra o retención de clientes).
2. **Justificación de la Ortogonalidad (Axioma de Independencia de Saaty):** Un axioma central de la jerarquía AHP es que los criterios deben ser mutuamente independientes [9]. La presencia de criterios sinónimos o solapados induce una doble ponderación que distorsiona algebraicamente el vector de pesos $\boldsymbol{w}$, duplicando artificialmente el peso de una misma variable.
3. **Justificación de la Completitud Holística (Marco 360° en Economía del Software):** Toda decisión estratégica en preproyecto debe balancear la triple hélice de inversión tecnológica: valor/impacto de negocio, esfuerzo/coste y viabilidad/adopción organizativa. Omitir una de estas facetas (como la curva de aprendizaje de los operarios) conduce frecuentemente al fracaso de implantación.
4. **Justificación de la Racionalidad y Capacidad Comparativa (XAI y Juicio Pareado):** En preproyecto, el decisor humano no aceptará un orden de prioridades si opera como una caja negra. Esta dimensión evalúa la capacidad del sistema para confrontar dos opciones en conflicto (*trade-off*), calibrar la intensidad del juicio en la escala Saaty (1–9) y fundamentar el coste de oportunidad de la preferencia elegida.

El detalle cualitativo de los cuatro niveles por dimensión se resume en la Tabla 4.6:

Tabla 4.6

Rúbrica de evaluación del soporte a la decisión en AHP.

Dimensión	Pts	Criterio Cualitativo del Juez LLM
Adaptación Contextual (Relevancia)	0	Criterios genéricos de plantilla, ajenos a la realidad de la empresa.
	1	Criterios estándar aplicables a cualquier negocio, sin personalización a los procesos del caso.
	2	Criterios adaptados al sector y tipología de la PYME (ej. construcción, comercio textil, retail).
	3	Criterios hiper-específicos que capturan con precisión los dolores, restricciones y metas del caso.
Ortogonalidad (No Solapamiento)	0	Criterios redundantes o sinónimos directos que duplican la ponderación de una variable.
	1	Fuerte solapamiento conceptual entre criterios (miden facetas muy próximas).
	2	Criterios conceptualmente diferenciados con leve intersección de ámbito.
	3	Criterios estrictamente independientes (ej. Valor de Negocio vs. Coste vs. Adopción vs. Plazos).
Completitud Holística (Cobertura)	0	Omisión de dimensiones críticas evidentes (ej. evaluar coste ignorando impacto y viabilidad).
	1	Perspectiva sesgada hacia un único ángulo dominante (ej. puramente financiero o técnico).
	2	Cubre las facetas principales pero omite dimensiones relevantes como riesgo o adopción.
	3	Cobertura equilibrada y holística de valor estratégico, esfuerzo/coste, viabilidad y adopción.
Racionalidad de Justificación (Juicio Pareado)	0	Sin justificaciones o basadas en tautologías vacías («A es mejor que B porque es preferible»).
	1	Justificaciones vagas o genéricas sin anclaje en el contexto de la organización.
	2	Justificaciones lógicas y coherentes basadas en el funcionamiento general del sector.
	3	Argumentación estratégica profunda que fundamenta la intensidad Saaty según los datos del caso.

4.4.2. Resultados Empíricos en AHP

A continuación se analizan los resultados obtenidos por los siete modelos de lenguaje en la formulación de criterios y el juicio pareado para la priorización multicriterio en AHP.

La Fig. 4.5 resume el desempeño mediante un diagrama de barras apiladas, donde la altura total representa la puntuación acumulada media (hasta un máximo de 12 puntos o 100% normalizado) y los segmentos interiores desglosan la aportación de cada una de las cuatro dimensiones de la rúbrica.

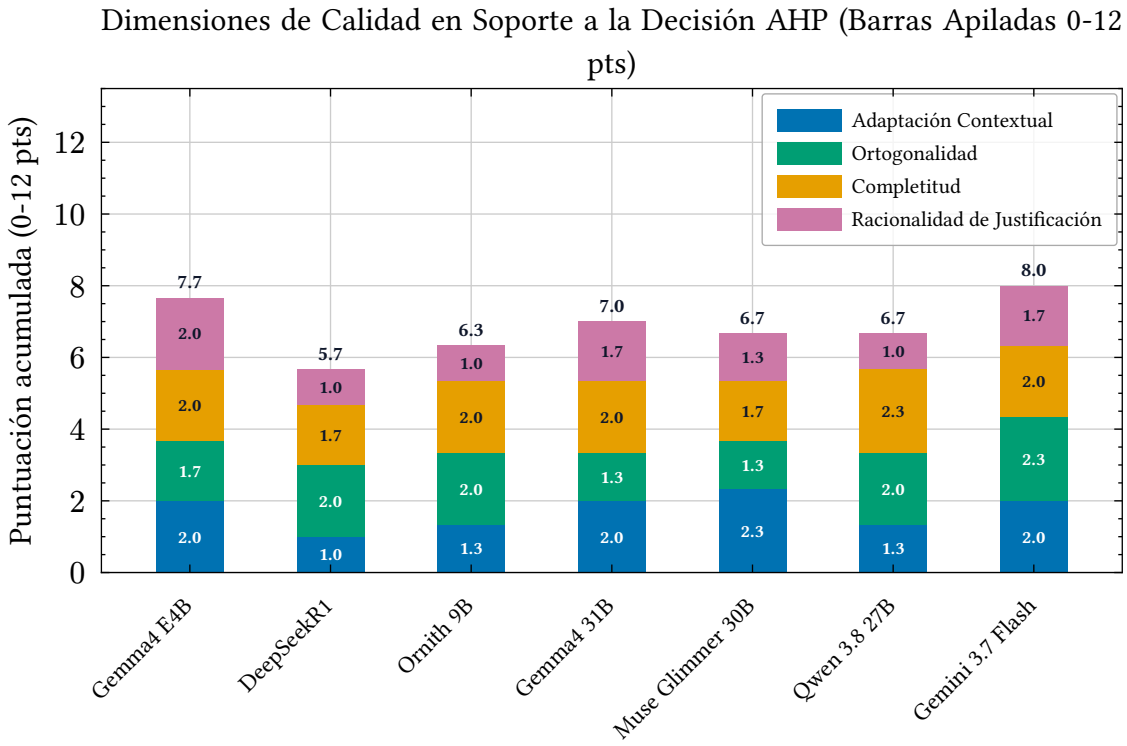


Fig. 4.5. Puntuación acumulada y desglose dimensional de calidad en AHP.

Los resultados confirman que modelos como **Gemini 3.7 Flash** y **Gemma 4 E4B** obtienen las puntuaciones más equilibradas, situándose entre el 64% y el 67% de la escala normalizada (7.67 y 8.00 sobre 12 puntos).

El desglose dimensional revela dos patrones de comportamiento determinantes. En primer lugar, respecto a la **calibración de la intensidad Saaty y la coherencia del juicio**, esta dimensión audita si el valor numérico asignado en la escala Saaty (1 a 9) refleja con fidelidad la magnitud real de las prioridades del negocio. Modelos como **DeepSeek R1** y **Ornith 9B** obtienen puntuaciones bajas ($\frac{1.00}{3}$) por emitir juicios tímidos o esquemáticos, tratando como comparativas casi igualadas (1 o 2) diferencias que en el caso son críticas. Por el contrario, **Gemini 3.7 Flash** y **Gemma 4 E4B** calibran la intensidad matemática adecuada a cada escenario, justificando con datos del caso por qué un criterio debe dominar con fuerza sobre otro (como primar de forma contundente los plazos frente al coste ante el riesgo de penalizaciones de obra).

En segundo lugar, se manifiesta un claro compromiso (**trade-off**) entre la **adaptación contextual y la ortogonalidad** de los criterios: modelos como **Muse Glimmer 30B** destacan en adaptar los criterios a la realidad del negocio ($\frac{2.33}{3}$ en Adaptación), pero a costa de introducir cierto solapamiento conceptual entre ellos ($\frac{1.33}{3}$ en Ortogonalidad). Por el contrario, **Qwen 3.8 27B** y **DeepSeek R1** garantizan criterios estrictamente independientes ($\frac{2.00}{3}$), recurriendo para ello a categorías más estándar y menos personalizadas al caso.

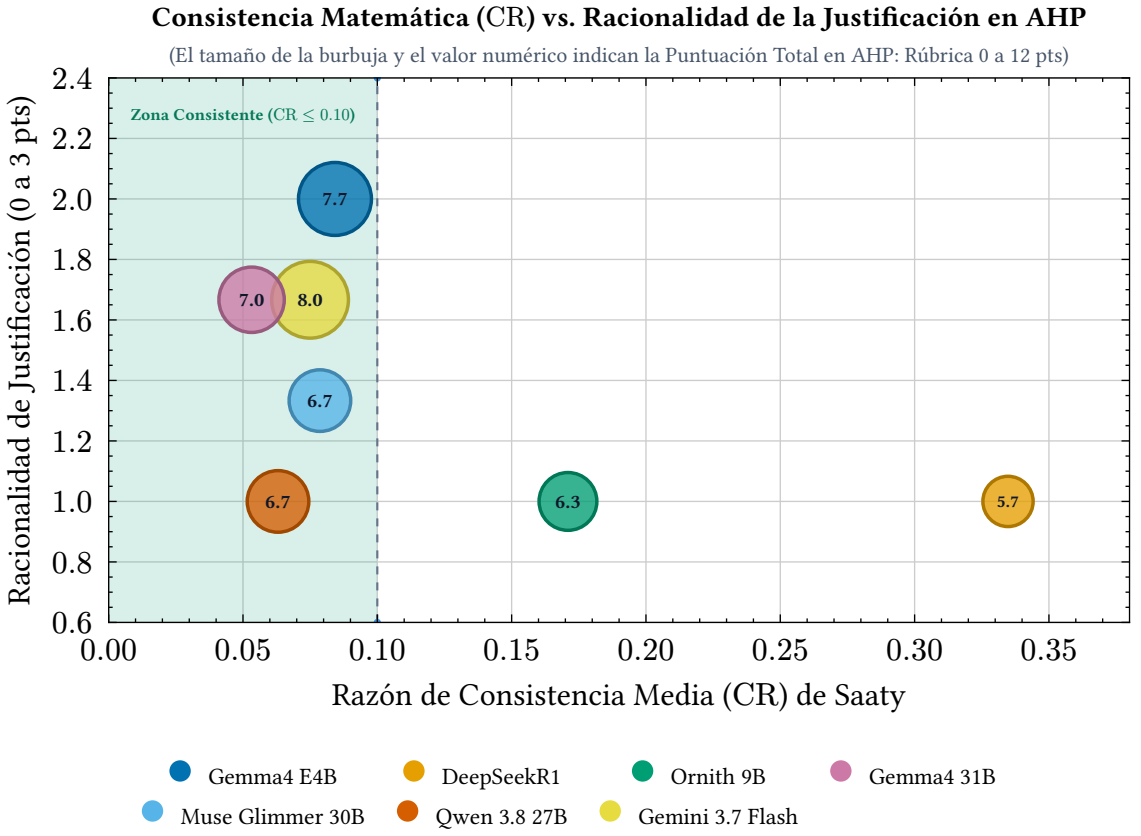


Fig. 4.6. Razón de Consistencia (CR) frente a solidez del juicio pareado en AHP.

Para profundizar en la relación entre el rigor deductivo y la corrección algebraica, la Fig. 4.6 cruza la solidez del juicio pareado con la Razón de Consistencia (CR) resultante. Como se aprecia en la distribución, existe una clara correlación empírica entre ambas variables: los modelos con mayor capacidad de contextualización (**Gemini 3.7 Flash**, **Gemma 4 E4B** y **Gemma 4 31B**) se sitúan holgadamente dentro de la zona de consistencia matemática, con valores medios de CR entre 0.053 y 0.084 (por debajo del límite de 0.10), demostrando que un razonamiento guiado por las necesidades reales de la empresa conduce de forma natural a comparaciones coherentes. Por el contrario, los modelos que emitieron explicaciones superficiales o genéricas (**Ornith 9B** con $CR = 0.171$ y **DeepSeek R1** con $CR = 0.335$) cayeron en contradicciones lógicas al comparar los criterios entre sí, superando el umbral de inconsistencia de Saaty. El registro numérico desagregado caso por caso se detalla en la Tabla B.3 del Apéndice *B. Tablas Detalladas de la Evaluación Experimental*.

4.5. Viabilidad Operativa y Rendimiento Temporal

Tras haber auditado de forma independiente la solvencia cognitiva del motor agéntico en las tres metodologías que componen AI-Driven DTGEP, resulta fundamental evaluar su viabilidad operativa en entornos profesionales reales. En el contexto de la consultoría de ingeniería de software, un sistema de preproyecto no solo debe garantizar rigor metodológico y consistencia algorítmica, sino también ofrecer tiempos de respuesta computacionalmente asumibles y adaptarse a las restricciones de infraestructura y privacidad de cada organización.

A este respecto, es imprescindible puntualizar la naturaleza de las métricas temporales recogidas en el benchmark: los datos reportados cuantifican estrictamente el **tiempo de cómputo neto del sistema** (el tiempo de inferencia de los modelos de lenguaje, el avance por los estados del grafo en LangGraph y la ejecución de las tuberías matemáticas deterministas). Al realizarse la evaluación experimental mediante un simulador sintético (*Stakeholder LLM*) que emite sus respuestas de forma prácticamente instantánea, estas cifras no reflejan la duración cronológica global que conllevaría una entrevista con un interlocutor humano real, quien naturalmente requiere pausas para leer, reflexionar, consultar documentación interna o responder a lo largo de su jornada laboral. Por tanto, el valor de estas mediciones reside en caracterizar el esfuerzo computacional, el coste de infraestructura y la latencia técnica del motor agéntico, la cual habilita un modelo asíncrono donde el usuario responde a su propio ritmo sin consumir tiempo síncrono del ingeniero.

4.5.1. Análisis Comparativo de Entornos de Despliegue

Los resultados del benchmark reflejan una clara diferenciación operativa según el entorno de inferencia seleccionado.

Bajo la modalidad de **inferencia remota en la nube (Cloud API)**, los modelos de gran escala y frontera (**Gemini 3.7 Flash**, **Gemma 4 31B**, **Muse Glimmer 30B** y **Qwen 3.8 27B**) completan el ciclo íntegro de preproyecto por empresa en un rango de 23 a 100 minutos de cómputo neto. En este grupo, **Gemma 4 31B** destaca por su extraordinaria eficiencia temporal, resolviendo la totalidad de las tres metodologías en apenas 23.3 minutos de tiempo de máquina por caso manteniendo un desempeño semántico y de decisión equivalente al de modelos de frontera. Estos tiempos confirman la viabilidad del motor agéntico para sesiones consultivas ágiles o evaluaciones automatizadas bajo demanda, validando asimismo que las arquitecturas abiertas de 27B–31B representan una alternativa idónea para empresas que opten por autoalojar el servicio en servidores locales dedicados provistos de $24 - 32$ GB de VRAM.

Por su parte, en escenarios de **inferencia local en hardware de consumo** orientados a organizaciones con soberanía de datos estricta y sin infraestructura dedicada, la Fig. 4.7 detalla el tiempo de ejecución acumulado y desglosado por metodología para los tres modelos evaluados en la estación de trabajo de referencia del estudio (MacBook Air M4 con 16 GB de memoria unificada):

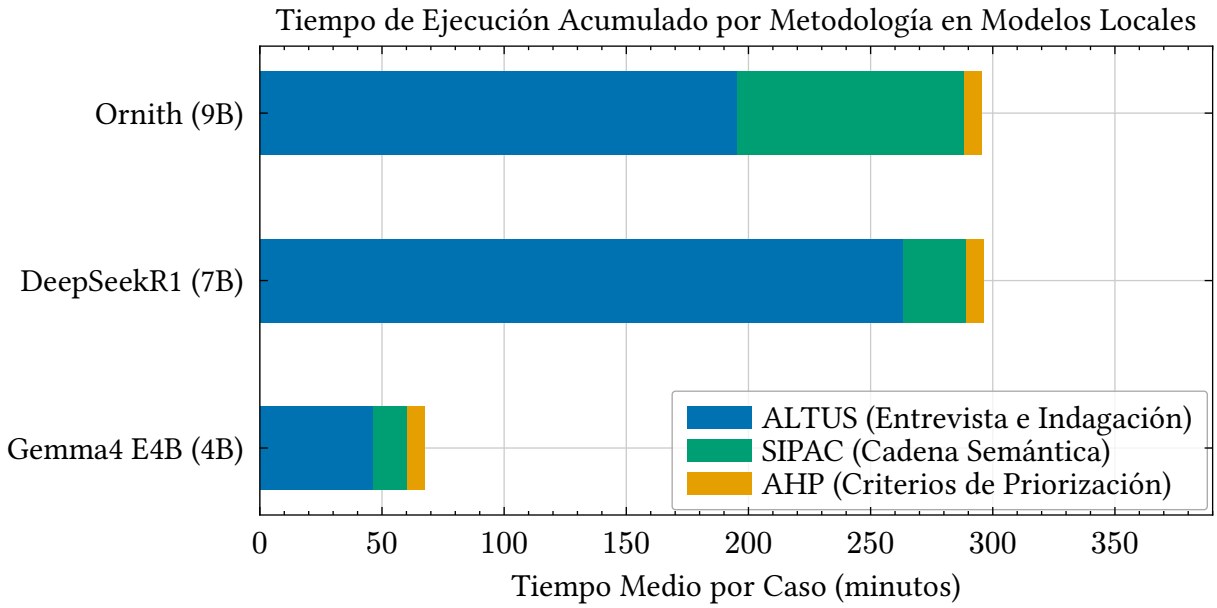


Fig. 4.7. Tiempo de ejecución acumulado por metodología en inferencia local.

4.5.2. Cuello de Botella en Memoria y Recomendaciones de Despliegue

El perfil de ejecución de la Fig. 4.7 pone de manifiesto dos fenómenos críticos en inferencia local.

Por un lado, se observa una clara **dominancia de la fase de indagación en ALTUS**, donde la entrevista de madurez concentra más del 70% del tiempo total de cómputo en todos los modelos locales (llegando a representar 212 de los 300 minutos totales en **DeepSeek R1**). Este comportamiento contrasta con SIPAC y AHP, cuyas fases de inferencia semántica y cálculo matricial se resuelven de forma mucho más ágil (20 — 45 minutos por fase).

Por otro lado, se identifica un severo problema de **saturación de memoria unificada y degradación por swap**: mientras que el modelo compacto **Gemma 4 E4B** (4B) se ejecuta con total soltura en 67.7 minutos totales, las arquitecturas de 7B (**DeepSeek R1**) y 9B (**Ornith**) multiplican por cinco la latencia, alcanzando las 5 horas de ejecución. La causa raíz técnica no reside en la complejidad algorítmica de DTGEP, sino en la acumulación de contexto: la evaluación secuencial de las 51 capacidades de ALTUS retiene un extenso historial conversacional. Al coexistir en los 16 GB de memoria unificada del equipo el modelo, los *KV caches* y el sistema operativo, los modelos $\geq$ 7B agotan la RAM disponible y fuerzan un desbordamiento continuo a memoria secundaria (*swap* en disco), penalizando drásticamente la tasa de generación de tokens.

A partir de estos hallazgos, se derivan tres directrices clave de despliegue para la práctica industrial: Para un **despliegue local ligero en equipos de 16 GB RAM**, la arquitectura compacta **Gemma 4 E4B** (4B) constituye la opción recomendada al conjugar privacidad total, rigor metodológico (MAE $= 1.18$ y consistencia CR $= 0.053$) y una ejecución fluida en poco más de una hora. Para un **despliegue local de alta capacidad (On-Premise con 24–32 GB VRAM)** en organizaciones que no puedan compartir datos

en la nube y requieran la máxima profundidad prescriptiva, se recomienda desplegar modelos de 27B–31B (como **Gemma 4 31B** o **Qwen 3.8 27B**) en servidores locales con GPUs dedicadas. Finalmente, para un **despliegue en la nube (SaaS / API)** en escenarios estándar sin restricciones de confidencialidad externa, el uso de APIs de frontera (**Gemini 3.7 Flash** o **Gemma 4 31B**) maximiza la calidad analítica y reduce la latencia a escala de minutos.

El registro cuantitativo completo y desglosado caso por caso de todas las métricas predictivas, semánticas y temporales se encuentra disponible para consulta en el Apéndice *B. Tablas Detalladas de la Evaluación Experimental*.

4.6. Contraste de Paradigmas: AI-Driven DTGEP frente a la Inferencia Directa con LLMs

La evaluación empírica precedente ha examinado el comportamiento del motor AI-Driven DTGEP integrando diversas arquitecturas de lenguaje. Sin embargo, desde los principios de la Economía de la Ingeniería de Software ([7]), surge una cuestión metodológica fundamental: **¿cuál es el valor diferencial que aporta una arquitectura agéntica basada en grafos de estado y metodologías formales frente al uso directo de un modelo fundacional de frontera mediante ingeniería de prompts avanzada?**

Para responder a esta pregunta de forma reproducible y objetiva, se implementó un banco de pruebas experimental de referencia (`run_baseline.ts`). Este entorno de evaluación suministra al modelo de frontera (**Gemini 3.7 Flash**, $T = 0.0$) el dossier íntegro de la empresa sin estructuración metodológica previa. Mediante un prompt de rol de consultor experto con razonamiento paso a paso (*Chain-of-Thought*), se le encomienda generar directamente las cuatro entregas clave de preproyecto: diagnóstico de madurez, catálogo de soluciones tecnológicas con KPIs, marco de criterios de decisión y priorización estratégica justificada.

Cabe destacar que la naturaleza narrativa y no tipada de la respuesta generada directamente por el LLM en Markdown impide someterla a métricas algebraicas deterministas (como el cálculo formal del autovector $\boldsymbol{w}$ o la verificación estricta de $\mathrm{CR} < 0.10$ en AHP, o la proyección en matrices 2×2 en SIPAC). Por tanto, la evaluación se instrumenta mediante un contraste cualitativo y de ingeniería de las salidas literales producidas para el caso representativo **Empresa C** (G3). La Tabla 4.7 sintetiza y enfrenta los entregables resultantes bajo ambos paradigmas.

Tabla 4.7
Comparativa de entregables entre Línea Base y AI-Driven DTGEP (caso G3).

Entrega de Preproyecto (DTGEP)	Línea Base (LLM Directo - Gemini 3.7 Flash)	AI-Driven DTGEP (Sistema Propuesto)
1. Diagnóstico de Madurez Digital (*DTGEP1 / ALTUS*)	Evaluación *ad-hoc* sobre 4 áreas no normalizadas: • Ventas: Nivel 1.0 (Manual) • Repositorio Picajes: Nivel 2.0 (OneDrive) • Conocimiento Técnico: Nivel 1.0 (Tácito) • B2B y PRL: Nivel 1.0 (Fragmentado) *(Extrapola supuestos no confirmados del dossier).*	Diagnóstico determinista de 12 capacidades de capital intelectual en escala formal 1–5: • 8 capacidades en Nivel 1 (Inicial) • 4 capacidades en Nivel 2 (Básico) *(Genera radar y diálogo interactivo de repreguntas).*
2. Catálogo de Soluciones y Artefactos (*DTGEP2 / SIPAC*)	Solucionismo comercial prescribiendo productos SaaS cerrados: • Shopify / WooCommerce + Zakeke (Canal B2C) • Airtable / Baserow (DAM de picajes) • Notion / BookStack (Wiki técnica de taller) • Trengo / HubSpot Service Hub (CRM B2B)	4 especificaciones funcionales neutrales trazadas a intangibles: • Portal e-commerce con configurador (`GIA 2`) • Repositorio DAM indexado de diseños (`GIA 10`) • Base de conocimiento de tejidos y taller (`GIA 11`) • Módulo CRM corporativo (`GIA 7`)
3. Marco de Criterios de Decisión (*DTGEP3 / AHP*)	4 criterios narrativos con pesos porcentuales fijos a priori: • Impacto en Negocio (35%) • Coste / Esfuerzo TCO (25%) • Viabilidad Técnica (20%) • Adopción Organizativa (20%)	Marco de criterios ortogonales sectoriales: • Reducción de tiempo de atención • Fidelización y valor de marca • Coste de implantación y Viabilidad *(Calibra juicios pareados en escala Saaty 1–9).*
4. Priorización y Hoja de Ruta (*DTGEP4 / AHP*)	Cronograma en 3 fases por suma lineal simple (WSM): • Fase 1 (Meses 1-3): DAM + Wiki • Fase 2 (Meses 4-6): E-commerce B2C • Fase 3 (Meses 7-8): Hub CRM B2B *(Sin verificación de coherencia ni autovalores).*	Vector cuantitativo de prioridades $\boldsymbol{w}$ resuelto por AHP: • 1º Portal E-commerce ($w = 0.41$) • 2º Repositorio DAM ($w = 0.28$) • 3º Módulo CRM ($w = 0.18$) • 4º Base Conocimiento ($w = 0.13$) *(Consistencia auditada:* $\mathrm{CR} = 0.04 < 0.10$*).*

A partir de la evidencia empírica recogida en la Tabla 4.7, el análisis comparativo permite extraer conclusiones claras sobre las divergencias metodológicas que separan ambos enfoques, estructuradas en cuatro dimensiones esenciales:

En primer lugar, respecto al diagnóstico de madurez digital en ALTUS, la inferencia directa se comporta como un receptor pasivo. Cuando el modelo se enfrenta a lagunas de información en el dossier inicial, tiende a asumir premisas no declaradas e inventa puntuaciones arbitrarias para completar el informe sin verificar la realidad operativa. En contraste, AI-Driven DTGEP monitoriza continuamente el nivel de evidencia fáctica disponible y articula un diálogo adaptativo con repreguntas orientadas a recabar evidencias concretas. Esto garantiza que la evaluación se fundamente en hechos contrastados y se normalice con rigor sobre las doce capacidades de capital intelectual del modelo.

En segundo término, en la fase de deducción de soluciones mediante SIPAC, la generación directa incurre sistemáticamente en un solucionismo tecnológico prematuro, saltando de los problemas identificados a la prescripción inmediata de herramientas SaaS comerciales cerradas (como Shopify, Airtable, Notion o HubSpot). En la fase de preproyecto ([7]), este planteamiento introduce un acoplamiento temprano e injustificado a proveedores externos antes de haber formalizado los requisitos funcionales del sistema. Por el contrario, el motor de SIPAC [11] formula especificaciones funcionales neutrales e independientes de la tecnología comercial, guiando la prescripción a través de la cadena causal del Modelo Intellectus (desde los procesos de negocio hacia las áreas de interés, los activos intangibles y, finalmente, los artefactos tecnológicos). De este modo, se asegura que las iniciativas propuestas potencien el capital intelectual y la ventaja competitiva real de la organización.

En tercer lugar, en lo relativo a la priorización multicriterio en AHP, el enfoque basado en inferencia directa asigna ponderaciones porcentuales arbitrarias a priori y evalúa las alternativas mediante modelos de suma lineal ponderada. Este proceder vulnera el axioma de independencia y ortogonalidad de Saaty [9] —al solapar conceptos como el impacto operativo y el retorno de la inversión— y carece de mecanismos para auditar la coherencia interna de los juicios. En cambio, AI-Driven DTGEP define un conjunto de criterios ortogonales y fundamenta las comparaciones pareadas en la escala Saaty de 1 a 9, explicitando las relaciones de compromiso (*trade-offs*) y el coste de oportunidad intrínseco a cada decisión estratégica.

Por último, en lo concerniente a la formalización y gobernanza de los entregables, la inferencia directa se limita a producir un cronograma heurístico y un documento narrativo en Markdown que resulta legible para un usuario humano, pero inviable para su procesamiento automatizado o auditoría matemática. Frente a esta debilidad, la arquitectura agéntica propuesta calcula algebraicamente el autovector principal de prioridades $\boldsymbol{w}$, verifica formalmente que la Razón de Consistencia satisfaga el umbral axiomático de Saaty ($\mathrm{CR} < 0.10$, alcanzando un valor de $\mathrm{CR} = 0.04$ en el caso de estudio) y persiste el estado completo del preproyecto en un grafo tipado y validado mediante esquemas JSON, lo que permite su exportación directa a motores BPMN, bases de datos o cuadros de mando corporativos.

En síntesis, este contraste empírico demuestra que la inferencia generativa directa con modelos fundacionales, pese a ofrecer una redacción superficialmente persuasiva, carece de los mecanismos de control, reproducibilidad y rigor analítico indispensables en la ingeniería del software. El valor fundamental de AI-Driven DTGEP radica en gobernar la estocasticidad propia de los modelos de lenguaje mediante marcos metodológicos y estructuras de control formales, transformando la inferencia generativa en un proceso de toma de decisiones trazable, determinista y orientado a maximizar el valor del software.

4.7. Validez y Limitaciones del Estudio Experimental

Con el propósito de contextualizar el alcance de los hallazgos y delimitar las condiciones de reproducibilidad del estudio, a continuación se analizan los factores de validez y las limitaciones metodológicas conforme a la taxonomía estándar en Ingeniería del Software empírica [39]:

4.7.1. Validez de Constructo

La validez de constructo examina en qué medida los instrumentos y procedimientos de evaluación implementados reflejan fielmente las capacidades cognitivas objeto de estudio.

En primer lugar, la auditoría de dimensiones semánticas abiertas en SIPAC y AHP se apoya en el modelo de frontera GPT-5.6 Luna mediante rúbricas formales ($0 - 3$ puntos). Aunque este enfoque constituye el estándar actual en la evaluación de agentes de IA [37], introduce una potencial dependencia de los sesgos internos del evaluador. Para mitigar esta limitación, aquellas facetas con fundamentación formal y cuantitativa se auditan mediante métricas deterministas desacopladas de cualquier juez sintético: por un lado, la calificación ordinal de las 51 capacidades en ALTUS ($0 - 5$) a través de métricas continuas exactas (*Accuracy* y *MAE*); por otro, la coherencia lógica de las comparaciones pareadas en AHP mediante la Razón de Consistencia ($\mathrm{CR} < 0.10$), resuelta de forma estrictamente algebraica a partir del autovalor principal $\lambda_{\max}$ de la matriz de Saaty [9].

Asimismo, la naturaleza del *Ground Truth* humano de referencia introduce una asimetría metodológica. Al haber sido generado por consultores junior en formación (estudiantes de último curso de Grado), su catálogo de artefactos tecnológicos en SIPAC adoptó un enfoque deliberadamente minimalista (3 elementos básicos). Cuando el agente de IA propone una arquitectura digital más exhaustiva y válida para el negocio, el mecanismo de asignación biunívoca penaliza matemáticamente la precisión calculada al computar dichas propuestas como excedentes.

Por último, el filtrado semántico previo por *embeddings* calibrado en $\tau^* = 0.35$ persigue optimizar la eficiencia computacional y blindar al juez LLM de emparejamientos espurios. No obstante, este filtro asume el riesgo de descartar soluciones válidas cuya redacción diste del vocabulario específico del consultor humano, otorgando al benchmark un carácter deliberadamente conservador.

4.7.2. Validez Interna

La validez interna analiza si las relaciones observadas y el rendimiento de los modelos se deben a sus capacidades deductivas intrínsecas o si han podido verse condicionados por factores de confusión no controlados en el entorno de ejecución.

Por un lado, a pesar de fijar la temperatura de inferencia en 0.0, los modelos de lenguaje pueden exhibir ligeras variaciones estocásticas derivadas de paralelismo interno y precisión numérica en punto flotante. Para neutralizar contingencias sintácticas accidentales ajenas al razonamiento del modelo, la infraestructura evaluadora implementa una política de reintentos adaptativos con auto-corrección guiada (*Adaptive Temperature Backoff* hasta 0.4).

Por otro lado, la evaluación del pipeline de SIPAC se ejecuta aislando cada fase mediante *Teacher Forcing*, suministrando al inicio de cada nodo los datos correctos del *Ground Truth* del paso previo. Este desacoplamiento metodológico previene la propagación de fallos tempranos en cascada y garantiza que las métricas reflejen con exactitud la competencia deductiva intrínseca y la cota superior de desempeño de cada etapa del grafo, quedando para trabajos futuros la evaluación del pipeline en ejecuciones completas de extremo a extremo sin asistencia intermedia.

4.7.3. Validez Externa

La validez externa aborda el grado en que los hallazgos empíricos pueden generalizarse a otros contextos industriales y organizativos del sector del software.

A este respecto, el conjunto de evaluación comprende cuatro organizaciones reales completas (un caso piloto de desarrollo y tres casos de test a ciegas) respaldadas por grabaciones de campo y documentación exhaustiva. Si bien cuatro casos no permiten realizar análisis estadísticos a gran escala, aportan un alto valor práctico al basar el estudio en problemas empresariales auténticos frente a escenarios sintéticos o simulados.

No obstante, las empresas evaluadas corresponden íntegramente a microempresas y PYMEs del sector servicios caracterizadas por una baja madurez tecnológica previa (predominio de calificaciones 0 y 1 en ALTUS). Por consiguiente, la generalización de las dinámicas conversacionales y de priorización a grandes corporaciones o entornos con alta madurez estructural previa (calificaciones 4 y 5) debe ser contrastada en futuros estudios.

4.7.4. Validez de Conclusión

La validez de conclusión se centra en comprobar que las comparativas y conclusiones extraídas a partir de los datos sean fiables, reproducibles y metodológicamente sólidas.

Para asegurar la repetibilidad del estudio, todo el banco de pruebas está automatizado mediante scripts que guardan el estado y las conversaciones en esquemas JSON estructurados. Esto garantiza que todos los modelos se hayan probado exactamente en las mismas condiciones y sin variabilidad manual.

Asimismo, al tratarse de un estudio basado en cuatro casos reales analizados en profundidad, el objetivo no es realizar un análisis estadístico a gran escala, sino comparar de forma directa y detallada el rendimiento de cada modelo en cada fase (mediante métricas como el MAE, el *Weighted F1* y la Razón de Consistencia). Esto permite identificar con claridad las fortalezas y puntos débiles de cada arquitectura en tareas de consultoría real.

Por último, los tiempos de ejecución medidos cuantifican exclusivamente el esfuerzo computacional y de inferencia del sistema bajo respuestas sintéticas instantáneas, sin incorporar los tiempos de respuesta y reflexión de un entrevistado humano real. Asimismo, las mediciones en hardware local pueden fluctuar ligeramente por factores del entorno físico (como la temperatura del procesador o la gestión de memoria del sistema operativo). Por ello, las conclusiones sobre la calidad del sistema se sustentan primordialmente en las métricas de acierto semántico y consistencia matemática, empleando las métricas temporales como una cota de referencia para el dimensionamiento de infraestructura y la viabilidad técnica del despliegue.

CAPÍTULO 5

CONCLUSIONES Y TRABAJO FUTURO

En este capítulo final se sintetizan los principales resultados obtenidos en la investigación, evaluando el grado de cumplimiento de los objetivos establecidos al inicio del proyecto. Asimismo, se consolidan las contribuciones teóricas, arquitectónicas y tecnológicas aportadas a la disciplina de la Economía de la Ingeniería de Software, se exponen las lecciones aprendidas sobre la gobernanza de modelos de lenguaje y se definen las líneas prioritarias de trabajo futuro.

5.1. Síntesis del Trabajo y Grado de Cumplimiento de Objetivos

El presente trabajo de fin de máster nació con la motivación de abordar una deficiencia estructural en la fase de preproyecto de transformación digital: la omisión sistemática o simplificación de la economía de la ingeniería del software debido al elevado coste temporal y humano que exige recopilar información cualitativa de la organización. A la luz de la evidencia experimental recopilada en el Capítulo *4. Marco y Resultados de la Evaluación Experimental*, la **hipótesis de trabajo** formulada en la Capítulo *1. Introducción* queda formalmente confirmada: el diseño e integración de una metodología de toma de decisiones asistida por IA agéntica permite automatizar la elicitación cualitativa preservando el rigor analítico y la consistencia matemática de los modelos formales de decisión, reduciendo drásticamente el tiempo de dedicación directa del ingeniero y habilitando su adopción con bajos requerimientos computacionales.

Respecto al **Objetivo General**, se ha formalizado, desarrollado y evaluado con éxito una metodología y plataforma para la integración de agentes generativos en la toma de decisiones en preproyecto, demostrando la viabilidad de automatizar la fase de elicitación del *Engineering Decision-Making Process* [7]. La solución implementada reduce drásticamente las barreras operativas al sustituir las tradicionales entrevistas presenciales y síncronas por un proceso conversacional asíncrono y desatendido cuyo **tiempo neto de cómputo oscila entre 23 y 67 minutos por empresa**. Frente a la consultoría tradicional —que exige la

presencia obligatoria del ingeniero durante toda la entrevista de campo (con grabaciones de audio que superan la hora por empresa en el material de origen) más el posterior volcado y cálculo manual—, la solución propuesta **elimina la necesidad de que el ingeniero esté presente durante la recolección de datos**. El cliente interactúa a su propio ritmo con el agente y los algoritmos procesan los resultados de manera inmediata, limitando la intervención profesional a una **auditoría diferida de los borradores estructurados** y manteniendo intacto el rigor analítico y la consistencia matemática de los modelos de decisión.

A continuación, se detalla el grado de consecución de los cuatro objetivos específicos planteados:

1. **Objetivo Específico 1 (Verificación de la calidad de recolección cualitativa):** Mediante los tests a ciegas sobre empresas reales frente al *Ground Truth* humano y arbitraje con **LLM-as-a-Judge**, se ha comprobado la calidad dialéctica del agente, alcanzando una tasa de acierto superior al 80% en la indagación y un error medio MAE entre 0.81 y 1.18 en ALTUS, demostrando una recolección cualitativa equivalente a la de un consultor experto.
2. **Objetivo Específico 2 (Validación de la integración de los procesos de decisión):** Se ha validado que la información recopilada de forma desatendida alimenta con éxito los tres métodos de decisión, permitiendo diagnosticar la madurez digital (ALTUS), deducir con un Recall del 88.9% los artefactos tecnológicos clave (SIPAC) y resolver algebraicamente el vector de prioridades con estricta consistencia axiomática ($CR < 0.10$, con valores entre 0.04 y 0.08 en AHP).
3. **Objetivo Específico 3 (Democratización, transparencia y auditabilidad asíncrona):** El modelo desacoplado y asíncrono democratiza el acceso a la toma de decisiones al eliminar la necesidad de presencia del ingeniero en la toma de datos. La información generada se estructura en esquemas JSON tipados y trazables que habilitan tanto la auditoría diferida por expertos humanos como su procesamiento directo por algoritmos deterministas.
4. **Objetivo Específico 4 (Flexibilidad y extensibilidad arquitectónica):** Se ha confirmado la genericidad del motor de educción agéntica en LangGraph, el cual opera como un intérprete declarativo guiado por contratos JSON de configuración. Esta arquitectura desacopla el ciclo conversacional de las metodologías concretas, permitiendo incorporar nuevos marcos de análisis o decisión sin alterar el núcleo del software.

5.2. Contribuciones Principales

Las aportaciones científicas y tecnológicas derivadas de este trabajo se articulan en cuatro dimensiones:

En primer lugar, respecto a la **contribución metodológica (AI-Driven DTGEP)**, se ha formalizado una evolución del marco DTGEP [4] que integra de manera sistemática la Inteligencia Artificial agéntica en el ciclo de decisiones de preproyecto del SWEBOK

[7]. Este enfoque resuelve la brecha histórica entre los marcos teóricos de decisión y su aplicabilidad práctica en pequeñas y medianas empresas.

En segundo lugar, en la **contribución arquitectónica (motor declarativo ReAct en LangGraph)**, se ha diseñado una arquitectura agéntica desacoplada que orquesta el ciclo de entrevista mediante máquinas de estados. El diseño incorpora una gestión de memoria jerárquica a dos niveles para eludir redundancias, guardas deterministas de parada que acotan la duración de las interacciones y sub-bucles de validación con reintentos guiados que aseguran salidas estructuradas estrictamente tipadas.

En tercer lugar, como **contribución experimental (estudio empírico y benchmark reproducible)**, se ha diseñado y ejecutado una evaluación exhaustiva sobre cuatro organizaciones reales para contrastar el desempeño de siete arquitecturas de modelos de lenguaje (tanto locales como en la nube) en las tres metodologías de preproyecto. Este estudio establece un marco de evaluación multidimensional que audita la capacidad conversacional y diagnóstica en ALTUS, la recuperación semántica de soluciones en SIPAC y la consistencia matemática en AHP, demostrando empíricamente la superioridad del enfoque agéntico estructurado frente a la inferencia directa con LLMs y caracterizando la viabilidad operativa y los requerimientos de computación de cada arquitectura.

Finalmente, en la **contribución tecnológica y de herramienta software**, se ha implementado una plataforma web monorepo en Next.js 16 que unifica el motor agéntico y los módulos algorítmicos en un entorno TypeScript homogéneo. La herramienta ofrece comunicación reactiva en tiempo real mediante Server-Sent Events (SSE), visualización dinámica del grafo de estados en React Flow y un módulo de trazabilidad propio integrado sobre los callbacks de ejecución.

5.3. Lecciones Aprendidas e Implicaciones Prácticas

El desarrollo y la evaluación empírica de este trabajo aportan reflexiones fundamentales para la adopción de la Inteligencia Artificial en la ingeniería del software:

En primer lugar, el contraste experimental frente a la inferencia directa con LLMs evidencia que el valor de la Inteligencia Artificial en consultoría no reside en delegarle la toma de decisiones como una caja negra. Cuando se consulta directamente a un modelo de frontera sin un marco metodológico, este tiende a extrapolar supuestos no confirmados, incurrir en solucionismo comercial prematuro prescribiendo productos SaaS específicos y emitir juicios cuantitativos inconsistentes. Por el contrario, la fortaleza del paradigma propuesto radica en gobernar la capacidad de comprensión del lenguaje del modelo dentro de un flujo de ingeniería estricto, utilizándolo como transductor para extraer información y delegando el cálculo y la priorización en algoritmos deterministas y auditables.

En segundo lugar, el análisis de viabilidad operativa aporta criterios clave para la selección del entorno de inferencia según los requisitos de privacidad e inversión de cada organización. Cabe recalcar que las métricas temporales del estudio reflejan el tiempo de cómputo neto del sistema en un entorno automatizado; en un despliegue real, la interacción humana se distribuye asíncronamente en el tiempo sin bloquear al consultor. A partir de esta premisa, se identifican tres escenarios de despliegue diferenciados:

Para organizaciones donde la **privacidad es prioritaria pero los recursos son limitados**, modelos compactos como **Gemma 4 E4B** (4B) permiten ejecutar auditorías completas en hardware de consumo modesto (16 GB RAM) en poco más de una hora de cómputo neto, garantizando que el conocimiento sensible no abandone las instalaciones locales para salir del paso, si bien asumiendo que los resultados no alcanzan la máxima exhaustividad que modelos superiores pueden ofrecer. Por su parte, con una **inversión moderada en hardware dedicado local** (servidores on-premise con 24–32 GB de VRAM), resulta viable autoalojar modelos abiertos de gran escala como **Muse Glimmer 30B** o **Qwen 3.8 27B**, aunando soberanía total del dato con un nivel de calidad cercano al de frontera y con el potencial de mejorar la latencia frente a las APIs remotas al eliminar la sobrecarga de red (hipótesis técnica que no pudo validarse empíricamente en este estudio por limitaciones de hardware dedicado). Finalmente, para escenarios donde la **privacidad externa no es una restricción prioritaria**, los servicios en la nube como **Gemini 3.7 Flash** ofrecen los mejores resultados del estudio sin requerir prácticamente inversión en infraestructura propia (más allá del coste por uso de la API), exhibiendo una cota cualitativa superior que, no obstante, mantiene una diferencia estrecha respecto a los modelos locales grandes.

En tercer lugar, el diseño del sistema evidencia un **compromiso explícito entre máxima flexibilidad declarativa y coste computacional**. La decisión de orquestar el flujo conversacional y las transiciones del grafo mediante modelos de lenguaje generales guiados exclusivamente por contratos JSON otorga una adaptabilidad total: el sistema es capaz de instanciar cuestionarios completamente nuevos o modificar las directivas de evaluación sobre la marcha sin necesidad de recopilar datasets de entrenamiento, realizar etiquetados manuales ni reentrenar modelos (**Zero-Shot In-Context Learning**). Este desacoplamiento resulta idóneo para la investigación y la experimentación en preproyecto de software, donde los marcos metodológicos evolucionan con frecuencia. El peaje asumido por esta flexibilidad radica en delegar cada decisión de estado en la inferencia completa de un LLM, lo que incrementa el tiempo de cómputo neto por sesión pero resulta plenamente asumible en un modelo asíncrono y desatendido.

5.4. Trabajo Futuro y Líneas de Investigación

A partir de los hallazgos, lecciones y limitaciones identificadas a lo largo de este trabajo, se proponen tres líneas prioritarias de trabajo futuro:

5.4.1. Ampliación Metodológica y Nuevos Dominios de Decisión

En el plano metodológico, se contempla en primer lugar completar el ciclo de vida de DTGEP mediante la formalización e integración de los subprocesos restantes: **DTGEP3** (para estructurar el plan de transición tecnológica y el diseño de la arquitectura de integración) y **DTGEP6** (para la supervisión continua del valor y la medición del impacto real de las soluciones implantadas). Asimismo, aprovechando la naturaleza declarativa del motor agéntico, se explorará la instanciación de otros marcos de evaluación y gobierno en ingeniería de software y tecnologías de la información, tales como auditorías de madurez de procesos bajo **CMMI**, esquemas de arquitectura empresarial en **TOGAF**. Finalmente, una extensión metodológica de alto impacto consistirá en modelar entrevistas

multi-stakeholder asíncronas, permitiendo que el motor distribuya bloques temáticos especializados a distintos roles organizativos (dirección general, operaciones, finanzas, TI) y sintetice de forma autónoma la visión global de la empresa detectando discrepancias o consensos entre departamentos.

5.4.2. Evolución de la Arquitectura del Motor Agéntico

En el plano de la arquitectura software del motor, se proyecta una transición desde el almacenamiento actual en ficheros JSON planos hacia un modelo de persistencia y gestión de esquemas centralizado en base de datos, evitando la generación masiva de ficheros en disco y facilitando la indexación y recuperación de variables. Asimismo, resulta prioritario optimizar y refinar sistemáticamente los *prompts* y los esquemas JSON de las metodologías existentes para maximizar la calidad de extracción semántica y acotar la dispersión. Para resolver el cuello de botella de memoria y *swap* observado en modelos locales durante entrevistas extensas, se plantea sustituir la acumulación lineal de resúmenes por una memoria episódica indexada vectorialmente (**RAG conversacional selectivo**), recuperando únicamente el contexto pertinente para la capacidad activa.

Adicionalmente, como vía de optimización e industrialización para despliegues donde los marcos metodológicos ya se encuentran consolidados y estables, se propone la **destilación de conocimiento hacia clasificadores especializados**. A partir del corpus de transiciones, decisiones de suficiencia y diagnósticos de alta calidad generados por los modelos de frontera durante este estudio, resulta prometedor entrenar modelos discriminativos ligeros (**Small Language Models**, modelos basados en BERT/DeBERTa, esquemas de inferencia lógica NLI o clasificadores de Machine Learning clásico sobre embeddings densos combinados con SVM o Gradient Boosting) para gobernar las decisiones internas del grafo de LangGraph (tales como el enrutamiento de dudas en `router`, la verificación de suficiencia en `architect` o la extracción de entidades en esquemas JSON). Esta aproximación permitiría evolucionar hacia una **arquitectura dual (Sistema 1 reflexivo y Sistema 2 deliberativo)**: los clasificadores especializados resolverían las transiciones del grafo en milisegundos con coste cero y ejecución determinista local, reservando los LLMs generativos de frontera exclusivamente para la interacción dialéctica abierta, la escucha empática y la formulación contextualizada de repreguntas.

Finalmente, se plantea incorporar nuevas ramas o subgrafos opcionales dentro de la máquina de estados de LangGraph (siguiendo el patrón ya establecido para la resolución de dudas o las preguntas de seguimiento) dedicados a la ejecución algorítmica determinista directamente dentro del flujo del grafo, integrando de forma nativa la fase de procesamiento matemático en el motor genérico sin delegar estas operaciones a la estocasticidad del modelo de lenguaje.

5.4.3. Extensión y Profundización del Marco Experimental

En el plano experimental, se identifican tres vías de desarrollo esenciales. En primer lugar, ampliar el *Ground Truth* de referencia mediante un catálogo más extenso y heterogéneo de organizaciones reales de diversos sectores, dotado de una mayor profundidad y granularidad en la anotación de artefactos. En segundo lugar, llevar a cabo revisiones con paneles de consultores humanos expertos para calibrar formalmente las capacidades evaluadoras

del juez LLM (midiendo el grado de acuerdo inter-evaluador mediante métricas de concordancia estadística) o para ejecutar una auditoría cualitativa exhaustiva de los resultados del sistema. Por último, se proyecta realizar evaluaciones empíricas sobre servidores locales dedicados provistos de hardware adecuado a las arquitecturas de 27B–30B para contrastar experimentalmente la hipótesis de latencia y rendimiento frente a la nube, así como desplegar ensayos de extremo a extremo sin *Teacher Forcing* y estudios de aceptación en vivo con directivos reales mediante marcos de adopción tecnológica (TAM).

BIBLIOGRAFÍA

[1] OECD, *Measuring the Digital Transformation: A Roadmap for the Future*. Paris: OECD Publishing, 2019. doi: 10.1787/9789264311992-en.

[2] P. Forth, T. Reichert, R. de Laubier, y S. Chakraborty, «Flipping the Odds of Digital Transformation Success». Accedido: 22 de julio de 2026. [En línea]. Disponible en: https://www.bcg.com/publications/2020/increasing-odds-of-success-in-digital-transformation

[3] B. Tabrizi, E. Lam, K. Girard, y V. Irvin, «Digital transformation is not about technology», *Harvard Business Review*, vol. 97, n.º 2, p. 13, 2019.

[4] M.-I. Sanchez-Segura, F. Medina-Dominguez, G.-L. Dugarte-Peña, A. de Amescua-Seco, y R. González Cruz, «Engineering sustainable digital transformation projects immune to technical debt», *Kybernetes*, vol. 53, n.º 3, pp. 1092-1116, dic. 2022, doi: 10.1108/K-06-2022-0875.

[5] McKinsey & Company, «Perspectives on transformation». Accedido: 22 de julio de 2026. [En línea]. Disponible en: https://www.mckinsey.com/capabilities/transformation/our-insights/perspectives-on-transformation

[6] V. Dalal, K. Krishnakanthan, I. Maor, y K.-H. Rathje, «Tech debt: Reclaiming tech equity». Accedido: 22 de julio de 2026. [En línea]. Disponible en: https://www.mckinsey.com/capabilities/tech-and-ai/our-insights/tech-debt-reclaiming-tech-equity

[7] R. E. Fairley y others, Eds., *Guide to the Software Engineering Body of Knowledge (SWEBOK Guide)*, Version 4.0. IEEE Computer Society, 2024. [En línea]. Disponible en: https://www.computer.org/education/bodies-of-knowledge/software-engineering

[8] M.-I. Sanchez-Segura, G.-L. Dugarte-Peña, A. Amescua-Seco, y F. Medina-Dominguez, «Exploring how the intangible side of an organization impacts its business model», *Kybernetes*, vol. 50, n.º 10, pp. 2790-2822, 2021, doi: 10.1108/K-05-2020-0302.

[9] E. H. Forman y S. I. Gass, «The Analytic Hierarchy Process—An Exposition», *Operations Research*, vol. 49, n.º 4, pp. 469-486, ago. 2001, doi: 10.1287/opre.49.4.469.11231.

[10] M.-I. Sanchez-Segura, F. Medina-Dominguez, A. de Amescua, y G.-L. Dugarte-Peña, «Knowledge governance maturity assessment can help software engineers during the design of business digitalization projects», *Journal of Software: Evolution and Process*, vol. 33, n.º 4, p. e2326, 2021, doi: 10.1002/smr.2326.

[11] M.-I. Sanchez-Segura, A. Ruiz-Robles, F. Medina-Dominguez, y G.-L. Dugarte-Peña, «Strategic Characterization of Process Assets Based on Asset Quality and Business

Impact», *Industrial Management & Data Systems*, vol. 117, n.º 8, pp. 1720-1737, 2017, doi: 10.1108/IMDS-10-2016-0422.

[12] L. Weng, «LLM Powered Autonomous Agents». Accedido: 1 de enero de 2024. [En línea]. Disponible en: https://lilianweng.github.io/posts/2023-06-23-agent/

[13] S. Yao *et al.*, «ReAct: Synergizing Reasoning and Acting in Language Models», en *International Conference on Learning Representations (ICLR)*, 2023.

[14] M.-I. Sánchez-Segura, F. Medina-Domínguez, y R. González-Cruz, «Identifying Intangible Assets in Organizations: A Review of Existing Technology-driven Approaches and Proposal of a New One That Improves IC Visibility», en *Intellectual Capital in a Global Business Landscape*, Springer Nature Switzerland AG, 2025, pp. 73-94. doi: 10.1007/978-3-031-86362-2_4.

[15] M.-I. Sanchez-Segura, A. de Amescua Seco, F. Medina-Dominguez, G.-L. Dugarte-Peña, y J.-A. Mora-Soto, «ALTUS: A Process-Oriented, Knowledge Governance Maturity Model», en *Knowledge, People, and Digital Transformation: Approaches for a Sustainable Future*, F. Matos, V. Vairinhos, I. Salavisa, L. Edvinsson, y M. Massaro, Eds., Cham: Springer International Publishing, 2020, pp. 133-162. doi: 10.1007/978-3-030-40390-4_10.

[16] M.-I. Sánchez-Segura, A. Ruiz-Robles, y F. Medina-Dominguez, «Uncovering hidden process assets: A case study», *Information Systems Frontiers*, vol. 18, pp. 1041-1049, 2016, doi: 10.1007/s10796-016-9622-5.

[17] M. B. Chrissis, M. Konrad, y S. Shrum, *CMMI for Development: Guidelines for Process Integration and Product Improvement*, 3rd ed. Addison-Wesley Professional, 2011.

[18] AXELOS, *ITIL Foundation: ITIL 4 Edition*. TSO (The Stationery Office), 2019.

[19] ISACA, *COBIT 2019 Framework: Introduction and Methodology*. ISACA, 2019.

[20] M. Dumas, M. La Rosa, J. Mendling, y H. A. Reijers, *Fundamentals of Business Process Management*, 2nd ed. Springer, 2018.

[21] M. Rother y J. Shook, *Learning to See: Value Stream Mapping to Add Value and Eliminate Muda*. Lean Enterprise Institute, 1999.

[22] The Open Group, *The TOGAF Standard, Version 9.2*. Van Haren Publishing, 2018.

[23] S. Opricovic y G.-H. Tzeng, «Compromise solution by MCDM methods: A comparative analysis of VIKOR and TOPSIS», *European Journal of Operational Research*, vol. 156, n.º 2, pp. 445-455, 2004, doi: https://doi.org/10.1016/S0377-2217(03)00020-1.

[24] J. Brans, P. Vincke, y B. Mareschal, «How to select and how to rank projects: The Promethee method», *European Journal of Operational Research*, vol. 24, n.º 2, pp. 228-238, 1986, doi: https://doi.org/10.1016/0377-2217(86)90044-5.

[25] R. Özakıncı y A. Kolukısa Tarhan, «A decision analysis approach for selecting software defect prediction method in the early phases», *Software Quality Journal*, vol. 31, n.º 1, pp. 121-177, sep. 2022, doi: 10.1007/s11219-022-09595-0.

[26] *Uses and Limitations of the AHP Method*. Accedido: 1 de agosto de 2026. [En línea]. Disponible en: https://link.springer.com/book/10.1007/978-3-030-60392-2

[27] M.-I. Sanchez-Segura, G.-L. Dugarte-Peña, F. Medina-Dominguez, y C. García de Jesús, «System dynamics and agent-based modelling to represent intangible process assets characterization», *Kybernetes*, vol. 47, n.º 2, pp. 289-306, 2018, doi: 10.1108/K-03-2017-0102.

[28] M.-I. Sanchez-Segura, G.-L. Dugarte-Peña, F. Medina-Dominguez, y A. Ruiz-Robles, «A model of biomimetic process assets to simulate their impact on strategic goals», *Information Systems Frontiers*, vol. 19, pp. 1067-1084, 2017, doi: 10.1007/s10796-016-9702-6.

[29] X. Hou *et al.*, «Large Language Models for Software Engineering: A Systematic Literature Review». [En línea]. Disponible en: https://arxiv.org/abs/2308.10620

[30] A. Korn, S. Gorsch, y A. Vogelsang, «LLMREI: Automating Requirements Elicitation Interviews with LLMs». [En línea]. Disponible en: https://arxiv.org/abs/2507.02564

[31] M. Tanhaei, «MedNegotiator: Automating requirements negotiation in healthcare; simulating clinical and technical perspectives using Generative AI agents», *Array*, vol. 30, p. 100783, 2026, doi: https://doi.org/10.1016/j.array.2026.100783.

[32] E. M. Bender, T. Gebru, A. McMillan-Major, y S. Shmitchell, «On the Dangers of Stochastic Parrots: Can Language Models Be Too Big? 🦜», en *Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency*, en FAccT '21. Virtual Event, Canada: Association for Computing Machinery, 2021, pp. 610-623. doi: 10.1145/3442188.3445922.

[33] Z. Ji *et al.*, «Survey of Hallucination in Natural Language Generation», *ACM Computing Surveys*, vol. 55, n.º 12, pp. 1-38, mar. 2023, doi: 10.1145/3571730.

[34] H. Zhao *et al.*, «Explainability for Large Language Models: A Survey». [En línea]. Disponible en: https://arxiv.org/abs/2309.01029

[35] I. O. Gallegos *et al.*, «Bias and Fairness in Large Language Models: A Survey», *Computational Linguistics*, vol. 50, n.º 3, pp. 1097-1179, sep. 2024, doi: 10.1162/coli_a_00524.

[36] G. L. Dugarte Peña, «Systems thinking and simulation to help IT/Software professionals to visualize knowledge assets evolution according to digital solutions implementation», Doctoral dissertation, 2019. [En línea]. Disponible en: https://hdl.handle.net/10016/29732

[37] L. Zheng *et al.*, «Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena». [En línea]. Disponible en: https://arxiv.org/abs/2306.05685

[38] K. El Emam, L. Briand, y R. Smith, «Assessor agreement in rating SPICE processes», *Software Process: Improvement and Practice*, vol. 2, n.º 4, pp. 291-306, 1996, doi: 10.1002/(SICI)1099-1670(199612)2:4<291::AID-SPIP54>3.0.CO;2-F.

[39] C. Wohlin, P. Runeson, M. Höst, M. C. Ohlsson, B. Regnell, y A. Wesslén, *Experimentation in Software Engineering*. Berlin, Heidelberg: Springer Science & Business Media, 2012. doi: 10.1007/978-3-642-29044-2.

APÉNDICE A

FORMULACIÓN MATEMÁTICA DE LAS METODOLOGÍAS DE DECISIÓN

En este anexo se detalla el desarrollo formal y las ecuaciones matemáticas teóricas correspondientes a los modelos de evaluación y métodos de toma de decisiones multicriterio integrados en el sistema (**ALTUS**, **SIPAC** y **AHP**), las cuales fundamentan el procesamiento algorítmico automatizado descrito en la Sección *3.2.2. Fase de Procesamiento Algorítmico*.

Metodología ALTUS

De acuerdo con el modelo de madurez de gobierno del conocimiento propuesto por Sánchez-Segura et al. [15] y formalizado por Dugarte-Peña [36], la evaluación analiza cincuenta y una capacidades críticas de conocimiento distribuidas en siete dimensiones arquitectónicas y cuatro niveles de madurez.

A partir de las puntuaciones individuales $s_i \in \{1, \ldots, 5\}$ asignadas a cada capacidad en la escala Likert, el modelo establece dos métricas cuantitativas principales:

1. Puntuación Media por Dimensión:
Para cada una de las siete dimensiones arquitectónicas de la organización (como Configuración, Formación, Memoria Transaccional, etc.), el sistema calcula la media aritmética simple de las puntuaciones obtenidas por las capacidades pertenecientes a dicha dimensión según la Ecuación A.3:

$$\text{avg}_d = \frac{\sum_{i \in \text{Cap}_d} s_i}{\mid \text{Cap}_d \mid} \tag{A.1}$$

Ecuación A.3: Puntuación media de una dimensión arquitectónica en ALTUS [15].

Donde Cap_d es el conjunto de capacidades asociadas a la dimensión arquitectónica d, s_i es la puntuación asignada a la capacidad i, y $|\text{Cap}_d|$ es el número total de capacidades que componen dicha dimensión.

2. Cobertura por Nivel de Madurez (Maturity Level Coverage):
Para evaluar en qué grado la organización satisface los requisitos de cada uno de los cuatro niveles de madurez (ML1 a ML4), el modelo define la tasa de cobertura comparando la suma de las puntuaciones obtenidas frente a la puntuación máxima teórica alcanzable en ese nivel (5 puntos por capacidad) según la Ecuación A.4:

$$\text{Coverage}_L = \frac{\sum_{j \in \text{Cap}_L} s_j}{5 \cdot |\ \text{Cap}_L\ |} \tag{A.2}$$

Ecuación A.4: Tasa de cobertura para un nivel de madurez en ALTUS [15].

Donde Cap_L es el conjunto de capacidades del nivel de madurez L ($L \in \{1, 2, 3, 4\}$), s_j es la puntuación de la capacidad j, y el denominador representa el valor óptimo posible. Esta métrica se expresa como porcentaje (0% a 100%) para ilustrar el avance organizativo.

Metodología SIPAC

La metodología SIPAC (*Systemic Intangible Process Assets Characterization*) [11] estructura la evaluación y caracterización estratégica en doce pasos secuenciales. Los Pasos 10, 11 y 12 formalizan computacionalmente la evaluación cuantitativa y los estados de salud de los activos intangibles de conocimiento, cuya modelización matemática se fundamenta en Dugarte-Peña [36]:

Paso 10.1: Estandarización de Indicadores:
Los valores brutos de los indicadores (valor actual medido $X_{\{\text{Act}\}}$ y valor meta de mejora $X_{\{\text{Goal}\}}$) se proyectan al intervalo uniforme $[0, 1]$ en función del sentido de mejora del indicador:

- Si el sentido es 1 (mayor valor representa mejor desempeño):

$$X' = \frac{X - X_{MIN}}{X_{MAX} - X_{MIN}} \tag{A.3}$$

Ecuación A.5: Estandarización de indicadores en SIPAC (Sentido = 1) [36].

- Si el sentido es -1 (menor valor representa mejor desempeño):

$$X' = \frac{X - X_{MAX}}{X_{MAX} - X_{MIN}} \cdot (-1) \tag{A.4}$$

Ecuación A.6: Estandarización de indicadores en SIPAC (Sentido = −1) [36].

Donde X' es el valor estandarizado, X es el valor bruto ($X_{\{\text{Act}\}}$ o $X_{\{\text{Goal}\}}$), y X_{MIN} y X_{MAX} definen los límites del rango físico admisible.

Paso 10.2: Cálculo del Valor Normalizado del Indicador (X_{NORM}):
A partir de los valores estandarizados ($X'_{\{\text{Act}\}}$, $X'_{\{\text{Goal}\}}$), se obtiene el valor normalizado relativo ($X_{\text{NORM}} \in [-1, 0]$), evaluando la distancia hacia la meta:

- Si el sentido es 1:

$$X_{\text{NORM}} = \frac{X'_{\{\text{Act}\}} - X'_{\{\text{Goal}\}}}{X'_{\{\text{Goal}\}}} \tag{A.5}$$

Ecuación A.7: Valor Normalizado del Indicador en SIPAC (Sentido = 1) [36].

- Si el sentido es -1:

$$X_{\text{NORM}} = \frac{X'_{\{\text{Act}\}} - X'_{\{\text{Goal}\}}}{X'_{\{\text{Act}\}}} \tag{A.6}$$

Ecuación A.8: Valor Normalizado del Indicador en SIPAC (Sentido = −1) [36].

Paso 10.3: Valoración de Calidad, Impacto y Valor Lineal del Activo:
Los valores normalizados de los indicadores se desagregan por dimensión para calcular la valoración media normalizada de calidad (Q_n^{VAL}, indicadores tipo 1) y de impacto (I_n^{VAL}, indicadores tipo 2):

$$\begin{aligned} Q_n^{\text{VAL}} &= \frac{\sum_{i=1}^{q} X_i^n}{q} \\ I_n^{\text{VAL}} &= \frac{\sum_{i=1}^{p} X_i^n}{p} \end{aligned} \tag{A.7}$$

Ecuación A.9: Valoración media normalizada de calidad (Q) e impacto (I) de un activo en SIPAC [36].

Asimismo, el valor lineal del activo intangible n (KA_n^{VAL}) se obtiene mediante la media agregada de sus m indicadores:

$$\text{KA}_n^{\text{VAL}} = \frac{1}{m} \sum_{i=1}^{m} X_{\text{NORM}}^i \tag{A.8}$$

Ecuación A.10: Valor lineal agregado de un Activo de Conocimiento en SIPAC [36].

Donde $\text{KA}_n^{\text{VAL}} \in [-1, 0]$. Por su parte, la importancia relativa del activo (W_k) utilizada en la agregación estratégica se deriva de la importancia ordinal asignada por el usuario en el Paso 5 ($\text{Imp}_k \in \{1, ..., 5\}$) normalizada respecto al conjunto de activos: $W_k = \frac{\text{Imp}_k}{\sum_{j=1}^{n} \text{Imp}_j}$.

Paso 11: Caracterización del Activo Intangible según Estados de Salud:
Las valoraciones (Q_n^{VAL}, I_n^{VAL}) se contrastan frente a los umbrales estratégicos configurables e independientes de calidad (Q_{th}) e impacto (I_{th}). El modelo contempla tres casos de caracterización adaptados a la tipología de los indicadores del activo:

- **Caso 1: Calidad e Impacto (bidimensional, 4 estados):**
  - **Activo Estable (Stable):** $I_n^{\text{VAL}} \geq I_{th}$ y $Q_n^{\text{VAL}} \geq Q_{th}$.
  - **Activo en Evolución (Evolving):** $I_n^{\text{VAL}} \geq I_{th}$ y $Q_n^{\text{VAL}} < Q_{th}$.
  - **Activo Reemplazable (Replaceable):** $I_n^{\text{VAL}} < I_{th}$ y $Q_n^{\text{VAL}} \geq Q_{th}$.
  - **Activo Nocivo (Warning):** $I_n^{\text{VAL}} < I_{th}$ y $Q_n^{\text{VAL}} < Q_{th}$.
- **Caso 2: Solo Calidad (unidimensional, 2 estados):**
  - **Activo de Calidad Aceptable:** $Q_n^{\text{VAL}} \geq Q_{th}$.
  - **Activo de Calidad Insuficiente:** $Q_n^{\text{VAL}} < Q_{th}$.
- **Caso 3: Solo Impacto (unidimensional, 2 estados):**
  - **Activo de Impacto Aceptable:** $I_n^{\text{VAL}} \geq I_{th}$.

- **Activo de Impacto Insuficiente:** $I_n^{\mathrm{VAL}} < I_{th}$.

Paso 12: Valoración de Consecución del Objetivo Estratégico ($\mathrm{SG_{VAL}}$):
La valoración cuantitativa de la consecución del objetivo de negocio se calcula agregando los valores lineales de todos los activos ponderados por su peso relativo (W_k):

$$\mathrm{SG_{VAL}} = \sum_{k=1}^{n} W_k \cdot \mathrm{KA}_k^{\mathrm{VAL}} \tag{A.9}$$

Ecuación A.11: Valoración de consecución del objetivo estratégico en función de los intangibles [36].

Método AHP (Analytic Hierarchy Process)

El método AHP [9] estructura la toma de decisiones multicriterio a través de comparaciones pareadas jerárquicas:

1. Matriz de Comparaciones Pareadas y Vector de Prioridades:
A partir de la matriz pareada $A = \left(a_{ij}\right)_{n\times n}$ construida mediante la escala fundamental de Saaty (1–9), el vector de prioridades $\boldsymbol{w}$ se obtiene por normalización de columnas:

$$w_i = \frac{1}{n}\sum_{j=1}^{n}\frac{a_{ij}}{\sum_{k=1}^{n} a_{kj}} \tag{A.10}$$

Ecuación A.12: Cálculo del vector de prioridades (pesos) en AHP [9].

2. Estimación del Autovalor Máximo ($\lambda_{(\mathrm{max}}$):
Se calcula promediando el cociente entre el vector de consistencia $A\boldsymbol{w}$ y el vector de prioridades $\boldsymbol{w}$:

$$\lambda_{\max} = \frac{1}{n}\sum_{i=1}^{n}\frac{\sum_{j=1}^{n} a_{ij}\cdot w_j}{w_i} \tag{A.11}$$

Ecuación A.13: Estimación del autovalor máximo en AHP [9].

3. Índice de Consistencia («CI») y Ratio de Consistencia («CR»):
El índice de consistencia («CI») mide la desviación de la transitividad:

$$\mathrm{CI} = \frac{\lambda_{\max} - n}{n-1} \tag{A.12}$$

Ecuación A.14: Cálculo del índice de consistencia en AHP [9].

El ratio de consistencia («CR») se obtiene dividiendo «CI» entre el índice de consistencia aleatoria tabulado («RI»):

$$\mathrm{CR} = \frac{\mathrm{CI}}{\mathrm{RI}} \tag{A.13}$$

Ecuación A.15: Cálculo del ratio de consistencia en AHP [9].

La matriz se valida como consistente si CR no supera los umbrales de tolerancia de Saaty: 0.05 para $n = 3$, 0.09 para $n = 4$, y 0.10 para $n \geq 5$.

4. Puntuación Global Ponderada:
La puntuación final de cada alternativa i se obtiene ponderando su desempeño bajo cada criterio j por el peso de dicho criterio:

$$\text{score}_i = \sum_{j=1}^{m} w_j^{\text{crit}} \cdot w_{i,j}^{\text{alt}} \tag{A.14}$$

Ecuación A.16: Puntuación global ponderada de alternativas en AHP [9].

APÉNDICE B

TABLAS DETALLADAS DE LA EVALUACIÓN EXPERIMENTAL

En este anexo se recopila de forma exhaustiva el registro cuantitativo completo de las métricas obtenidas por los modelos evaluados en los casos de test a ciegas para las metodologías **ALTUS**, **SIPAC** y **AHP**. Estas tablas proporcionan el soporte numérico formal y el registro de reproducibilidad para las figuras analíticas presentadas en el Capítulo *4. Marco y Resultados de la Evaluación Experimental*.

Métricas Detalladas en ALTUS

La Tabla B.1 recoge el registro cuantitativo exhaustivo de la evaluación en ALTUS para cada modelo y caso de prueba a ciegas. Además de las métricas principales de desempeño diagnóstico (**Acc**, **MAE**), eficacia extractiva (**Hit Rate**) y calidad de indagación (**Calidad**) descritas en el Sección *4.2.2. Métricas de Evaluación de ALTUS*, la tabla incorpora las siguientes variables operacionales y de control del diálogo:

- **Redundancia (Redund. / Over-asking):** Proporción de repreguntas que solicitan información técnica que ya había sido revelada previamente por el interlocutor ($\frac{|\text{Over-asking}|}{N_{\text{followups}}}$).
- **Parada Prematura (Parada P. / Premature Stop):** Proporción de capacidades organizacionales evaluadas de forma directa sin emitir ninguna pregunta de seguimiento ($\frac{|\text{Premature Stop}|}{N_{\text{capacidades}}}$).
- **Turnos:** Número medio de turnos conversacionales de interacción requeridos por capacidad evaluada, donde la formulación de la pregunta base inicial representa el valor basal de 1 turno y cada repregunta de seguimiento (*follow-up*) incrementa la cuenta sucesivamente.

Tabla B.1

Métricas detalladas de diagnóstico y diálogo conversacional en ALTUS.

Modelo	Caso	Acc	MAE	Hit Rate	Redund.	Parada P.	Calidad	Turnos
Gemma4 E4B Local Ollama	G2: Empresa B	15.7%	1.078	85.7%	14.3%	86.3%	2.57	1.14
	G3: Empresa C	19.6%	1.412	100.0%	0.0%	92.2%	2.50	1.08
	G4: Empresa D	17.6%	1.333	100.0%	0.0%	88.2%	2.83	1.12
	Media Global	**17.6%**	**1.274**	**95.2%**	**4.8%**	**88.9%**	**2.63**	**1.11**
DeepSeekR1 Local Ollama	G2: Empresa B	13.7%	1.314	55.3%	44.7%	78.4%	1.00	1.75
	G3: Empresa C	9.8%	1.686	84.4%	15.6%	76.5%	0.91	1.88
	G4: Empresa D	37.3%	0.784	100.0%	0.0%	94.1%	2.00	1.06
	Media Global	**20.3%**	**1.261**	**79.9%**	**20.1%**	**83.0%**	**1.30**	**1.56**
Ornith 9B Local Ollama	G2: Empresa B	17.6%	1.176	78.6%	21.4%	84.3%	2.57	1.27
	G3: Empresa C	15.7%	1.392	0.0% *	0.0% *	100.0%	0.00 *	1.00
	G4: Empresa D	17.6%	0.902	50.0%	50.0%	98.0%	2.50	1.04
	Media Global	**17.0%**	**1.157**	**42.9%**	**23.8%**	**94.1%**	**1.69**	**1.10**
Gemma4 31B Cloud API	G2: Empresa B	11.8%	1.059	0.0% *	0.0% *	100.0%	0.00 *	1.00
	G3: Empresa C	17.6%	1.490	0.0% *	0.0% *	100.0%	0.00 *	1.00
	G4: Empresa D	19.6%	0.843	100.0% *	0.0% *	98.0%	0.00 *	1.02
	Media Global	**16.3%**	**1.131**	**33.3%** *	**0.0%** *	**99.3%**	**0.00** *	**1.01**
Muse Glimmer 30B Cloud API	G2: Empresa B	35.3%	0.882	100.0%	0.0%	92.2%	2.80	1.10
	G3: Empresa C	17.6%	1.451	88.9%	11.1%	86.3%	2.67	1.18
	G4: Empresa D	21.6%	0.863	100.0%	0.0%	84.3%	2.55	1.22
	Media Global	**24.8%**	**1.065**	**96.3%**	**3.7%**	**87.6%**	**2.67**	**1.17**
Qwen 3.8 27B Cloud API	G2: Empresa B	23.5%	0.961	100.0%	0.0%	96.1%	3.00	1.06
	G3: Empresa C	19.6%	1.529	100.0%	0.0%	94.1%	2.67	1.06
	G4: Empresa D	15.7%	0.980	100.0%	0.0%	88.2%	2.89	1.18
	Media Global	**19.6%**	**1.157**	**100.0%**	**0.0%**	**92.8%**	**2.85**	**1.10**
Gemini 3.7 Flash Cloud API	G2: Empresa B	23.5%	0.941	100.0%	0.0%	98.0%	0.00	1.04
	G3: Empresa C	15.7%	1.510	100.0%	0.0%	94.1%	2.67	1.06
	G4: Empresa D	19.6%	0.961	100.0%	0.0%	88.2%	2.43	1.14
	Media Global	**19.6%**	**1.137**	**100.0%**	**0.0%**	**93.5%**	**1.70**	**1.08**

* **Nota metodológica sobre casos con escasa o nula interacción:** Cuando el modelo incurre en parada prematura generalizada (por ejemplo, **Gemma4 31B** en G2 y G4 con 100% de parada prematura), las métricas del proceso conversacional (*Hit Rate*, *Redundancia* y *Calidad*) se calculan sobre 0 o 1 repregunta, constituyendo un artefacto estadístico de la falta de interacción.

Métricas Detalladas en SIPAC

La Tabla B.2 detalla el rendimiento en deducción semántica ponderada (*Weighted F1*) obtenido en cada una de las etapas del pipeline de SIPAC bajo *Teacher Forcing*.

Tabla B.2

Métricas detalladas de deducción semántica (Weighted F1) en SIPAC.

Modelo	Caso	F1 Global	F1 GIA	F1 Activos	F1 CI	F1 Artef.	F1 Indic.
Gemma4 E4B Local Ollama	G2: Empresa B	0.599	0.667	0.800	0.800	0.479	0.248
	G3: Empresa C	0.379	0.533	0.400	0.400	0.278	0.283
	G4: Empresa D	0.399	0.476	0.400	0.667	0.208	0.244
	Media Global	**0.459**	**0.559**	**0.533**	**0.622**	**0.322**	**0.258**
DeepSeekR1 Local Ollama	G2: Empresa B	0.410	0.545	0.667	0.370	0.467	0.000
	G3: Empresa C	0.182	0.333	0.333	0.000	0.242	0.000
	G4: Empresa D	0.430	0.533	0.400	0.800	0.417	0.000
	Media Global	**0.341**	**0.470**	**0.467**	**0.390**	**0.375**	**0.000**
Ornith 9B Local Ollama	G2: Empresa B	0.503	0.533	0.444	0.714	0.533	0.290
	G3: Empresa C	0.486	0.500	0.303	0.444	0.222	0.960
	G4: Empresa D	0.432	0.333	0.333	0.250	0.242	1.000
	Media Global	**0.474**	**0.455**	**0.360**	**0.469**	**0.332**	**0.750**
Gemma4 31B Cloud API	G2: Empresa B	0.561	0.667	0.667	0.667	0.538	0.264
	G3: Empresa C	0.481	0.667	0.556	0.333	0.429	0.422
	G4: Empresa D	0.429	0.476	0.500	0.571	0.333	0.267
	Media Global	**0.490**	**0.603**	**0.574**	**0.524**	**0.433**	**0.318**
Muse Glimmer 30B Cloud API	G2: Empresa B	0.577	0.667	0.667	0.667	0.607	0.275
	G3: Empresa C	0.322	0.571	0.400	0.333	0.172	0.133
	G4: Empresa D	0.471	0.476	0.462	0.500	0.471	0.444
	Media Global	**0.457**	**0.571**	**0.510**	**0.500**	**0.417**	**0.284**
Qwen 3.8 27B Cloud API	G2: Empresa B	0.246	0.667	0.561	0.000	0.000	0.000
	G3: Empresa C	0.506	0.667	0.417	0.667	0.400	0.381
	G4: Empresa D	0.539	0.417	0.462	0.800	0.571	0.444
	Media Global	**0.430**	**0.584**	**0.480**	**0.489**	**0.324**	**0.275**
Gemini 3.7 Flash Cloud API	G2: Empresa B	0.572	0.667	0.708	0.727	0.516	0.240
	G3: Empresa C	0.518	0.800	0.556	0.533	0.356	0.343
	G4: Empresa D	0.442	0.476	0.600	0.400	0.400	0.333
	Media Global	**0.511**	**0.648**	**0.621**	**0.553**	**0.424**	**0.305**

Métricas Detalladas en AHP

La Tabla B.3 detalla las puntuaciones de calidad asignadas por el juez LLM sobre las cuatro dimensiones analíticas del soporte a la decisión y priorización en AHP.

Tabla B.3

Métricas detalladas de soporte a la decisión y consistencia en AHP.

Modelo	Caso	Score Norm.	CR	Adaptación (0-3)	Ortogonal. (0-3)	Completitud (0-3)	Justificación (0-3)
Gemma4 E4B Local Ollama	G2: Empresa B	0.583	0.074	2.00	1.00	2.00	2.00
	G3: Empresa C	0.667	0.163	2.00	2.00	2.00	2.00
	G4: Empresa D	0.667	0.016	2.00	2.00	2.00	2.00
	Media Global	**0.639**	**0.084**	**2.00**	**1.67**	**2.00**	**2.00**
DeepSeekR1 Local Ollama	G2: Empresa B	0.500	0.265	1.00	2.00	2.00	1.00
	G3: Empresa C	0.500	0.266	1.00	2.00	2.00	1.00
	G4: Empresa D	0.417	0.473	1.00	2.00	1.00	1.00
	Media Global	**0.472**	**0.335**	**1.00**	**2.00**	**1.67**	**1.00**
Ornith 9B Local Ollama	G2: Empresa B	0.500	0.191	1.00	2.00	2.00	1.00
	G3: Empresa C	0.500	0.191	1.00	2.00	2.00	1.00
	G4: Empresa D	0.583	0.131	2.00	2.00	2.00	1.00
	Media Global	**0.528**	**0.171**	**1.33**	**2.00**	**2.00**	**1.00**
Gemma4 31B Cloud API	G2: Empresa B	0.583	0.074	2.00	1.00	2.00	2.00
	G3: Empresa C	0.500	0.012	2.00	1.00	2.00	1.00
	G4: Empresa D	0.667	0.074	2.00	2.00	2.00	2.00
	Media Global	**0.583**	**0.053**	**2.00**	**1.33**	**2.00**	**1.67**
Muse Glimmer 30B Cloud API	G2: Empresa B	0.750	0.044	3.00	2.00	2.00	2.00
	G3: Empresa C	0.500	0.044	2.00	1.00	2.00	1.00
	G4: Empresa D	0.417	0.148	2.00	1.00	1.00	1.00
	Media Global	**0.556**	**0.079**	**2.33**	**1.33**	**1.67**	**1.33**
Qwen 3.8 27B Cloud API	G2: Empresa B	0.500	0.000	1.00	2.00	2.00	1.00
	G3: Empresa C	0.500	0.076	1.00	2.00	2.00	1.00
	G4: Empresa D	0.667	0.113	2.00	2.00	3.00	1.00
	Media Global	**0.556**	**0.063**	**1.33**	**2.00**	**2.33**	**1.00**
Gemini 3.7 Flash Cloud API	G2: Empresa B	0.667	0.075	2.00	3.00	2.00	1.00
	G3: Empresa C	0.667	0.076	2.00	2.00	2.00	2.00
	G4: Empresa D	0.667	0.075	2.00	2.00	2.00	2.00
	Media Global	**0.667**	**0.075**	**2.00**	**2.33**	**2.00**	**1.67**

APÉNDICE C

DECLARACIÓN DE USO DE IA GENERATIVA

He utilizado IA generativa en este trabajo:

Sí;	**No**;

1. Reflexión sobre comportamiento legal, ético y responsable

Pregunta	
1. En mi interacción con herramientas de Inteligencia Artificial Generativa he facilitado **datos de carácter confidencial** contando siempre con la debida autorización de los interesados.	
Sí, he usado estos datos con la autorización correspondiente.	No, no he usado datos de carácter confidencial.
2. En mi interacción con herramientas de Inteligencia Artificial Generativa he facilitado **materiales protegidos por derechos de autoría** contando con la autorización respectiva.	
Sí, he usado estos materiales con autorización de los titulares de derechos de autor; o bien sin ella porque se ajustan a una de las excepciones o límites que permite la ley: • Obra en dominio público	No, no he usado materiales protegidos por derechos de autoría.

• Obra licenciada (licencias Creative Commons) • Uso de fragmentos con fines de investigación (derecho de cita)	
3. En mi interacción con herramientas de Inteligencia Artificial Generativa he facilitado **datos de carácter personal** con la debida autorización de los interesados.	
Sí, he usado estos datos con autorización de los interesados y conforme a las instrucciones contenidas en la guía aprobada por la Universidad.	No, no he usado datos de carácter personal.
4. Mi utilización de la herramienta de Inteligencia Artificial Generativa ha **respetado sus términos de uso**, así como los principios éticos esenciales, no orientándola de manera maliciosa a obtener un resultado inapropiado para el trabajo presentado.	
Sí	No

2. Declaración de uso técnico

Declaro haber hecho uso del sistema de IAG (Google Antigravity (modelos Gemini 2.5 Pro y Gemini 3.8 Flash)) para:

Documentación y redacción

- **Soporte a la documentación y redacción del trabajo: generación de contenido textual para la elaboración de la memoria, así como apoyo en la documentación de los procesos seguidos durante el desarrollo del proyecto:**

A partir del prompt: *«Quiero que me redactes la dedicatoria en report/report.typ a partir de las siguientes ideas...»* o *«Escribe un párrafo que transicione entre la metodología DTGEP y la arquitectura agéntica en solucion.typ»*, teniendo como interacción: la redacción preliminar y el posterior refinamiento del tono académico para su integración en la memoria y en el guion de defensa.

- **Soporte a la reflexión en relación con el desarrollo del trabajo: proceso iterativo de análisis de alternativas y enfoques utilizando la IAG:**

A partir del prompt: *«Quiero discutir qué encaja más en el sistema si usar API REST o WebSockets tras analizar core y web»* o *«¿Es justificable que el motor de entrevistado sea genérico pero la interfaz web esté adaptada a cada marco?»*, teniendo como interacción: el debate técnico y contraste de alternativas arquitectónicas de software (latencia, desacoplamiento y complejidad operativa), reflejado en el capítulo de diseño de la solución.

- **Revisión o reescritura de párrafos redactados previamente:**

A partir del prompt: *«Puedes reescribir las conclusiones de la comparativa entre inferencia directa y el sistema agéntico en evaluacion.typ»* o *«Mi tutora me ha realizado varios comentarios en la memoria, organicemos una matriz de cambios»*, teniendo como interacción: la reescritura de pasajes complejos para dotarlos de mayor concisión, fluidez y rigor formal conforme a las revisiones académicas.

- **Búsqueda de información o respuesta a preguntas concretas:**

A partir del prompt: *«¿Cómo funciona el algoritmo húngaro en nuestro sistema y de dónde obtiene los costes?»* o *«Explícame al detalle el cálculo matemático de consistencia en AHP implementado»*, teniendo como interacción: la profundización teórica y validación de las formulaciones matemáticas de concordancia semántica (algoritmo de Munkres) y ratios de consistencia (CR < 0.10) plasmadas en la memoria.

- **Búsqueda de bibliografía:**

A partir del prompt: *«Estoy recopilando referencias para la memoria sobre economía del software, SWEBOK y marcos de madurez digital, ¿qué autores clave deberíamos revisar?»*, teniendo como interacción: la identificación de literatura relevante y la homogeneización de entradas en formato BibTeX.

Desarrollar contenido específico

- **Asistencia en el desarrollo de líneas de código (programación):**

A partir del prompt: *«Quiero configurar LiteLLM con LM Studio para invocar modelos locales»* o *«En la web el div del chat no tiene scroll propio y hace crecer toda la página, arréglalo manteniendo Tailwind»*, teniendo como interacción: la generación, depuración e integración continua de código TypeScript/React para la plataforma web y Python para el motor agéntico con LangGraph.

- **Generación de esquemas, imágenes, audios o vídeos:**

A partir del prompt: *«Ponte creativo en la presentación para hacer figuras donde explicar la metáfora del iceberg de deuda técnica»* o *«Diseña los gráficos de radar para las dimensiones ALTUS a partir del Excel de evaluación»*, teniendo como interacción: el diseño e implementación de componentes visuales en Vue/Slidev y diagramas vectoriales para la memoria.

- **Procesos de optimización:**

A partir del prompt: *«Claramente hay un problema de RateLimit (HTTP 429) y timeouts en la evaluación de SIPAC al evaluar muchas variantes muy rápido»*, teniendo como interacción: la reestructuración del flujo asíncrono con control de concurrencia, reintentos exponenciales y refactorización de estados para evitar bucles en el benchmark.

- **Tratamiento de datos: recogida, análisis, cruce de datos…:**

A partir del prompt: *«En el gráfico de recall vs precisión de la evaluación creo que abusamos de scatterplot, analiza los datos y sugiere cómo agruparlos»* o *«Lee los resultados de los tests y compáralos con el Ground Truth»*, teniendo como interacción: el cruce de matrices de evaluación cuantitativa (MAE en ALTUS, Weighted Recall en SIPAC y CR en AHP) para su sintetización en tablas y gráficas en Typst.

- **Inspiración de ideas en el proceso creativo:**

A partir del prompt: *«Estoy planteando cómo estructurar la presentación de este TFM para que la narrativa sea atractiva e impacte al tribunal»*, teniendo como interacción: la conceptualización del hilo discursivo basado en la tríada experimental y la visualización de la deuda técnica previa.

- **Otros usos vinculados a la generación de puntos concretos del desarrollo específico del trabajo:**

A partir del prompt: *«Planifica y estructura commits atómicos en base a los cambios de Git actuales»*, teniendo como interacción: la organización sistemática del control de versiones del repositorio y la verificación de compilación Typst.

3. Reflexión sobre utilidad

El uso del asistente de Inteligencia Artificial Generativa (Google Antigravity) ha constituido una herramienta de apoyo continuo durante la ejecución de este Trabajo de Fin de Máster. Resulta especialmente significativo señalar el paralelismo existente entre el objeto de investigación de este trabajo —el diseño de una metodología y arquitectura basada en agentes generativos para la toma de decisiones en ingeniería de software— y el empleo de un agente generativo como asistente técnico durante su desarrollo.

Entre las principales fortalezas identificadas destaca la agilidad en la programación por parejas (pair-programming) sobre un ecosistema heterogéneo (Python con LangGraph, TypeScript con Next.js y Typst), la resolución rápida de errores de concurrencia en la evaluación automatizada y el soporte como interlocutor técnico para contrastar alternativas arquitectónicas.

Por otro lado, como debilidades y limitaciones se ha constatado la tendencia recurrente de los modelos a sugerir dependencias desactualizadas, la generación de código excesivamente verboso en interfaces de usuario y el riesgo de asumir como válidas explicaciones teóricas sin contraste empírico. Esta experiencia ha reafirmado una de las conclusiones nucleares del propio TFM: los sistemas generativos alcanzan su máximo valor cuando operan bajo un marco metodológico estructurado, supervisado y validado en todo momento por el criterio crítico del ingeniero humano (human-in-the-loop).